

شرح الورقة بالمصري — Foundation or Formula?

يعني إيه "Formula" و يعني إيه "Foundation"؟

عنوان الورقة بيحط كلمتين قدام بعض. خرينا نفهمهم الأول، لأن الورقة كلها مبنية على المقارنة بينهم.

1) ال Formula — "الصيغة"، الطريقة القديمة

ال Formula معناها **معادلة رياضية** إنت بتفترضها وبعدين بتطبط أرقامها على بياناتك.

مثال: **ARIMA** بتقول لك إن قيمة النهارده = معادلة فيها قيم الأيام اللي فاتت + الأخطاء اللي فاتت. المعادلة نفسها إنت اللي بتختارها، والكمبيوتر بيحدد الأرقام (ال parameters) اللي جواها من بياناتك إنت لوحدك.

خصائصها:

- صغيرة جداً — 3 أو 4 أرقام بس.
- بتتعلم من سلسلتك إنت بس — معندهاش أي معرفة سابقة بالدنيا.
- مفهومة — تقدر تبص على الأرقام وتفهم الموديل بيقول إيه وليه.
- قديمة ومجربة — بقالها 50 سنة في الكتب والصناعة.

من ديه: **ARIMA** ، **ETS** ، **Theta** ، **Seasonal Naive**.

2) ال Foundation — "الأساس"، الطريقة الجديدة

ال Foundation Model معناها شبكة عصبية ضخمة اتدربت مرة واحدة على ملايين السلاسل الزمنية من الدنيا كلها، وبعدين بتديها سلسلتك إنت فتتنبأ ليك من غير ما تدربها من أصله. ودي اللي بيسمونها **zero-shot**.

TimesFM-3 من ديه: 330 مليون رقم جواه، متدرب على أكثر من تريليون نقطة زمنية.

خصائصها:

- ضخمة — 330 مليون رقم مقابل 3.
- بتعرف حاجات من بره سلسلتك — شافت ملايين السلاسل قبل كده.
- مقفولة — مش هتتعرف تبص جواها وتفهم قرارها.
- جديدة — الحاجات دي طلعت في آخر سنتين.

الكلمة المفتاحية: مصدر المعرفة

الفرق الحقيقي بينهم مش "قديم وجديد" ولا "صغير وكبير" — الفرق هو المعرفة جاية منين:

Foundation	Formula	
من ملايين السلاسل التي اتدربت عليها	من سلسلتك إنت بس	بتعرف من فين؟
مفیش — بتشتغل على طول	بيانات كفاية عشان تقدّر معادلتها	محتاجة إيه؟
لما بياناتك قليلة أو شكلها غريب	لما يبقى عندك بيانات كتير وشكلها واضح	بتنفع إمتى؟

تشبيه: ال Formula زي **دكتور خريج لسه** بس معاه كتاب مطبوط: لو الحالة موصوفة في الكتاب بالطبط، هيبقى ممتاز. وال Foundation زي **دكتور شاف مليون حالة:** مش معاه كتاب، بس عنده **حدس** قوي — ولو الحالة نادرة هيبقى أحسن منه بكتير.

وعشان كده العنوان سؤال

"Foundation or Formula?" يعني: **أستخدم الوحش الضخم اللي شاف الدنيا، ولا المعادلة الصغيرة المفهومة؟**

والورقة **مش** بتجاوب "ده أحسن من ده". بتجاوب: **إمتى ده وإمتى ده** — وبأرقام متختبرة إحصائياً مش بآراء.

من الآخر: Formula = معادلة صغيرة بتتعلّم من بياناتك إنت. Foundation = شبكة ضخمة اتعلّمت من بيانات الدنيا. والسؤال هو مين فيهم ينفعك، **إمتى**.

0. The Big Idea in One Breath — الفكرة الكبيرة في نفس واحد

قبل ما ندخل في أي تفصيلة، خد الصورة كلها في دقيقة:

Google نزلت موديل اسمه **TimesFM-3** بيتنبأ بالسلاسل الزمنية (time series) من غير ما تدّربه على بياناتك خالص — بيسمّوا ده **zero-shot**. السؤال العملي: أنا ك محلل، لو قدامي سلسلة زمنية، أستخدم الموديل الجبار ده ولا أستخدم **ARIMA** القديمة الكويسة؟

الورقة دي بتجاوب على السؤال ده. وأهم حاجة فيها إننا **مخترعناش طريقة جديدة** — دي دراسة مقارنة (comparative study)، وقلناها بصراحة في الورقة. اللي يخليها تستاهل النشر حاجة ثانية: **إحنا مولّدا البيانات بنفسنا**، والسبب هنشره بعد شوية وهو قلب الموضوع كله.

النتيجة باختصار: **مفیش طرف كسب**. لكن الطريقة اللي "مكسبش" بيها كل طرف هي الحكاية الحلوة.

من الآخر: الورقة مش بتقول "ال AI كسب" ولا "الكلاسيكي أحسن" — بتقول **إمتى** ده وإمتى ده، وبأرقام متختبرة إحصائياً.

1. What Is TimesFM-3? — إيه هو ال TimesFM-3 أصلاً؟

في 31 أغسطس 2026 نزلت Google الجيل الثالث من موديلها **TimesFM**. خصائصه:

- **330 مليون parameter** (بالطبط 330,710,976 — إحنا عدّيناهم من ال checkpoint نفسه مش نقلاً عن حد).
- متدرّب على **أكثر من تريليون نقطة زمنية** (time points)، بيانات حقيقية و بيانات صناعية (synthetic).

- أول واحد في العيلة متدرّب أصلاً على الـ **multivariate** — يعني ياخذ أكثر من سلسلة مع بعض، ويقدر ياخذ **covariates** (متغيرات مساعدة) سواء من الماضي أو معروفة للمستقبل.
- يستخدم **attention** بالتبادل: مرة على المحور الزمني (causal-temporal) ومرة على محور المتغيرات (full-variant).
- **بيطلع الأفق كله في مرة واحدة** (non-autoregressive) — يعني مش بيتنبأ بخطوة ويرجع يدخلها عشان يتنبأ باللي بعدها.
- **quantiles 9** (من **q0.1** لـ **q0.9**) — يعني مش رقم واحد، دا توزيع.
- طول الـ context بيوصل **16k** نقطة.
- **تشبيه:** تخيل دكتور اتخرج ومشتغلش في مستشفى واحدة بس — لأ، ده اتفرّج على مليون حالة من مستشفيات الدنيا كلها. لما ييجي يشوف مريضك، هو معندوش ملف مريضك بس عنده **حدس** اتبنى من كل اللي شافه. ده بالطبط معنى **zero-shot** : مشافش سلسلتك، بس شاف حاجات شبهها كتير أوي.
- **من الآخر:** **TimesFM-3** = موديل ضخم بيتنبأ من غير تدريب، وبيديك توزيع مش رقم.

2. Why the Published Evidence Is Not Enough — ليه الأدلة المنشورة مش كفاية؟

هنا لب المشكلة، وده اللي بنى عليه البحث كله.

لما شركة تنزل موديل، بتقولك "بص، كسبت على الـ benchmarks الفلانية". المشكلة إن الـ benchmarks دي بيانات عامة **ومنشورة على الإنترنت**، والموديل اتدرّب على... الإنترنت.

باحثين اسمهم Meyer وزماليه (2025) عملوا حاجة مهمة: تتبّعوا **نسب البيانات** لـ 22 موديل foundation model للسلاسل الزمنية. لقوا إن من **dataset 401** استُخدمت في تقييمهم، **6% بس** هي اللي **مظهرتش** في corpus التدريب بتاع أي موديل منهم.

يعني إيه؟ يعني 94% من التقييمات دي، الموديل يمكن يكون **شايف الإجابة قبل الامتحان**.

وأكثر من كده: لقوا إن تداخل بنسبة **0.1% بس** بين بيانات التدريب وبيانات الاختبار ممكن يحرك الـ MAPE بمقدار **8 لـ 29 نقطة مئوية**. ودي مش نسبة صغيرة، دي فرق بين موديل ممتاز وموديل فاشل.

وكمان — والنقطة دي ذكية — التسريب (leakage) مش لازم يكون **مباشر**. لو الموديل اتدرّب على سلسلة تانية **متداخلة زمنياً** ومرتبطة سببياً بسلسلتك، هو كده أخذ ميزة على سلسلتك حتى لو عمره ما شافها.

تشبيه: طالب ذاكر من بنك أسئلة، والامتحان جه 94% منه من بنك الأسئلة ده. درجته العالية معناها إيه بالطبط؟ مش عارفين. ودي بالطبط مشكلة الـ benchmarks.

فيه كمان انتقاد تاني اتقال كتير على الأوراق دي: بيقدروا الموديل الجبار بـ baselines كلاسيكية **مفكوكة وغير متظبطة** — يعني ياخدوا **ARIMA** لوحدها بدل ما ياخدوا الـ **combination** اللي بتكسب في مسابقات التنبؤ زي **M4**. ده زي ما تقارن فريقك بلاعب واحد من الفريق التاني.

من الآخر: أي رقم من benchmark عام = قياس **مجهول المصدر**، ولازم نلاقي طريقة تانية.

3. The Idea That Closes Both Objections — الفكرة اللي بتقفل الاعتراضين مع بعض

الحل اللي الورقة اختارته: إحنا نوّلد البيانات بنفسنا.

لما نوّلد سلسلة من عملية معروفة (Data-Generating Process — واختصارها DGP)، بيحصل حاجتين في نفس اللحظة، وده اللي بيدي المقارنة قوتها:

1. **الموديل قطعاً مشافش السلسلة دي** — مش "على الأغلب"، لأ؛ السلسلة دي **معملتش أصلاً** غير لما شغلنا التجربة. فمستحيل تكون في corpus التدريب.

2. **الموديل الكلاسيكي بيبقى "صح بالتعريف"** (correctly specified by construction) — لو البيانات فعلاً **ARIMA(1,1,1) with drift**، بيبقى **AutoARIMA** مش تقرب للحقيقة، دي هي الحقيقة نفسها، وفاضل بس إنه يقدر ال parameters.

النقطة الثانية دي هي السر. عشان كده السؤال بقى حاد ومحدد:

- الموديل بيخسر قد إيه لما يلعب على أرض الكلاسيكي (يعني الشكل الرياضي صح 100%)؟
- ويكسب قد إيه لما مفيش شكل كلاسيكي صح (كسر هيكل، لا خطية، طلب متقطع، تقلّب)؟

⚠️ تفرقة مهمة جداً — لازم تكون أمينة

فيه حاجة لازم نقولها بصراحة، وقلناها في الورقة:

- اللي التصميم بتاعنا **بيمنعه** هو التلوث على مستوى **التحقق الفردي** (the realisation) — السلسلة دي بالذات مكنتش موجودة.
- اللي التصميم **مش** بيمنعه هو الألفة على مستوى **العيلة** (the family). يعني **TimesFM-3** اتدرّب على بيانات **صناعية** كمان، والبيانات الصناعية لل time-series models عادةً بتتولّد من نفس العائلات دي بالظبط (AR, ARMA, seasonal..). فهو **يعرف الشكل العام** حتى لو مشافش النسخة دي.

عشان كده **شيلنا كلمة "Contamination-Free" من عنوان الورقة** وخيلناه "A Simulation-Based Comparison" — لأن الادعاء الأول كان أقوى من اللي إحنا فعلاً قدرنا نثبتته.

من الآخر: إحنا مولّدنا البيانات عشان نضمن حاجتين: الموديل مشافهاش، والكلاسيكي صح بالتعريف. بس مدّعينا إن الموديل مش عارف نوع البيانات — دي أمانة علمية مش تواضع.

4. Design of the Simulation — تصميم دراسة المحاكاة

4.1 The Nine DGPs — التسع عمليات المولّدة للبيانات

اخترنا 9 عمليات بحيث تغطي المدى من "الكلاسيكي صح تماماً" لـ "مفيش كلاسيكي صح":

الرمز	العملية	الشرح بالمصري	مين "صح" فيها؟
D1	AR(1), $\phi=0.7$	القيمة النهارده = $0.7 \times$ امبارح + عشوائية. أبسط حاجة ممكنة.	ARIMA
D2	ARMA(1,1)	زي فوق + بتفتكر الخطأ بتاع امبارح كمان.	ARIMA
D3	ARIMA(1,1,1) + drift	فيها اتجاه (trend) — بتمشي لفوق بمعدل ثابت + عشوائية.	ARIMA
D4	SARIMA(1,0,0)(1,1,0)[12]	فيها موسمية قوية كل 12 شهر (زي مبيعات رمضان).	ARIMA
D5	ETS(A,A,A)	مستوى + اتجاه + موسمية، بس بصيغة الـ state-space.	ETS
D6	Local level + كسر هيكلي	ماشية عادي وفجأة تقفز قفزة (زي زيادة سعر).	ولا واحد
D7	Logistic growth	نمو بيتشبع (S-curve) — بيطلع بسرعة وبعدين يقف.	ولا واحد
D8	Intermittent demand	طلب متقطع : 70% أصفار، وبين الحين والتاني طلبية.	ولا واحد
D9	AR(1) + GARCH(1,1)	المتوسط صح، بس التذبذب نفسه بيتغير (فترات هدوء وفترات جنون).	ARIMA في المتوسط بس

ليه اخترنا D6 بالكسر جوه الـ context مش في المستقبل؟ دي نقطة تصميم مهمة جداً. لو حطينا الكسر في الفترة اللي بنتنبأ بيها، مفيش طريقة في الدنيا تقدر تتنبأ بيه — فالتجربة كانت هتقيس بس "مين أكثر واحد محافظ ومش بيتحرك". لكن لما نحطه جوه البيانات اللي الموديل شافها (عند $0.7 \times n$)، السؤال يبقي عادل ومحترم: "إنت شفت المستوى اتغير — هتتنبأ من المستوى الجديد ولا هترجع للقديم؟"


ليه D7 نقطة الانقلاب عند 0.6 من السلسلة؟ عشان الفترة اللي بنتنبأ بيها تقع في الجزء اللي بيتشبع. أي طريقة بتركب خط مستقيم (drift) هت تعدي فوق (overshoot). وده بالضبط اللي عايزين نكشفه.

4.2 Lengths, Replications, Horizon — الأطوال والتكرارات والأفق

- **أطوال السلاسل:** $n \in \{24, 48, 96, 200\}$. الـ 24 دي قاسية بشكل مقصود: مع موسمية 12، يبقى عندك دورتين موسميتين بس. وهنشوف بعدين إن ده بيفرق حاجة كانت الناس بتخلط بينها.
- **التكرارات:** 200 تكرار لكل خلية (DGP × طول).
- **إجمالي السلاسل:** $200 \times 4 \times 9 = 7,200$ سلسلة.
- **الأفق (horizon):** $H = 12$. بنولد $n + 12$ نقطة، أول n بندّيها للموديل، وآخر 12 بنخبّيها ونقارن بيها.
- **الـ Seeding:** كل سلسلة ليها seed محسوبة من هويّتها: رقم الطول + رقم التكرار × $1,000$ + DGP رقم الـ $seed = 1,000,000 \times$. يعني السلسلة بتتعداد بالضبط من غير ما يفرق عدد الأنوية اللي شغالة ولا ترتيب التنفيذ.

من الآخر: 9 عمليات × 4 أطوال × 200 تكرار = 7,200 سلسلة، كل واحدة ليها seed ثابتة، فأني حد يقدر يعيد نفس الأرقام بالضبط...

Figure 1: One realisation of each data-generating process ($n = 96$; held-out horizon in colour)



شكل 1 — عينة واحدة من كل عملية من التسعة (عند $n = 96$). الجزء الرمادي هو البيانات التي الموديل يبشورها، والجزء الملون في الآخر هو الـ 12 نقطة المخيبة التي بنقيس عليها. بّص على **D6**: الكسر الهيكلي واضح عند النقطة 67 تقريباً — يعني 0.7×96 بالظبط زي ما صمّمناه. وبّص على **D8**: معظمها أصفار، وده اللي هيبوّظ الـ **MAPE** بعدين.

5. The Methods Compared — الطرق التي اتقارنت

مفيش أي طريقة اتظبطت بالإيد. كل طريقة كلاسيكية شغالة بالاختيار الأتوماتيكي بتاعها — لأن ده الوضع اللي المحلل الحقيقي بيقابله.

الطريقة	الشرح بالمصري
TimesFM3	الموديل بتاع Google، zero-shot، من غير تدريب ولا تطبيق.
SeasonalNaive	أغبي طريقة ممكنة: "النهارده هيبقى زي نفس اليوم السنة اللي فاتت".
Theta	الطريقة اللي كسبت مسابقة M3 — بتفكك السلسلة وتعيد تركيبها.
AutoETS	Exponential smoothing بيختار الشكل أوتوماتيك (Hyndman-Khandakar).
AutoARIMA	ARIMA بيدور على ال orders أوتوماتيك.
Combination	متوسط ال 3 دول: AutoARIMA. + AutoETS + Theta

ليه ال Combination إجباري مش اختياري؟

عشان أشهر انتقاد بيتقال على أوراق ال foundation models هو إنهم يقارنوا نفسهم بطرق كلاسيكية **مفكوة**. ال state of the art الكلاسيكي هو **الدمج** مش الطريقة الواحدة. لو شلناه، يبقى إحنا بنينا النتيجة اللي عايزينها **جوه التصميم** نفسه — وده غش منهجي.

⚠ ملاحظة أمانة: عدم تماثل في المعلومات

فيه حاجة قلناها في الورقة بصراحة لأنها في **صالح الكلاسيكي**: كل الطرق الكلاسيكية بندّيها **الفترة الموسمية الحقيقية** (m = 12) كمعلومة جاهزة، بينما **TimesFM-3** بياخد السلسلة الخام من غير ما نقوله إن فيها موسمية أصلاً ولا طولها كام. يعني الكلاسيكي واخد مساعدة.

من الآخر: 6 طرق، الكلاسيكي واخد مساعدة (الموسمية جاهزة)، وال Combination موجود عشان المقارنة تبقى شريفة.

6. The Metrics — المقاييس، وإزاي بنقيس "الغلط"

6.1 Point Metrics — مقاييس النقطة الواحدة

MASE (المقياس الأساسي): الخطأ المطلق مقسوم على خطأ ال seasonal naive داخل العينة.

$$\text{MASE} = \frac{\frac{1}{h} \sum_{i=1}^h |y_i - \hat{y}_i|}{\frac{1}{n-m} \sum_{t=m+1}^n |y_t - y_{t-m}|}$$

تفكيك المعادلة رمز رمز:

- y_i — القيمة الحقيقية في الخطوة رقم i من الفترة اللي بنتنبأ بيها.
- $\hat{y}_i$ — القيمة المتوقعة من الموديل لنفس الخطوة. (القبعة فوق الحرف معناها "تقدير").
- h — طول الأفق، يعني كام خطوة بنتنبأ بيها. عندنا $h = 12$.
- n — طول السلسلة المعروفة اللي الموديل شافها.
- m — الفترة الموسمية. عندنا $m = 12$ للسلاسل الموسمية، و $m = 1$ لغيرها.

والكسر نفسه:

- **البسط** — متوسط الخطأ المطلق **بتناك** في الفترة المتنبأ بها. يعني: بتغلط بكام في المتوسط؟
- **المقام** — متوسط خطأ "أغبي طريقة" (ال: seasonal naive: ال) النهارده زي نفس اليوم في الدورة اللي فاتت"، محسوب على البيانات **الي إنت شايفها** مش على المستقبل.

وإزاي تقرا الرقم الناتج؟

- $MASE = 1$ — إنت **بالظبط زي** الطريقة الغبية.
 - $MASE < 1$ — إنت **أحسن** منها. يعني **0.68** معناها خطأك 68% من خطأها.
 - $MASE > 1$ — إنت **أوحش** من الطريقة الغبية! وده بيحصل فعلاً — شوف **AutoETS** في القسم 8.3.
- ليه القسمة دي مهمة؟** عشان تقدر تجمع نتايج من سلاسل مقاييسها مختلفة تماماً — سلسلة أرقامها بالملايين وسلسلة أرقامها بالعشرات — من غير ما الكبيرة تبلع الصغيرة.
- RMSSE** : نفس الفكرة بالظبط بس بالتربيع بدل المطلق (زي ما في مسابقة **sMAPE**). (**M5** : نسبة مئوية متماثلة، مدى من 0 لـ 200.

6.2 Why MAPE Is Not the Headline — ليه ال MAPE مش المقياس الأساسي

ال **MAPE** هو أشهر مقياس عند الناس، ومع ذلك حظينه في **الملحق** بس. ليه؟

1. **غير معرّف عند الصفر** — القسمة على صفر. وفي **D8** (الطلب المتقطع) 70% من القيم أصفار!
 2. **غير متماثل** — بيعاقب المبالغة في التقدير أكثر من التقليل. فهو **بيحابي** الطرق المتحفظة.
 3. **بيقلب الترتيب** — وده مش كلام نظري، ده حصل في بياناتنا فعلاً.
- الرقم اللي بيثبت الكلام ده:** ال MAPE طلع **غير معرّف في 12,906 من 129,600** تقييم — يعني **9.96%** — وكلهم **بالظبط** في **D8**.

يعني لو كنا اعتمادنا على ال MAPE، كنا هنضطر **نшил النظام اللي فيه أقوى نتيجة عندنا** من المقارنة خالص، أو نخترع اتفاقية للأصفار من دماغنا.

من الآخر: ال MAPE مقياس مشهور لكنه بيكدب لما فيه أصفار — و **D8** كلها أصفار، فمينفعش يكون الأساس.

6.3 Probabilistic Metrics — مقاييس التوزيع مش النقطة

الموديلات دي مش بتديك رقم واحد، بتديك **توزيع**. فلازم نقيس التوزيع نفسه:

- **Pinball loss** (خسارة ال quantile): بنحسبها على ال 9 deciles كلها، ومقسومة على نفس مقام ال MASE عشان تبقى قابلة للمقارنة. دي **proper scoring rule** يعني مقياس شريف رياضياً.
- **Coverage** : الفترة اللي قلت عليها 80% — هل الحقيقة وقعت جواها 80% من المرات فعلاً؟
- **Width** : عرض الفترة. ودي مهمة أوي — هنشوف ليه كمان شوية.

⚠ **ليه 60% و 80% ومفيش 90%؟**

دي نقطة تصميم مقصودة: **TimesFM-3** بيطلع ال **deciles** بس (من **q0.1** لـ **q0.9**). فمفيش عندك **q0.05** ولا **q0.95** عشان تعمل فترة 90%. لو قارنا فترة 90% كلاسيكية بفترة معمولة بالاستقراء (extrapolation) من الموديل، تبقى

مقارنة **مش عادلة**. فأخذنا أوسع فترة **الاثنين** يقدروا يعبروا عنها: [q0.1, q0.9].

من الآخر: بنقيس النقطة (MASE) والتوزيع (pinball) والفترة (width + coverage) — الثلاثة، مش واحد.

7. The Statistical Tests — الاختبارات الإحصائية

مش كفاية نقول "المتوسط ده أقل من ده". لازم **نختبر**.

7.1 Paired Wilcoxon — الاختبار الأساسي

جوه كل خلية (DGP × طول × أفق)، بنقارن TimesFM-3 بكل طريقة كلاسيكية باختبار Wilcoxon signed-rank **المزدوج** على فروق الـ MASE بين الـ 200 تكرار.

ليه Wilcoxon مش t-test؟ لأنه **مش يفترض التوزيع الطبيعي**، وتوزيعات الخطأ في التنبؤ تبقى ملتوية (skewed) بشكل بشع. بس برضه بنحسب الـ **t-test** ك **sensitivity check**.

7.2 Why NOT Diebold–Mariano — ليه رفضنا اختبار Diebold–Mariano

دي نقطة منهجية مهمة، والأدب المنشور يستخدم **DM** بشكل شبه تلقائي.

الـ **DM** **متصمم** لسلسلة فروق خسارة **مترابطة زمنياً** (autocorrelated) جاية من **سلسلة واحدة** عبر الزمن. عندنا في المحاكاة، الـ 200 تكرار دول **سحوبات مستقلة** من نفس العملية — مفيش ترتيب زمني بينهم أصلاً! فلو استخدمنا DM هنبقى بنوصف بنية اعتماد **مش موجودة**.

وفي بيانات **M4** الحقيقية، التصميم بتاعنا فيه **3 origins** بس لكل سلسلة، يعني الإحصاء هتبقى بـ **درجتين حرية** — يعني مفيش قوة إحصائية خالص.

⚠️ **وحصل غلط حقيقي هنا اكتشفناه بالمراجعة:** في نسخة أولى، الكود حسب DM على **مقطع عرضي** (cross-section) من 1000 متوسط مرتين أبدياً بحسب اسم السلسلة! يعني التصحيح كان بيجمع autocovariances عبر سلاسل **مالهاش علاقة ببعض** وبترتيب عشوائي تماماً. الدليل القاطع: الإحصاء طلعت -13.97 بالترتيب ده، وبين -18 و -23 لما نخلط الترتيب عشوائياً. حاجة بتتغير 30-70% لما تخلط فهرس عشوائي دي **مش اختبار**. فقررنا **نمسحها خالص** مش نصلحها، لأن مفيش نسخة منها التصميم ده بيسمح بيها.

7.3 Multiplicity — التصحيح للمقارنات المتعددة

إحنا بنعمل 180 مقارنة. لو كل واحدة عند 5%، يبقى متوقع نلاقي 9 نتائج "معنوية" **بالصدفة البحتة**. فبنستخدم **Benjamini–Hochberg** للتحكم في الـ False Discovery Rate عند 0.05، ونببّغ الـ p الخام والمصحح.

7.4 Effect Sizes — أحجام الأثر

مع كل اختبار بنبّغ: - **Hodges–Lehmann**: تقدير للفرق الوسيط. - **نسبة الـ MASE الوسيطة**: عشان تشوف الفرق عملياً يعني إيه.

ليه؟ عشان فرق ممكن يبقى **معنوي إحصائياً** وهو **تافه عملياً**. مع 200 تكرار، فرق 0.2% ممكن يطلع معنوي. لازم القارئ يشوف ده.

من الآخر: بنختبر كل فرق، بنصح للمقارنات المتعددة، وبنقول حجم الفرق مش بس هل هو معنوي.

8. The Results — النتائج

التصميم طلع 7,200 سلسلة، ومع 6 طرق و 3 شرائح أفق = 129,600 تقييم.

8.1 A Split Decision, Not a Rout — قرار منقسم مش كاسح

لو عدّينا مين كسب في كل خلية من الـ 36 خلية (DGP × طول):

الطريقة	عدد الخلايا اللي كسبتها
TimesFM3	16
AutoARIMA	10
SeasonalNaive	4
Theta	2
Combination	2
AutoETS	2

يعني الكلاسيكي كسب 20 والموديل كسب 16. القراءة السطحية: "الكلاسيكي كسب".

بس دي قراءة ناقصة، وهنا بيت القصيد: الـ 20 دول متوزعين على 5 طرق مختلفة! يعني عمود الكلاسيكي هو عمود فايزين مختلفين، وإنت معندكش طريقة تعرف مقدماً مين منهم هيكسب على سلسلتك من غير ما تعمل الشغل اللي الـ foundation model المفروض يوفره عليك.

ولما نختبر ضد أحسن طريقة كلاسيكية في كل خلية: 18 من 36 فرق نجوا من تصحيح BH — 7 لصالح TimesFM-3 و 11 لصالح الكلاسيكي، و18 خلية تعادل.

8.2 Who Actually Holds Their Ground — مين بيصمد قدامه فعلاً؟

خلينا نبص على الـ 180 مقارنة الثنائية. منها 132 معنوية: 113 لصالح TimesFM-3 و 19 لصالح الكلاسيكي. التفصيل حسب الخصم:


الخصم	مقارنات معنوية	كسب TimesFM-3	كسب الخصم
AutoARIMA	20	11	9
SeasonalNaive	26	22	4
AutoETS	27	25	2
Theta	29	28	1
Combination	30	27	3

الجدول ده هو رسالة الورقة المركزية. بَص على السطر الأول: **AutoARIMA** هو الوحيد اللي بيصمد (11 مقابل 9، يعني عملة معدنية). كل اللي غيره — حتى دمج الثلاثة مع بعض — بيتغلب في الغالبية العظمى.

يعني إيه عملياً؟

- محلل بيختار **AutoARIMA** صح كل مرة → مش هيخسر حاجة لو فضل كلاسيكي.
 - محلل مش بيعرف يختار، أو معندوش وقت يظبط كل سلسلة → أحسن له بكتير يستخدم الـ foundation model.
- من الآخر: الموديل مش بيكسب على أحسن طريقة، لكنه بيكسب على متوسط الطرق — وقيمتة إنك مش محتاج تعرف أنهي طريقة تختار.

Figure 2: Accuracy of TimesFM-3 relative to the best classical method



شكل 2 — دقة **TimesFM-3** بالنسبة لأحسن طريقة كلاسيكية في كل خلية. العمود اللي تحت الصفر معناه **TimesFM-3** أدق، واللي فوق الصفر معناه الكلاسيكي أدق. شوف **D8** (الطلب المتقطع) نازل تحت بوضوح في الأطوال الأربعة، و **D4** (الموسمية) طالع فوق في الأربعة — دول النظامين الحاسمين اللي هنتكلم عنهم في 8.5. والباقي قريب من الصفر، يعني تعادل.

8.3 ★ Specification Is Not Estimability — التخصيص الصحيح مش زي القابلية للتقدير

دي أهم نتيجة في الورقة كلها، والحاجة اللي تستاهل تفتكرها لو نسيت كل حاجة تانية.

الفرضية التي سجلناها مسبقاً (H1) كانت: "الموديلات الكلاسيكية هتكسب على أرضها، والفرق هيبقى أكبر في السلاسل القصيرة". **الفرضية دي اتفندت** — والسبب هو الدرس.

الدليل الأول: في D1 (AR(1)) و TimesFM-3 ، D2 (ARMA(1,1)) طلع مش أقل من AutoARIMA المخصص صح، في كل الأطوال ما عدا n=200 في D2 . وولا فرق منهم معنوي غير ده. يعني كون AutoARIMA "صح بالتعريف" **مجايلوش حاجة** تتقاس على السلاسل القصيرة والمتوسطة — لأن ال parameters لسه لازم **تتقدّر** من البيانات اللي قدامك، بينما TimesFM-3 جاي ومعاها معرفة مسبقة من تريليون نقطة.

الدليل القاطع (الرقم اللي لازم تفكره): عند n = 24 مع موسمية 12 — يعني دورتين موسميتين بس:

الطريقة	MASE على D5 عند 24=n
AutoETS	3.025 — المفروض إنه "صح بالتعريف"!
SeasonalNaive	1.139 — أغبي قاعدة في الدنيا
TimesFM3	1.152

يعني إيه؟ **AutoETS** خسر بفارق 2.7 مرة قدام قاعدة من سطر واحد — على بيانات عملية ETS هي اللي ولدتها بنفسها!

ونفس الحكاية في D4 : عند Theta ، n=200 سجل 4.155 بينما AutoARIMA سجل 0.886.

فالخلاصة المنهجية: الصفة الحاسمة مش هل الموديل الكلاسيكي **مخصص صح** (correctly specified)، لأ — هي هل هو **قابل للتقدير** (estimable) من البيانات اللي قدامك فعلاً.

تشبيه: عندك وصفة أكل مضبوطة 100% من شيف عالمي. بس مطبخك فيه **مكوّنين بس**. الوصفة المضبوطة دي مش هتنفعك — والراجل اللي ييطبخ بالفطرة من غير وصفة هيطلع أكل أحسن منك. الوصفة صح، بس إنت **مش قادر تنفذها**.

فين الموديل بيبقى مفيد أكثر؟ بالضبط في المكان اللي التقدير الكلاسيكي فيه **جعان** بيانات. وفين بيبقى أقل فائدة؟ لما بيبقى التقدير مرتاح.

من الآخر: مش السؤال "الموديل بتاعي صح؟" — السؤال "عندي بيانات تكفي أقدره؟"

Robustness, Not Peak Accuracy 8.4 — الموديل بيشتري الثبات مش الدقة القصوى

إزاي نقيس الثبات ده بشكل عادل؟

⚠ **محاولة غلط عملناها وصلحناها:** في البداية كتبت إن TimesFM-3 "بيتهور بلطف" بناءً على أسوأ MASE مطلق.

الرقم ده **مايدعمش الادعاء** — لأن D3 صعبة على الكل، فأسوأ الحالات المطلقة بتبقى محكومة بالعملية دي مش بهشاشة أي طريقة. الدليل: Theta أسوأ حالة مطلقة عنده (4.483) **أحسن** من بتاع TimesFM-3 (4.656) ! ولو صدّقنا ده بيبقى Theta أثبت طريقة، وده كلام فارغ.

المقياس الصح: نسبة كل طريقة لـ **أحسن طريقة في نفس الخلية**. ده بيعزل الهشاشة لوحدها:

الطريقة	النسبة الوسيطة	المتوسط	أسوأ نسبة	أسوأ خلية
TimesFM3	1.008	1.054	1.31	D4, n=200
AutoARIMA	1.032	1.137	2.22	D4, n=24
Combination	1.108	1.273	3.00	D4, n=24
AutoETS	1.194	1.366	3.50	D4, n=24
SeasonalNaive	1.200	1.470	5.65	D7, n=48
Theta	1.251	1.614	4.69	D4, n=200

اقرأ الجدول ده كويس:

- TimesFM-3 عمره ما بقى أسوأ من 1.31 مرة من أحسن طريقة في أي خلية في التصميم كله.
- وفي الخلية الوسيطة هو في حدود 0.8% من الأحسن.
- بينما كل طريقة كلاسيكية بتبقى في مكان ما 2.2 مرة أسوأ على الأقل، وبعضها 4.7 و 5.6 مرة.

تشبيه: لاعب بيجيب 8/10 في كل ماتش، مقابل لاعب بيجيب 10/10 مرة و 3/10 مرة. اللي عايز يكسب البطولة كلها بياخد الأول.

من الآخر: TimesFM-3 نادراً ما ييبقى الأحسن، وأبدأ مش ييبقى كارثة. الكلاسيكي الأوتوماتيكي أحياناً ممتاز وأحياناً ييقع.

Two Decisive Regimes 8.5 — النظامين اللي فيهم قرار واضح

أ) موسمية قوية + بيانات تكفي ← استخدم **AutoARIMA** عند $n = 48, 96, 200$ في **AutoARIMA**، **D4** أحسن بـ 21.8% و 21.1% و 23.7% على الترتيب، وكلها بـ p مصحح > 0.0001 .

⚠ **وغلط في الحساب صلحناه:** كنت كاتب "27-31% أحسن" — ده غلط. النسبة 1.28 معناها إن **TimesFM-3** أسوأ بـ 27-31%، لكن **AutoARIMA** أحسن بـ 21-24%. الاثنين مش نفس الرقم (لأن $1 - 1/1.28 = 0.22$ مش 0.28). دي المراجعة اللي مسكتها.

والتوصية بتنقلب عند $n = 24$! بدورتين موسميتين بس: - أحسن طريقة كلاسيكية مش **AutoARIMA** أصلاً — دي (1.029) **SeasonalNaive** - و **TimesFM-3** بيكسب على **AutoARIMA** بـ 42% (1.321 مقابل 2.284)

يعني نصيحة "استخدم ARIMA للموسمية" صح بس بعد ما يبقى الموديل الموسمي قابل للتقدير. تحت الحد ده هي نصيحة وحشة.

ب) الطلب المتقطع (**D8**) ← الحكاية أعقد، والمقاييس بتتخاقل على **TimesFM-3**، **MASE** يقلل الخطأ بـ 21.7% و 26.5% و 26.0% و 26.2% على الأطوال الأربعة، وكلها $p > 0.0001$. وعلى الـ **pinball loss** كمان هو الأحسن في كل طول.

بس على **RMSSE** هو بيخسر في كل طول. وعلى **sMAPE** هو أوحش واحد في الستة بفارق كبير.


ليه؟ فيه ميكانيزم حقيقي مش صدفة:

70% من قيم **D8** أصفار. والقاعدة الرياضية بتقول: - مقاييس **الخطأ المطلق** (زي **MASE**) بتتصغر عند الـ **median** بتاع التوزيع — وده هنا صفر أو قريب منه. - مقاييس **الخطأ التربيعي** (زي **RMSSE**) بتتصغر عند الـ **mean** — وده أكبر من صفر بالتأكيد.

فالطريقة اللي بتتنبأ قريب من الـ **median** بتكسب **MASE** وتخسر **RMSSE**، والعكس صحيح. ودي بالضبط المصيدة اللي **Kolassa (2016)** وثّقها للطلب المتقطع في التجزئة.

من الآخر: في الطلب المتقطع، **مفيش رقم واحد بيحسم الموضوع** — اللي يحسمه هو دالة الخسارة اللي قرارك التجاري بيواجهها فعلاً.

Figure 4: Accuracy by horizon, split by whether a classical model is correct



شكل 4 — الدقة حسب طول الأفق، مقسومة على النظامين. الشمال: العمليات اللي فيها موديل كلاسيكي صح (D1 - D5). اليمين: اللي مفيهاش (D6 - D9). كل الطرق بتسوء كل ما الأفق يطول — وده طبيعي.

⚠ **بس خد بالك من قراءة غلط هنا:** **TimesFM-3** مبين الأقل في **اللوحتين**، وده مش بيناقض إن الكلاسيكي كسب خلايا أكثر — لأن **المتوسط** بيخلط الخلايا اللي الكلاسيكي كسبها بالخلايا اللي وقع فيها، وخلية واحدة كارثية (زي **Theta** بـ 4.16 على **D4**) بتحرك المتوسط أكثر بكتير من كذا مكسب صغير.

8.6 Adding the Right Tool: Croston ★ — ضفنا الأدوات المتخصصة فعلاً

المراجعة قالت لنا حاجة وجيهة: "مجموعة المقارنة بتاعتكم مفيهاش ولا طريقة متصممة للطلب المتقطع!" وده اعتراض عادل — **Croston** وعيلته موجودين بالضبط للحالة دي.

فضفناهم: **CrostonClassic**, **CrostonOptimized**, **CrostonSBA**, **ADIDA**, **IMAPA**, **TSB** — بنفس الـ seeds ونفس الـ 200 تكرار.

النتيجة (وهي قوية في الاتجاهين):

على **TimesFM-3**: **MASE** كسب على الستة كلهم في الأطوال الأربعة — 24 من 24 مقارنة معنوية، بنسب وسيطة بين 0.70 و 0.82. أحسن منافس متخصص كان **TSB** عند $n=96$ بـ 0.916، مقابل 0.683 لـ **TimesFM-3**.

على **ADIDA** : **RMSSE** و **CrostonSBA** سجلوا الأقل في كل طول (0.694-0.769) مقابل 0.774-0.806 لـ **TimesFM-3**.

والنتيجة دي بتأكد الميكانيزم بشكل أنصف من الأول: طرق **Croston** متصممة أصلاً لتقدير معدل الطلب المتوسط (mean demand rate) — وده بالطبط اللي الخطأ التريبي بيكافئه! فالطرفين متحسنين لدوال مختلفة، وكل واحد بيكسب تحت المقياس اللي بيوافق هدفه. مفيش حد منهم غلط.

فالاعتراض اتقف: الموديل مش بس بيكسب على الطرق العامة — هو بيكسب على **الأدوات المتخصصة** كمان، وبفارق أوسع. لكن على المقياس التريبي بيخسر لهم.

من الآخر: لو تكلفتك في المخزن **خطية** بالقطعة ← **TimesFM-3** . لو **تريبيعية** ← **Croston** . وقول ده بصراحة أحسن من إنك تختار المقياس اللي يعجبك.

8.7 Interval Reliability — هل الفترات بتاعتهم صادقة؟

لما موديل يقولك "أنا واثق 80%"، هل فعلاً الحقيقة بتقع جوه فترته 80% من المرات؟

النظرة المتوسطة (على العمليات التسعة): تغطية **TimesFM-3** للفترة 80% بتفضل بين **0.802** و **0.834** عبر كل الأطوال — أقرب للمطلوب من أي طريقة تانية. بينما **SeasonalNaive** بتنجرف من 0.777 عند $n=24$ لـ 0.869 عند $n=96$.

⚠ **بس النظرة دي مجاملة للكل، وقلنا الرقم الأمين جنبها:** لما تاخذ متوسط التغطية عبر العمليات، الزيادة في عملية بتلغي النقص في عملية تانية. المقياس الصح هو **متوسط الانحرافات المطلقة لكل خلية**، وهو حوالي 3 أضعاف:

الطريقة	انحراف "المتوسط أولاً" (مجامل)	الانحراف الأمين لكل خلية
TimesFM3	0.015	0.047
AutoARIMA	0.021	0.066
Combination	0.032	0.089
AutoETS	0.021	0.101
Theta	0.040	0.127
SeasonalNaive	0.038	0.144

الترتيب متغيرش و **TimesFM-3** فضل الأحسن معايرةً — **بس المستوى مش قريب من المطلوب:** تغطيته لكل خلية بتتراوح من **0.583** لـ **0.921**! يعني **مفيش ولا طريقة** في الدراسة دي بتدي فترات 80% موثوقة عبر العمليات التسعة.

الحالة اللي بتوضح كل حاجة: الكسر الهيكلي (D6)

التغطية (المطلوب 0.80)	عرض الفترة (مقيس)	
0.966 – 0.999	4.81 – 10.36	كل الطرق الكلاسيكية
0.828 – 0.889	3.00 – 5.07	TimesFM3


بصّ للكلاسيكي: تغطية 99.9%؟! ده مش "موثوقة" — ده **عَرَض مرضي**. الكسر الهيكلي بيضخّم تقدير التباين، فالفترات بتبقى **ضخمة**. هي بتحتوي الحقيقة دايماً لأنها بتحتوي **كل حاجة**.

TimesFM-3 بيغطي 82.8-88.9% (فوق المطلوب برضه) بفترات **نص العرض تقريباً**.

تشبيه: لو قتللك "بكرة الجو هيبقى بين 50- و 80+ درجة" — كلامي صح 100%، وبلا فائدة 100%.

من الآخر: التغطية لوحدها بتكذب. لازم تبص على **العرض** معاها.

Figure 3: Interval reliability, averaged over all nine processes



شكل 3 — التغطية الفعلية للفترات مقابل المطلوب (الخط المتقطع)، بمتوسط على العمليات التسعة. لاحظ إن TimesFM-3 ماشي على الخط المطلوب تقريباً في كل الأطوال، بينما الكلاسيكي **بيقصّر** عند $n = 24$ و**بيزود** من $n = 96$. بس افكر التحذير فوق: ده **المتوسط**، والانحراف الحقيقي لكل خلية أكبر 3 مرات.

8.8 Was the Combination a Straw Man? — هل ال Combination كان خصم ضعيف؟

TimesFM-3 كسب على ال Combination في 27 من 30 مقارنة معنوية. وده بيفتح اعتراض وجيه: ال Combination بتاعكم فيه **Theta** اللي بيقع بشكل كارثي في خلايا معينة، و**المتوسط مش محصّن** ضد عضو واحد بايظ.

فأعدنا المقارنة ضد **combination بالوسيط (median)** بدل المتوسط، وده محصّن ضد عضو فاشل.

النتيجة: الاعتراض مش صامد. ال median combination طلع **أسوأ شوية** من ال (MASE mean = 1.712 مقابل 1.656، و TimesFM-3 = 1.439)، و TimesFM-3 لسه كاسب 25 من 29 مقارنة معنوية.

يعني تفوّق الموديل على الدمج **مش ناتج** عن طريقة تكوين الدمج. (والتحليل ده **بعدي/post-hoc** وقلنا كده صراحةً).

8.9 Effect Sizes and a Sensitivity Check — أحجام الأثر وفحص الحساسية

تقديرات Hodges–Lehmann (الفرق الوسيط في MASE، السالب لصالح TimesFM-3):

الخصم	الفرق الوسيط
AutoARIMA	-0.010
Combination	-0.091
SeasonalNaive	-0.133
AutoETS	-0.183
Theta	-0.227

اقرأ الرقم الأول كويس: قدام **AutoARIMA** الفرق النموذجي هو واحد من مية من وحدة MASE. ده فرق بيتقاس أحياناً، بس مش فرق محلل هيلاحظه في شغله.

فحص الحساسية: ال t-test اتفق مع Wilcoxon في 163 من 180 مقارنة (90.6%). وال 17 اللي اختلفوا فيهم مش عشوائيين — فيهم نمط مهم:

في **D8** قدام **SeasonalNaive**، ال **t-test** يقول **TimesFM-3** أحسن بشكل معنوي في كل طول ($p > 0.0001$)، بينما **Wilcoxon** يقول **مفیش فرق معنوي** (p من 0.11 لـ 0.92)!

ليه؟ لأن الاثنين بيحاولوا على سؤالين مختلفين: - **المتوسط** كبير لأن **أقلية** من السلاسل بتنتج أخطاء ضخمة جداً لـ **SeasonalNaive** - **الوسيط** قريب من صفر لأن على معظم السلاسل الفردية الاثنين متقاربين.

وده سبب **تالت مستقل** يخلينا نعامل نتيجة **D8** كنتيجة **مشروطة** مش حاسمة.

9. The Real-Data Tier: M4 Monthly — البيانات الحقيقية

المحاكاة بتشتري النقاء بثمان الواقعية. القسم ده بيرجع جزء من الثمن ده.

9.1 What Is M4 Anyway? — إيه هي بيانات M4 أصلاً؟

ال **M4** هي **مسابقة تنبؤ عالمية** نظمها Spyros Makridakis سنة 2018. حظوا 100,000 **سلسلة زمنية حقيقية** من الاقتصاد والمالية والصناعة والديموغرافيا، وخلّوا الناس كلها تتنافس عليها. دي مش بيانات لعبة — دي المرجع المعياري اللي أي ورقة تنبؤ جادة بتتقاس عليه.

السلاسل مقسومة بالتردد: سنوية، ربع سنوية، **شهرية**، أسبوعية، يومية، بالساعة. إحنا أخذنا **الشهرية** — وهي أكبر مجموعة فيهم: **48,000 سلسلة**.

ليه الشهرية بالذات؟ لأنها أقرب حاجة للواقع اللي المحلل بيشتغل عليه (مبيعات شهرية، طلبات شهرية، مؤشرات اقتصادية شهرية)، وفيها **موسمية** حقيقية بفترة 12 — وده بيخليها الاختبار الطبيعي للتناج اللي طلعت من **D4** و **D5** في المحاكاة.

9.2 How We Picked the Series — إزاي اخترنا السلاسل بالظبط

مخدناش ال 48,000 كلهم — لأن ده هياخد أيام حساب من غير فائدة إضافية. المواصفات بالتفصيل:

الخطوة	القيمة	ليه
المجموعة الأصلية	48,000 سلسلة شهرية	كل الشهرية في M4
شرط الطول	السلسلة لازم تكون ≤ 138 شهر	عشان تكفي ل context محترم + 18 شهر مخبيين
المؤهلة بعد الشرط	32,581 سلسلة	اللي عدت الشرط
العينة	1,000 سلسلة عشوائي	ب seed ثابتة 20260908

ليه seed ثابتة؟ عشان أي حد يشغل الكود يجيب نفس الألف سلسلة بالظبط — مش عينة ثانية. لو مكانش فيه seed، كل واحد هيجيب نتيجة مختلفة شوية والمقارنة تبقى مالهش معنى.

طول السلاسل اللي طلعت: الأقصر 138 شهر، الوسيط 299 شهر (يعني حوالي 25 سنة!)، والأطول 1,808 شهر. يعني دي سلاسل طويلة ومحترمة مش أمثلة صغيرة.

9.3 ★ "Window" and a "Origin" What Is an — يعني إيه "origin" و "window"؟

دي أهم نقطة محتاجة توضيح، وهي بسيطة جداً لما تتشرح صح.

ال Origin (نقطة الأصل) = اللحظة اللي بتقف فيها عن المشاهدة وتبدأ تتنبأ.

تخيل إنك واقف في شهر معين. كل اللي قبله إنت شايفه (ده ال context)، وكل اللي بعده مخبي عنك (ده ال truth اللي هتتقاس عليه). النقطة اللي إنت واقف عندها دي اسمها ال origin.

ال Window (النافذة) = زوج واحد: (البيانات اللي شفتها، الحقيقة المخبية).

مثال حقيقي بالأرقام من بياناتنا

خد سلسلة حقيقية من العينة، اسمها M10046 ، طولها 346 شهر. إحنا بنأخذ منها 3 نوافذ:

النافذة	الموديل بيشف	بيتنبأ بـ	العدد
origin 1	شهور 1 → 328	شهور 329 → 346	18 شهر
origin 2	شهور 1 → 316	شهور 317 → 334	18 شهر
origin 3	شهور 1 → 304	شهور 305 → 322	18 شهر

شوف النمط: كل مرة بنرجع 12 شهر لورا (سنة كاملة)، وبنطلب منه يتنبأ بـ 18 شهر من النقطة دي.

ليه بنرجع 12 شهر مش شهر واحد؟ عشان لو رجعنا شهر واحد، النوافذ هتبقى متداخلة جداً وكإننا بنقيس نفس الحاجة 3 مرات. الرجوع سنة كاملة بيدي مواقف مختلفة فعلاً في السلسلة.

ليه 3 نوافذ مش واحدة؟ عشان لو قيّمنا على نقطة واحدة بس، ممكن نكون وقعنا على شهر استثنائي (أزمة، عيد، حاجة غريبة) والنتيجة كلها تبقى حظ. ثلاث نقاط بتقلّل الحظ ده.

وليه 18 شهر بالذات؟ لأن ده الأفق الرسمي اللي مسابقة M4 نفسها حدّته للسلاسل الشهرية. يعني نتايجنا تبقى قابلة للمقارنة مع أي نتيجة منشورة على M4.

وليه 2,932 نافذة مش 3,000؟

سلسلة × 3 نوافذ = 3,000 1,000 — بس الرقم الحقيقي 2,932. ليه؟

لأن **مش كل سلسلة طولها يسمح بـ 3 نوافذ**. عشان تاخذ النافذة الثالثة لازم السلسلة تكون طويلة كفاية إن بعد ما ترجع 24 شهر لورا وتشيل 18 شهر، يفضل عندك 120 شهر على الأقل يشوفهم الموديل. التفصيل:

عدد النوافذ	عدد السلاسل
3 نوافذ	951 سلسلة
نافذتين	30 سلسلة
نافذة واحدة	19 سلسلة
الإجمالي	2,932 نافذة

يعني $2,932 = 951 \times 3 + 30 \times 2 + 19 \times 1$ بالظبط. والسلاسل القصيرة **مترمتش** — أخذت اللي طولها يسمح بيه وخلص، وده أشرف من إننا نرمي بيانات أو نزوّق الرقم.

9.4 ★★ Why Use Data the Model May Have Seen? — ليه نستخدم بيانات الموديل يمكن يكون شافها؟

ده أهم سؤال في القسم كله، وسؤال وجيه جداً. الإجابة من ثلاث حتت:

الحتة الأولى: إحنا مش بنبني الادعاء الأساسي عليها

الادعاء الرئيسي للورقة مبني على **المحاكاة** — لأن هناك التلوث **مستحيل بالبناء**. القسم ده بيجابو على سؤال ثاني خالص وأصيق:

السلاسل الحقيقية بتشبه أنهى نظام من الأنظمة التسعة اللي حاكيناها؟

وده سؤال مشروع تماماً حتى لو البيانات ملوثة، لأنه سؤال عن **شكل البيانات** مش عن **مين أدق**.

الحتة الثانية: المحاكاة لوحدها ممكن تكون منفصلة عن الواقع

لو الورقة اكتفت بالمحاكاة، أول اعتراض من أي محكم هيقى: "كلامكم حلو على بيانات صناعية — بس الدنيا الحقيقية مش كده". فلازم نوريه إن نتايجنا **بتتكرر** على بيانات حقيقية.

وده اللي حصل بالظبط: نفس النمط ظهر في الاثنين. والاتفاق ده قيمته أكبر من أي طبقة لوحدها، لأن **ضعف كل طبقة معاكس للتانية**:

المحاكاة	M4 الحقيقية
التلوث	مستحيل بالبناء
الواقعية	صناعية ومبسطة
	حقيقية 100%
	محتمل جداً

يعني لو حاجة طلعت صح في **الاثنين**، تبقى مش صدفة تصميم ولا صدفة تلوث.

الحتة الثالثة ★ — التعادل نفسه دليل

دي النقطة الذكية اللي تستاهل تفتكرها.

لو كان TimesFM-3 بيغش فعلاً (يعني حافظ سلاسل M4 من التدريب)، كنا هنتوقع إيه؟ كنا هنتوقع إنه يسحق الطرق الكلاسيكية سحق — لأنه حرفياً شايف الإجابة.

بس ده مش اللي حصل. هو تعادل مع $p = 0.27$ (52.6% AutoARIMA) وتعادل مع الـ (48.5% Combination $p = 0.27$). يعني حتى على البيانات اللي هو "متهم" إنه شافها، مكسبش عليهم.

فالتعادل ده في حد ذاته دليل ضد فرضية إن الموديل بيستفيد استفادة ضخمة من الحفظ. مش دليل قاطع — يمكن حافظ حنة صغيرة — بس هو أقوى حاجة تقدر تستنتجها من بيانات عامة.

من الآخر: إحنا بنستخدم M4 عارفين إنها ملوثة، وقايلين كده بصراحة في الورقة، ومش بانيين عليها الادعاء الرئيسي. بنستخدمها عشان نعرف شكل الواقع ونشوف هل المحاكاة بتوصف الدنيا الحقيقية ولا لأ. والنتيجة إن الاتنين بيقلوا نفس الكلام.

النتيجة

الطريقة	متوسط MASE	التغطية 80%	pinball
Combination	0.9027	0.8006	0.3653
TimesFM3	0.9114	0.7655	0.3627
AutoARIMA	0.9182	0.7851	0.3744
AutoETS	0.9465	0.7909	0.3840
Theta	0.9672	0.7344	0.3977
SeasonalNaive	1.2768	0.7867	0.5135

والاختبارات (Wilcoxon مزدوج عبر الـ 1,000 سلسلة، مصحح بـ BH):

المقارنة	% سلاسل TimesFM-3 أحسن فيها	p مصحح	الحكم
ضد SeasonalNaive	80.1%	< 0.0001	TimesFM-3 كسب
ضد Theta	56.8%	< 0.0001	TimesFM-3 كسب
ضد AutoETS	54.1%	0.0043	TimesFM-3 كسب
ضد AutoARIMA	52.6%	0.27	تعادل
ضد Combination	48.5%	0.27	تعادل

ملاحظات مهمتين

الأولى — الطبقتين يتفقا. النمط ده نفس نمط المحاكاة بالظبط: بيكسب على كل حاجة ما عدا **AutoARIMA** اللي بيتعادل معاه. وسلاسل **M4** الشهرية **طويلة وموسمية** — يعني بالظبط النظام "القابل للتقدير" اللي المحاكاة اتنبأت إن الكلاسيكي هيبقى منافس فيه. والاتفاق ده قيمته أكبر من أي طبقة لوحدها، لأن الاتنين **ضعفهم معاكس لبعض**: المحاكاة نضيفة بس صناعية، والحقيقية واقعية بس ملوثة.

الثانية — نتيجة الفترات مانتقلتش. على البيانات المولدة كان **TimesFM-3** الأحسن معاييرة؛ هنا هو **تاني أسوأ واحد**: تغطية **0.765** مقابل مطلوب 0.80، بينما الـ **Combination** وصل **0.801**. يعني على سلاسل حقيقية فيها بنية مش موجودة في عملياتنا التسعة، الـ quantiles المتعلمة بتاعته **بتقصر**. وده بيخفف من نتيجة المعاييرة اللي فوق، ومتسق مع اللي **وزمائله (2026) Adler** بلغوا عنه.

لكن لاحظ: على الـ **pinball loss** — وهو proper scoring rule ومسجل مسبقاً — **TimesFM-3** طلع **الأحسن** (0.3627). فالصورة مش "فترات وحشة" على طول، دي "التغطية وحشة والتوزيع ككل كويس".

من الآخر: على بيانات حقيقية طويلة وموسمية، الموديل والكلاسيكي **متعادلين** في الدقة، والكلاسيكي أحسن في صدق الفترات.

10. Costs That Don't Show in an Accuracy Table — تكاليف مش بتظهر في جدول الدقة

10.1 ★ Speed — والنتيجة بالعكس تماماً من المتوقع

الطبيعي إنك تفتكر إن موديل بـ 330 مليون parameter هو الغالي، والموديل الإحصائي بـ 3 parameters هو الرخيص. **العكس تماماً** على الجهاز ده:

الطريقة	زمن لكل سلسلة	النسبة لـ TimesFM-3
SeasonalNaive	3.1 ms	0.13×
Theta	9.0 ms	0.39×
TimesFM3 (GPU, batched)	23.2 ms	1×
AutoETS	102.0 ms	4.4×
AutoARIMA	2382.7 ms	102.8×

AutoARIMA أبطأ 103 مرة من **TimesFM-3** لكل سلسلة!

ليه؟ السبب بنيوي مش عرضي: الـ **AutoARIMA** بيعمل بحث **تدرجي** على الـ orders، وبيركب كل مرشح بـ maximum likelihood، لكل سلسلة لوحدها. بينما **TimesFM-3** بيعمل **مرور أمامي واحد مجمّع (batched)** وبيوزع تكلفته على الدفعة كلها.

⚠ بس التحفظ الثاني أهم من الرقم الرئيسي

غلط ثاني مسكته المراجعة وصلحته: كنت كاتب إن الكلاسيكي أخذ "9 دقائق مقابل 5 ثواني" — ده مش صحيح. الأرقام الحقيقية من ال log بتاع التشغيل:

- الطرق الكلاسيكية الأربعة على ال 7,200 سلسلة كلها بـ 22 نواة: **7.3 دقيقة**

- **TimesFM-3** على نفس الشغل بـ GPU واحد: **3.2 دقيقة**

- النسبة: **2.3×** — مش **103×**!

يعني: ال **103×** صح لكل سلسلة على نواة واحدة، لكن الكلاسيكي بيتوازي ببساطة، والتوازي بيسترد معظم الفرق. الرقمين يجاوبوا على سؤالين مختلفين، وإني أقول الأول بس يبقى مبالغة. (وكمان **TimesFM-3** محتاج GPU أصلاً).

من الآخر: الموديل الجبار مش الخيار الغالي — لا لكل سلسلة ولا في الإجمالي. بس الفرق الإجمالي **2.3×** مش **103×**.

10.2 ★★ Licensing — وده أهم بند عملي في الورقة كلها

TimesFM-3 صادرة تحت رخصة **timesfm-non-commercial-license-v1.0** — يعني استخدام غير تجاري وغير إنتاجي فقط.

الكود نفسه Apache-2.0، وأوزان **TimesFM-2.5** كانت Apache-2.0 كمان. لكن أوزان النسخة 3 لأ.

النتيجة العملية مطلقة وسابقة لأي كلام عن الدقة: لو إنت بتشتغل في تطبيق تنبؤ تجاري، فـ **TimesFM-3** بشكله المنشور مش متاح لك أصلاً — عند أي مستوى دقة. تقليل 26% في الخطأ على الطلب المتقطع **ملهوش أي معنى** لتاجر تجزئة مش مسموح له قانونياً ينشر الموديل ده.

الخيارات المتاحة: تستخدم **TimesFM-2.5** تحت Apache-2.0، أو تتفاوض على شروط منفصلة مع Google، أو تستخدم طريقة كلاسيكية. كل طريقة كلاسيكية في المقارنة دي خالية من القيود دي.

بنقول ده مش كنقد لـ Google — بنقله لأنه بيتشال دايماً من مقارنات الموديلات، وهو يقلب الترتيب رأساً على عقب لفئة كاملة من المستخدمين.

من الآخر: قبل ما تسأل "أدق؟" اسأل "مسموح لي أصلاً؟"

10.3 Interpretability — القابلية للتفسير والتشخيص

ARIMA بيقولك ال orders والمعاملات والأخطاء المعيارية بتاعتها. **ETS** بيقولك معاملات التنعيم والحالات. ودول بيسمحوا بشغل التشخيص العادي: تفحص ال residuals، تختبر الارتباط الذاتي المتبقي، تفسر لصاحب القرار **ليه** التنبؤ بيلف هنا، وتكتشف إن الموديل **بطل يظبط**.

TimesFM-3 **مبيديش حاجة من دول**. لما يتنبأ غلط، مفيش parameter تبصله ولا تشخيص تشغله — اللي تقدر تعمله إنك **تلاحظ** الأخطاء وتغير الطريقة. وفي بيئة منظّمة (regulated) لازم تبرّر التنبؤ مش بس تنتجه — الفرق ده لوحده ممكن يترجّح على المقارنة كلها.

10.4 Prediction Intervals in Theory — الفترات نظرياً

الفترات الكلاسيكية مشتقة من **بنية الخطأ المفترضة**، فتقدر تناقشها تحليلياً. أما **TimesFM-3** **quantiles** فهي **مخرجات متعلّمة** من رأس شبكة، من غير نظرية. أثبتنا فوق إنها في الواقع أحسن معايرة في المتوسط — **بس تجريبياً، على العمليات دي**، مش بالبناء. وسلوكها على عملية شبيهة بحاجة مش موجودة في corpus التدريب **مجهول بالتعريف**.

11. When to Use Which — امتى تستخدم إيه (جدول القرار)

ده خلاصة الورقة العملية:

الموقف	استخدم	الدليل
نشر تجاري أو إنتاجي	كلاسيكي (أو TimesFM-2.5)	أوزان v3 رخصتها غير تجارية — الدقة مش القيد أصلاً
طلب متقطع، وتكلفتك خطية	TimesFM-3	كسب على الستة Croston في 24/24 مقارنة
طلب متقطع، وتكلفتك تربيعية	Croston-SBA / ADIDA	بيكسبوا على RMSSE في كل طول
موسمية قوية + ≤ 4 دورات	AutoARIMA	أحسن بـ 21-24%، كلها $p > 0.0001$
موسمية بس ≥ 2 دورتين	SeasonalNaive أو TimesFM-3	الكلاسيكي الأتوماتيكي بيعع: AutoETS = 3.03
آلاف السلاسل، مفيش وقت تضبط كل واحدة	TimesFM-3	بيكسب على كل الطرق ما عدا AutoARIMA
سلسلة واحدة وإنت عارف تحدد وتقدر الموديل	كلاسيكي	AutoARIMA متعادل (9-11)، ومجاني ومفسر
كسر هيكل قريـب والفترات مهمة	TimesFM-3	تغطية مشابهة بفترات نص العرض (محاكاة بس)
الإنتاجية مهمة وعندك GPU	TimesFM-3	أسرع $103 \times$ لكل سلسلة، $2.3 \times$ إجمالاً
فترات موثوقة على بيانات حقيقية	Combination JI	على M4: 0.801 مقابل 0.765 لـ TimesFM-3
لازم تفسر أو تراجع (audit)	كلاسيكي	TimesFM-3 مبيديش parameters ولا تشخيص

12. The Hypotheses — الفرضيات: مفيش واحدة نجت سليمة

سجلنا 5 فرضيات قبل أي تنبؤ. والنتيجة:

#	الفرضية	الحكم
H1	الكلاسيكي يكسب على أرضه، والفرق أكبر عند n صغير	✗ مفندة — الفرق يبروح في الاتجاه المعاكس عند n صغير
H2	TimesFM-3 يكسب حيث لا شكل كلاسيكي صحيح	⚠ مدعومة جزئياً — على MASE و pinball نعم، على RMSSE و SMAPE لا
H3	في D9 يتعادلا في المتوسط والكلاسيكي يقصر في التغطية	⚠ جزئياً — التعادل صح، لكن AutoARIMA بس هو اللي يقصر
H4	ال Combination يكسب على كل فرد ويكون أصعب خصم	✗ مفندة في الشقين — AutoARIMA أحسن منه، وهو الخصم الأصعب (11-9 مقابل 27-3)
H5	الطرفين يقصروا في تغطية 80%	✗ مفندة — على المتوسط TimesFM-3 على المطلوب والكلاسيكي يبرؤد من $n=96$

النقطة المهمة: إن كل فرضية فشلت في حته ما هو أقوى حجة للتسجيل المسبق. لو الفرضيات اتكتبت **بعد** النتائج، القسم ده كان هيبّلغ 5 تأكيدات.

من الآخر: التسجيل المسبق مش بيروقراطية — هو اللي خلانا نقول "غلطنا" 3 مرات بدل ما نقول "توقعنا صح" 5 مرات.

13. Limitations — حدود الدراسة (بصراحة)

1. **قوة المحاكاة هي حدودها كمان.** سلاسل مولدة من 9 عمليات بارامترية **مش** سلاسل حقيقية: هي نضيفة، ومستقرة حيث حددنا، وخالية من خطأ القياس والتأثيرات التقويمية والعروض الترويجية وتغيّرات النظام. اللي اشتترته المحاكاة (غياب التلوث + معرفة التخصيص الصحيح) دفعت تمنه **واقعية**.
2. **قيّمنا الموديل zero-shot و univariate بس.** الجديد الأساسي فيه هو ال **multivariate** بال covariates، والقدرة دي **مش متختبرة هنا** لأن عملياتنا كلها أحادية المتغير بالبناء. دراسة تستغل المعلومات عبر السلاسل ممكن توصل لنتائج مختلفة — وده الامتداد الطبيعي.
3. **مفيش تطبيق يدوي لأي طريقة.** ده مقصود وهو الوضع اللي معظم المحللين بيقابلوه، لكن خبير يشوف كل عملية بعينه ويركب الموديل المناسب بإيده **هيكسب على كل** طريقة أوتوماتيكية هنا.
4. **الأفق قصير** ($H=12$) والفترة الموسمية ثابتة عند 12. آفاق أطول وترددات تانية ممكن تختلف.
5. **تحليل الطلب المتقطع بعدي (post-hoc)** — أضفنا Croston بعد ما شفنا النتائج، رداً على ثغرة اتحدت في المراجعة، ونبّلغه منفصل عن المقارنة المسجلة مسبقاً.
6. **دي دراسة عن موديل واحد.** **Chronos** و **Moirai** مش متقيمين هنا، فمفيش حاجة هنا تتقري كادعاء عن ال foundation models عموماً.

14.1 Pre-registration and Deviations — التسجيل المسبق والانحرافات

- **PREREGISTRATION.md** متجمّد قبل أي تنبؤ، ومتعدّلش أبداً بعد كده.
 - **DEVIATIONS.md** فيه 9 انحرافات، كل واحد بتاريخه وسببه، مقسومين مجموعتين:
 - **D-01 لـ D-03** اتعملوا قبل وجود أي نتيجة (تصليح توزيعات البيانات).
 - **D-04 لـ D-09** اتعملوا بعد وجود نتائج، وكل واحد بيقول كده في مدخله.
- ⚠️ وحتى ترويسة الملف ده اتصلحت: كانت بتقول "كل الانحرافات اتعملت قبل النتائج" — ده كان صح لما كان فيه 3 بس، وبقي غلط لما اتضافوا اللي بعدهم. صلّحناها علناً بدل ما نعيد كتابتها بالساكت.

14.2 Real Bugs Caught — أخطاء حقيقية اتمسكت، وإزاي

- ★ **الغلط الأخطر: اختلال محاذاة صامت.** لما ربّنا سلاسل M4 بـ `unique_id = str(i)`، مكتبة `statsforecast` رجّعت الصفوف بترتيب أبجدي: "0", "1", "10", "100", "1000" ... بينما الكود بيعيد التشكيل على أساس ترتيب رقمي. النتيجة: كل تنبؤ اتقرن بالسلسلة الغلط. ومفيش أي رسالة خطأ — الكود اشتغل عادي!
- اكتشفناه إزاي؟ لأن `SeasonalNaive` طلع `MASE = 28.9`، وده مستحيل: هو أساساً مقام الـ MASE، فلازم يبقى حوالي 1.
- الدرس (وده أهم درس هندسي في المشروع):** لازم يبقى معاك دائماً رقم واحد على الأقل تعرف قيمته الصحيحة مسبقاً، عشان الغلط الصامت يبقى مستحيل مش بس مستغرب. والحل: `f"{i:07d}"` — أصفار في الأول عشان الترتيب الأبجدي = الرقمي.

غلط ثاني: الـ `Diebold-Mariano` غير الصالح (شرحناه في 7.2) — اتمسح.

غلط ثالث: ادعاء إن "كل DOI اتحقق منه عبر Crossref" كان غير دقيق — السكربت كان بيراجع قائمة **مكتوبة بالإيد** موازية لـ `refs.bib`، والاتنين افترقوا، و **DOIs 6** في المراجع مراجعوش خالص (كلهم arXiv، و Crossref ميخدمهاش أصلاً). اتصلّح: السكربت دلوقتي **بيقرا الـ bib نفسه** ويحلّ الـ DOI عبر `doi.org` اللي بيرد عن Crossref و DataCite. دلوقتي 30 من 30 بيتحلّوا.

14.3 Archiving and Publication — الأرشفة والنشر

- **المستودع العام:** (172//https: github.com/ebrahimkhaled/timesfm-classical-paper) ملف، 115 ميغا: الكود كامل + المقاييس لكل سلسلة في الـ 129,600 تقييم + التنبؤات الخام + الأشكال + مصدر المخطوطة).
- **Zenodo:** بالطريقة المعتادة — تفعيل المستودع من موقع Zenodo، وبعدين عمل release على GitHub، والـ webhook بيسك الـ DOI لوحده. وملف `zenodo.json` موجود في جذر المستودع فـ Zenodo بياخد العنوان والـ ORCID والرخصة منه أوتوماتيك.
- **ليه ننشر التنبؤات الخام؟** مش للكمال — عشان نتيجة الطلب المتقطع **بتنقلب** بين المقاييس، فأني قارئ عايز يعيد التقييم بدالة خسارة مختلفة يقدر **من غير ما يعيد الدراسة كلها**.
- **arXiv:** الحزمة اتبنت واتحققت في **غرفة نظيفة** (extract في مجلد فاضي + compile) — صفر أخطاء، صفر مراجع غير معرّفة. الفئة الأساسية `stat.ME` مع cross-list على `stat.AP` و `cs.LG`.
- **أوزان الموديل مش متعادة نشرها** — رخصتها غير تجارية، والكود بينزلها من Hugging Face.

15. الخلاصة الكبيرة — لو هتفتكر 5 حاجات بس

1. مفيش طرف كسب. الموديل كسب 16 خلية والكلاسيكي 20 — بس ال 20 دول موزعين على 5 طرق مختلفة، والموديل واحد من غير تطبيق.
 2. **AutoARIMA** هو الوحيد اللي بيصمد (9-11). كل اللي غيره — حتى دمج الثلاثة — بيتغلب في الغالبية.
 3. التخصيص الصحيح ≠ القابلية للتقدير. بدورتين موسميتين، **AutoETS** خسر بـ 2.7 مرة قدام قاعدة من سطر واحد — على بيانات هو اللي ولدها. ال foundation models أنفع بالظبط لما التقدير الكلاسيكي جعان بيانات.
 4. الموديل بيشتري الثبات مش الدقة القصوى. عمره ما بقى أسوأ من 1.31× من الأحسن، بينما كل كلاسيكي بيبقى ≤ 2.2× أسوأ في مكان ما.
 5. حاجتين بيقطعوا عرض المقارنة كلها: الموديل أسرع 103× لكل سلسلة من **AutoARIMA** (مش أعلى!)، ورخصته غير تجارية — يعني لفئة كاملة من المستخدمين السؤال محسوم قبل أي كلام عن دقة.
- من الآخر خالص: مش "الجديد أحسن من القديم" ولا العكس — الجديد أثبت، والقديم أدق لما يقدر يتقدّر، والرخصة ممكن تحسم الموضوع قبل الاتنين.

الملف ده شرح مصاحب للورقة. الأرقام كلها متطابقة مع ملفات النتائج في **results/**، وكل رقم في الورقة نفسها متربوط بملف CSV بيثبتته (18 من 18 فحص بيعدي).