

شرح الورقة بالمصري — Foundation or Formula?

يعني إيه "Formula" و يعني إيه "Foundation"؟

عنوان الورقة بيحط كلمتين قدام بعض. خرينا نفهمهم الأول، لأن الورقة كلها مبنية على المقارنة بينهم.

1) ال Formula — "الصيغة"، الطريقة القديمة

ال Formula معناها **معادلة رياضية** إنت بتفترضها وبعدين بتطبط أرقامها على بياناتك.

مثال: **ARIMA** بتقول لك إن قيمة النهارده = معادلة فيها قيم الأيام اللي فاتت + الأخطاء اللي فاتت. المعادلة نفسها إنت اللي بتختارها، والكمبيوتر بيحدد الأرقام (ال parameters) اللي جواها من بياناتك إنت لوحدك.

خصائصها:

- صغيرة جداً — 3 أو 4 أرقام بس.
- بتتعلم من سلسلتك إنت بس — معندهاش أي معرفة سابقة بالدنيا.
- مفهومة — تقدر تبص على الأرقام وتفهم الموديل بيقول إيه وليه.
- قديمة ومجربة — بقالها 50 سنة في الكتب والصناعة.

من ديه: **ARIMA** ، **ETS** ، **Theta** ، **Seasonal Naive**.

2) ال Foundation — "الأساس"، الطريقة الجديدة

ال Foundation Model معناها شبكة عصبية ضخمة اتدربت مرة واحدة على ملايين السلاسل الزمنية من الدنيا كلها، وبعدين بتديها سلسلتك إنت فتتنبأ ليك من غير ما تدربها من أصله. ودي اللي بيسمونها **zero-shot**.

TimesFM-3 من ديه: 330 مليون رقم جواه، متدرب على أكثر من تريليون نقطة زمنية.

خصائصها:

- ضخمة — 330 مليون رقم مقابل 3.
- بتعرف حاجات من بره سلسلتك — شافت ملايين السلاسل قبل كده.
- مقفولة — مش هتتعرف تبص جواها وتفهم قرارها.
- جديدة — الحاجات دي طلعت في آخر سنتين.

الكلمة المفتاحية: مصدر المعرفة

الفرق الحقيقي بينهم مش "قديم وجديد" ولا "صغير وكبير" — الفرق هو المعرفة جاية منين:

Foundation	Formula	
من ملايين السلاسل اللي اتدربت عليها	من سلسلتك إنت بس	بتعرف من فين؟
مفيش — بتشتغل على طول	بيانات كفاية عشان تقدّر معادلتها	محتاجة إيه؟
لما بياناتك قليلة أو شكلها غريب	لما يبقى عندك بيانات كتير وشكلها واضح	بتنفع إمتى؟

تشبيه: ال Formula زي **دكتور خريج لسه** بس معاه كتاب مطبوط: لو الحالة موصوفة في الكتاب بالطبط، هيبقى ممتاز. وال Foundation زي **دكتور شاف مليون حالة:** مش معاه كتاب، بس عنده **حدس** قوي — ولو الحالة نادرة هيبقى أحسن منه بكتير.

وعشان كده العنوان سؤال

"Foundation or Formula?" يعني: **أستخدم الوحش الضخم اللي شاف الدنيا، ولا المعادلة الصغيرة المفهومة؟**

والورقة **مش** بتجاوب "ده أحسن من ده". بتجاوب: **إمتى ده وإمتى ده** — وبأرقام متختبرة إحصائياً مش بآراء.

من الآخر: Formula = معادلة صغيرة بتتعلّم من بياناتك إنت. Foundation = شبكة ضخمة اتعلّمت من بيانات الدنيا. والسؤال هو مين فيهم ينفعك، **إمتى**.

0. The Big Idea in One Breath — الفكرة الكبيرة في نفس واحد

قبل ما ندخل في أي تفصيلة، خد الصورة كلها في دقيقة:

Google نزلت موديل اسمه TimesFM-3 بيتنبأ بالسلاسل الزمنية (time series) من غير ما تدربه على بياناتك خالص — بيسمّوا ده **zero-shot**. السؤال العملي: أنا ك محلل، لو قدامي سلسلة زمنية، أستخدم الموديل الجبار ده ولا أستخدم **ARIMA** القديمة الكويسة؟

الورقة دي بتجاوب على السؤال ده. وأهم حاجة فيها إننا **مخترعناش طريقة جديدة** — دي دراسة مقارنة (comparative study)، وقلناها بصراحة في الورقة. اللي يخليها تستاهل النشر حاجة تانية: **إحنا مولّدا البيانات بنفسنا**، والسبب هنشره بعد شوية وهو قلب الموضوع كله.

النتيجة باختصار: **مفيش طرف كسب**. لكن الطريقة اللي "مكسبش" بيها كل طرف هي الحكاية الحلوة.

من الآخر: الورقة مش بتقول "ال AI كسب" ولا "الكلاسيكي أحسن" — بتقول **إمتى** ده وإمتى ده، وبأرقام متختبرة إحصائياً.

1. Introduction — المقدمة: ليه الدراسة دي وإيه الجديد فيها

1.1 Why the Published Evidence Is Not Enough — ليه الأدلة المنشورة مش كفاية؟

هنا لب المشكلة، وده اللي بنى عليه البحث كله.

لما شركة تنزل موديل، بتقولك "بصّ، كسبت على ال benchmarks الفلانية". المشكلة إن ال benchmarks دي بيانات **عامّة** ومنشورة على الإنترنت، والموديل اتدرب على... الإنترنت.

باحثين اسمهم Meyer وزملايه (2025) عملوا حاجة مهمة: تتبّعوا نسب البيانات لـ 22 موديل foundation model للسلاسل الزمنية. لقوا إن من **dataset 401** استُخدمت في تقييمهم، 6% بس هي اللي **مظهرتش** في corpus التدريب بتاع أي موديل منهم.

يعني إيه؟ يعني 94% من التقييمات دي، الموديل يمكن يكون **شايف الإجابة قبل الامتحان**.

وأكثر من كده: لقوا إن تداخل بنسبة 0.1% بس بين بيانات التدريب وبيانات الاختبار ممكن يحرك الـ MAPE بمقدار 8 لـ 29 **نقطة مئوية**. ودي مش نسبة صغيرة، دي فرق بين موديل ممتاز وموديل فاشل.

وكمان — والنقطة دي ذكية — التسريب (leakage) مش لازم يكون **مباشر**. لو الموديل اتدرب على سلسلة تانية **متداخلة زمنياً** ومرتبطة سببياً بسلسلتك، هو كده أخذ ميزة على سلسلتك حتى لو عمره ما شافها.

تشبيه: طالب ذاكر من بنك أسئلة، والامتحان جه 94% منه من بنك الأسئلة ده. درجته العالية معناها إيه بالظبط؟ مش عارفين. ودي بالظبط مشكلة الـ benchmarks.

فيه كمان انتقاد ثاني اتقال كتير على الأوراق دي: بيقارنوا الموديل الجبار بـ baselines كلاسيكية **مفكوة وغير متظبطة** — يعني ياخدوا **ARIMA** لوحدها بدل ما ياخدوا الـ **combination** اللي بتكسب في مسابقات التنبؤ زي **M4**. ده زي ما تقارن فريقك بلاعب واحد من الفريق الثاني.

من الآخر: أي رقم من benchmark عام = قياس **مجهول المصدر**، ولازم نلاقي طريقة تانية.

1.2 The Idea That Closes Both Objections — الفكرة اللي بتقفل الاعتراضين مع بعض

الحل اللي الورقة اختارته: **إحنا نوّلد البيانات بنفسنا**.

لما نوّلد سلسلة من عملية معروفة (Data-Generating Process — واختصارها **DGP**)، بيحصل **حاجتين في نفس اللحظة**، وده اللي بيدي المقارنة قوتها:

1. **الموديل قطعاً مشافش السلسلة دي** — مش "على الأغلب"، لأ؛ السلسلة دي **معملتش أصلاً** غير لما شغلنا التجربة. فمستحيل تكون في corpus التدريب.

2. **الموديل الكلاسيكي بيبقى "صح بالتعريف"** (correctly specified by construction) — لو البيانات فعلاً **ARIMA(1,1,1) with drift**، بيبقى **AutoARIMA** مش تقرب للحقيقة، دي **هي الحقيقة** نفسها، وفاضل بس إنه يقدر الـ parameters.

النقطة الثانية دي هي السر. عشان كده السؤال بقى حاد ومحدد:

- الموديل بيخسر قد إيه لما يلعب على **أرض الكلاسيكي** (يعني الشكل الرياضي صح 100%)؟
- وبيكسب قد إيه لما **مفيش شكل كلاسيكي صح** (كسر هيكل، لا خطية، طلب متقطع، تقلّب)؟

⚠ **تفرقة مهمة جداً** — لازم تكون **أمنية** فيه حاجة لازم نقولها بصراحة، وقلناها في الورقة:

- اللي التصميم بتاعنا **بيمنعه** هو التلوث على مستوى **التحقق الفردي** (the realisation) — السلسلة دي بالذات مكتتش موجودة.
- اللي التصميم **مش** بيمنعه هو الألفة على مستوى **العيلة** (the family). يعني **TimesFM-3** اتدرب على بيانات **صناعية** كمان، والبيانات الصناعية للـ time-series models عادةً بتتولّد من نفس العائلات دي بالظبط (**ARMA** , **AR** ,

(..seasonal). فهو يعرف الشكل العام حتى لو مشافش النسخة دي.

عشان كده عنوان الورقة يقول "A Simulation-Based Comparison" — بيوصف الطريقة (محاكاة) من غير ما يدّعي إن الموديل مايعرفش نوع البيانات، لأن ده ادعاء أوسع من اللي التصميم بيثبتته.

من الآخر: إحنا مولدنا البيانات عشان نضمن حاجتين: الموديل مشافهاش، والكلاسيكي صح بالتعريف. بس مدّعينا إن الموديل مش عارف نوع البيانات — دي أمانة علمية مش تواضع.

1.3 The Four Contributions — إيه الجديد في الورقة دي بالضبط؟

الورقة مش بتخترع طريقة جديدة — بس فيها أربع حاجات جديدة على الأدبيات:

1. **تقييم نضيف من التلوث بالبناء:** البيانات اتولدت بعد الموديل، فمستحيل يكون شافها، وكل ده تحت بروتوكول متجمّد قبل أي تنبؤ، وكل انحراف عنه متسجّل.

2. **أسوأ حالة، مش المتوسط بس:** ال benchmarks بتقارن **متوسطات**؛ إحنا بصّينا كمان على **أسوأ سيناريو** لكل طريقة — ولقينا إن الحد ده خاص بـ **TimesFM-3** من بين خمس موديلات أساس، وفي الأفق القصير بس (لحد حوالي سنتين من الخطوات الشهرية).

3. **التخصيص الصحيح ≠ القابلية للتقدير:** أكبر إخفاقات **AutoARIMA** و **AutoETS** بتحصل لما دورتين موسميتين مايكفوش لتقدير شكل موسمي — مش لما الموديل غلط.

4. **مقارنة بأبطال M4 الحقيقيين ومعايير بسيطة:** حطينا الموديلات الأساس قدام **التنبؤات المنشورة** لأحسن مشاركات مسابقة M4، وقدام معايير بسيطة من التاريخ نفسه في الطلب المتقطع — وسجّلنا كمان قيود **الرخصة والتكلفة**.

من الآخر: الجديد مش "مين كسب"، الجديد إننا عرفنا **إمتى ولحد فين** كل طرف بيعصم، في ظروف نضيفة.

2. What Is TimesFM-3? — إيه هو ال TimesFM-3 أصلاً؟

في 31 أغسطس 2026 نزلت Google الجيل الثالث من موديلها **TimesFM**. خصائصه:

- **330 مليون parameter** (بالضبط 330,710,976 — إحنا عدّيناهم من ال checkpoint نفسه مش نقلًا عن حد).
- متدرّب على **أكثر من تريليون نقطة زمنية** (time points)، بيانات حقيقية و بيانات صناعية (synthetic).
- أول واحد في العيلة متدرّب أصلاً على ال **multivariate** — يعني ياخذ أكثر من سلسلة مع بعض، ويقدر ياخذ **covariates** (متغيرات مساعدة) سواء من الماضي أو معروفة للمستقبل.
- بيستخدم **attention** بالتبادل: مرة على المحور الزمني (causal-temporal) ومرة على محور المتغيرات (full-variate).
- **بيطلّع الأفق كله في مرة واحدة** (non-autoregressive) — يعني مش بيتنبأ بخطوة ويرجع يدخلها عشان يتنبأ باللي بعدها.
- **بيطلّع 9 quantiles** (من **q0.1** لـ **q0.9**) — يعني مش رقم واحد، دا توزيع.
- طول ال context بيوصل **16k** نقطة.

تشبيه: تخيل دكتور اتخرّج ومشتغلش في مستشفى واحدة بس — لأ، ده اتفرّج على مليون حالة من مستشفيات الدنيا كلها. لما يبجي يشوف مريضك، هو معندوش ملف مريضك بس عنده **حدس** اتبنى من كل اللي شافه. ده بالضبط معنى **zero-shot**: مشافش سلسلتك، بس شاف حاجات شبهها كتير أوي.

من الآخر: TimesFM-3 = موديل ضخمة بيتنبأ من غير تدريب، وبيديك توزيع مش رقم.

3. Design of the Simulation — تصميم دراسة المحاكاة

3.1 The Nine DGPs — التسع عمليات المولدة للبيانات

اخترنا 9 عمليات بحيث تغطي المدى من "الكلاسيكي صح تماماً" لـ "مفیش كلاسيكي صح":

الرمز	العملية	الشرح بالمصري	مين "صح" فيها؟
D1	$AR(1), \phi=0.7$	القيمة النهارده = $0.7 \times$ امبارح + عشوائية. أبسط حاجة ممكنة.	ARIMA
D2	$ARMA(1,1)$	زي فوق + بتفتكر الخطأ بتاع امبارح كمان.	ARIMA
D3	$ARIMA(1,1,1) + \text{drift}$	فيها اتجاه (trend) — بتمشي لفوق بمعدل ثابت + عشوائية.	ARIMA
D4	$SARIMA(1,0,0)(1,1,0)[12]$	فيها موسمية قوية كل 12 شهر (زي مبيعات رمضان).	ARIMA
D5	$ETS(A,A,A)$	مستوى + اتجاه + موسمية، بس بصيغة الـ state-space.	ETS
D6	Local level + كسر هيكل	ماشية عادي وفجأة تقفز قفزة (زي زيادة سعر).	ولا واحد
D7	Logistic growth	نمو بيتشبع (S-curve) — بيطلع بسرعة وبعدين يقف.	ولا واحد
D8	Intermittent demand	طلب متقطع: 70% أصفار، وبين الحين والتاني طلبية.	ولا واحد
D9	$AR(1) + GARCH(1,1)$	المتوسط صح، بس التذبذب نفسه بيتغير (فترات هدوء وفترات جنون).	ARIMA في المتوسط بس

ليه اخترنا D6 بالكسر جوه الـ context مش في المستقبل؟ دي نقطة تصميم مهمة جداً. لو حطينا الكسر في الفترة اللي بنتنبأ بيها، مفیش طريقة في الدنيا تقدر تتنبأ بيه — فالتجربة كانت هتقيس بس "مين أكثر واحد محافظ ومش بيتحرك". لكن لما نحطه جوه البيانات اللي الموديل شافها (عند $n \times 0.7$)، السؤال يبقي عادل ومحترم: "إنت شفت المستوى اتغير — هتتنبأ من المستوى الجديد ولا هترجع للقديم؟"

ليه D7 نقطة الانقلاب عند 0.6 من السلسلة؟ عشان الفترة اللي بنتنبأ بيها تقع في الجزء اللي بيتشبع. أي طريقة بتركب خط مستقيم (drift) هت تعدي فوق (overshoot). وده بالضبط اللي عايزين نكشفه.


3.2 Lengths, Replications, Horizon — الأطوال والتكرارات والأفق

- أطوال السلاسل: $n \in \{24, 48, 96, 200\}$. الـ 24 دي قاسية بشكل مقصود: مع موسمية 12، يبقى عندك دورتين موسميتين بس. وهنشوف بعدين إن ده يفرق حاجة كانت الناس بتخلط بينها.
- التكرارات: 200 تكرار لكل سيناريو (DGP $\times$ طول).
- إجمالي السلاسل: $7,200 = 200 \times 4 \times 9$ سلسلة.
- الأفق (horizon): $H = 12$. بنولد $n + 12$ نقطة، أول n بنديها للموديل، وآخر 12 بنخبها ونقارن بيها.

• ال Seeding: كل سلسلة ليها seed محسوبة من هويتها:

رقم الطول + رقم التكرار $\times 1,000$ + رقم ال $\text{DGP} = \text{seed} = 1,000,000$. يعني السلسلة بتتعد بالظبط من غير ما يفرق عدد الأنوية اللي شغالة ولا ترتيب التنفيذ.

من الآخر: 9 عمليات $\times 4$ أطوال $\times 200$ تكرار = 7,200 سلسلة، كل واحدة ليها seed ثابتة، فأني حد يقدر يعيد نفس الأرقام بالظبط...



شكل 1 — عينة واحدة من كل عملية من التسعة (عند $n = 96$). الجزء الرمادي هو البيانات اللي الموديل بيشوفها، والجزء الملون في الآخر هو ال 12 نقطة المخبية اللي بنقيس عليها. بّص على **D6** : الكسر الهيكل واضح عند النقطة 67 تقريباً — يعني 96×0.7 بالظبط زي ما صمّمناه. وبّص على **D8** : معظمها أصفار، وده اللي هيبوّط ال **MAPE** بعدين.

3.3 The Methods Compared — الطرق اللي اتقارنت

مفيش أي طريقة اتظبطت بالإيد. كل طريقة كلاسيكية شغالة بالاختيار الأتوماتيكي بتاعها — لأن ده الوضع اللي المحلل الحقيقي بيقابله.

الطريقة	الشرح بالمصري
TimesFM3	الموديل بتاع Google ، zero-shot ، من غير تدريب ولا تطبيق.
SeasonalNaive	أغبي طريقة ممكنة: "النهارده هيبقى زي نفس اليوم السنة اللي فاتت".
Theta	الطريقة اللي كسبت مسابقة M3 — بتفكك السلسلة وتعيد تركيبها.
AutoETS	Exponential smoothing بيختار الشكل أوتوماتيك (Hyndman-Khandakar).
AutoARIMA	ARIMA بيدور على ال orders أوتوماتيك.
Combination	متوسط ال 3 دول: AutoARIMA. + AutoETS + Theta

ليه ال Combination إجباري مش اختياري؟

عشان أشهر انتقاد بيتقال على أوراق ال foundation models هو إنهم بيقارنوا نفسهم بطرق كلاسيكية **مفكوة**. ال state of the art الكلاسيكي هو **الدمج** مش الطريقة الواحدة. لو شلناه، يبقى إحنا بنينا النتيجة اللي عايزينها **جوه التصميم** نفسه — وده غش منهجي.

⚠ ملاحظة أمانة: عدم تماثل في المعلومات

فيه حاجة قلناها في الورقة بصراحة لأنها **في صالح الكلاسيكي**: كل الطرق الكلاسيكية بندّيه **الفترة الموسمية الحقيقية** (m) = 12 كمعلومة جاهزة، بينما TimesFM-3 بياخد السلسلة الخام من غير ما نقوله إن فيها موسمية أصلاً ولا طولها كام. يعني الكلاسيكي واخد مساعدة.

من الآخر: 6 طرق، الكلاسيكي واخد مساعدة (الموسمية جاهزة)، وال Combination موجود عشان المقارنة تبقى شريفة.

3.4 The Metrics — المقاييس، وإزاي بنقيس "الغلط"

6.1 Point Metrics — مقاييس النقطة الواحدة

MASE (المقياس الأساسي): الخطأ المطلق مقسوم على خطأ ال seasonal naive داخل **العينة**.

$$\text{MASE} = \frac{\frac{1}{h} \sum_{i=1}^h |y_i - \hat{y}_i|}{\frac{1}{n-m} \sum_{t=m+1}^n |y_t - y_{t-m}|}$$

تفكيك المعادلة رمز رمز:

- y_i — القيمة **الحقيقية** في الخطوة رقم i من الفترة اللي بنتنبأ بيها.
- $\hat{y}_i$ — القيمة **المتوقعة** من الموديل لنفس الخطوة. (القبة فوق الحرف معناها "تقدير").
- h — **طول الأفق**، يعني كام خطوة بنتنبأ بيها. عندنا $h = 12$.
- n — **طول السلسلة المعروفة** اللي الموديل شافها.
- m — **الفترة الموسمية**. عندنا $m = 12$ للسلاسل الموسمية، و $m = 1$ لغيرها.

والكسر نفسه:

- **البسط** — متوسط الخطأ المطلق **بتاعك** في الفترة المتنبأ بيها. يعني: بتغلط بكام في المتوسط؟

- **المقام** — متوسط خطأ "أغبي طريقة" (ال seasonal naive: "النهاره زي نفس اليوم في الدورة اللي فاتت"), محسوب على البيانات **اللي إنت شايفها** مش على المستقبل.

وإزاي تقرا الرقم الناتج؟

- $MASE = 1$ ← إنت **بالظبط زي** الطريقة الغبية.
- $MASE < 1$ ← إنت **أحسن** منها. يعني **0.68** معناها خطأك 68% من خطأها.
- $MASE > 1$ ← إنت **أوحش** من الطريقة الغبية! وده بيحصل فعلاً — شوف **AutoETS** في القسم 4.4.

ليه القسمة دي مهمة؟ عشان تقدر تجمع نتايج من سلاسل مقاييسها مختلفة تماماً — سلسلة أرقامها بالملايين وسلسلة أرقامها بالعشرات — من غير ما الكبيرة تبلع الصغيرة.

RMSSE : نفس الفكرة بالظبط بس بالتربيع بدل المطلق (زي ما في مسابقة **sMAPE**). (**M5** : نسبة مئوية متماثلة، مدى من 0 لـ 200.

6.2 Why MAPE Is Not the Headline — ليه ال MAPE مش المقياس الأساسي

ال **MAPE** هو أشهر مقياس عند الناس، ومع ذلك حظينه في **الملحق** بس. ليه؟

1. **غير معرف عند الصفر** — القسمة على صفر. وفي **D8** (الطلب المتقطع) 70% من القيم أصفار!
2. **غير متماثل** — بيعاقب المبالغة في التقدير أكثر من التقليل. فهو **بيحابي** الطرق المتحفظة.
3. **بيقلب الترتيب** — وده مش كلام نظري، ده حصل في بياناتنا فعلاً.

الرقم اللي بيثبت الكلام ده: ال MAPE طلع **غير معرف في 12,906 من 129,600** تقييم — يعني **9.96%** — وكلهم **بالظبط** في **D8** .

يعني لو كنا اعتمادنا على ال MAPE، كنا هنضطر **نшил النظام اللي فيه أقوى نتيجة عندنا** من المقارنة خالص، أو نخترع اتفاقية للأصفار من دماغنا.

من الآخر: ال MAPE مقياس مشهور لكنه بيكذب لما فيه أصفار — و **D8** كلها أصفار، فمينفعش يكون الأساس.

6.3 Probabilistic Metrics — مقاييس التوزيع مش النقطة

الموديلات دي مش بتديك رقم واحد، بتديك **توزيع**. فلازم نقيس التوزيع نفسه:

- **Pinball loss** (**خسارة ال quantile**): بنحسبها على ال 9 deciles كلها، ومقسومة على نفس مقام ال MASE عشان تبقى قابلة للمقارنة. دي **proper scoring rule** يعني مقياس شريف رياضياً.
- **Coverage** : الفترة اللي قلت عليها 80% — هل الحقيقة وقعت جواها 80% من المرات فعلاً؟
- **Width** : عرض الفترة. ودي مهمة أوي — هنشوف ليه كمان شوية.

⚠ ليه 60% و 80% ومفيش 90%؟

دي نقطة تصميم مقصودة: **TimesFM-3** بيطلع ال **deciles** بس (من **q0.1** لـ **q0.9**). فمفيش عندك **q0.05** ولا **q0.95** عشان تعمل فترة 90%. لو قارنا فترة 90% كلاسيكية بفترة معمولة بالاستقراء (extrapolation) من الموديل، تبقى مقارنة **مش عادلة**. فأخذنا أوسع فترة **ال اثنين** يقدروا يعبروا عنها: **[q0.1, q0.9]** .

من الآخر: بنقيس النقطة (MASE) والتوزيع (pinball) والفترة (width + coverage) — الثلاثة، مش واحد.

3.5 The Statistical Tests — الاختبارات الإحصائية

مش كفاية نقول "المتوسط ده أقل من ده". لازم نختبر.

7.1 Paired Wilcoxon — الاختبار الأساسي

جوه كل سيناريو (DGP × طول × أفق)، بنقارن **TimesFM-3** بكل طريقة كلاسيكية باختبار **Wilcoxon signed-rank** **المزدوج** على فروق الـ MASE بين الـ 200 تكرار.

ليه Wilcoxon مش t-test؟ لأنه **مش يفترض التوزيع الطبيعي**، وتوزيعات الخطأ في التنبؤ بتبقى ملتوية (skewed) بشكل بشع. بس برضه بنحسب الـ **t-test** كـ **sensitivity check**.

7.2 Why NOT Diebold–Mariano — ليه رفضنا اختبار Diebold–Mariano

دي نقطة منهجية مهمة، والأدب المنشور بيستخدم **DM** بشكل شبه تلقائي.

الـ **DM** **متصمم** لسلسلة فروق خسارة **مترابطة زمنياً** (autocorrelated) جاية من **سلسلة واحدة** عبر الزمن. عندنا في المحاكاة، الـ 200 تكرار دول **سحوبات مستقلة** من نفس العملية — مفيش ترتيب زمني بينهم أصلاً! فلو استخدمنا DM هنبقى بنوصف بنية اعتماد **مش موجودة**.

وفي بيانات **M4** الحقيقية، التصميم بتاعنا فيه **origins 3** بس لكل سلسلة، يعني الإحصاء هتبقى بـ **درجتين حرية** — يعني مفيش قوة إحصائية خالص.

⚠️ **وحصل غلط حقيقي هنا اكتشفناه بالمراجعة:** في نسخة أولى، الكود حسب DM على **مقطع عرضي** (cross-section) من 1000 متوسط مرتبين **أبجدياً** بحسب اسم السلسلة! يعني التصحيح كان بيجمع autocovariances عبر سلاسل **مالهاش علاقة ببعض** وبترتيب **عشوائي تماماً**. الدليل القاطع: الإحصاء طلعت -13.97 بالترتيب ده، وبين -18 و -23 لما نخلط الترتيب عشوائياً. حاجة بتتغير 30-70% لما تخلط فهرس عشوائي دي **مش اختبار**. فقررنا **نمسحها خالص** مش نصلحها، لأن مفيش نسخة منها التصميم ده بيسمح بيها.

7.3 Multiplicity — التصحيح للمقارنات المتعددة

إحنا بنعمل 180 مقارنة. لو كل واحدة عند 5%، يبقى متوقع نلاقي 9 نتائج "معنوية" **بالصدفة البحتة**. فبنستخدم **Benjamini-Hochberg** للتحكم في الـ False Discovery Rate عند 0.05، ونبلّغ الـ p الخام والمصحح.

7.4 Effect Sizes — أحجام الأثر

مع كل اختبار بنبلّغ:

- **Hodges-Lehmann** : تقدير للفرق الوسيط.

- **نسبة الـ MASE الوسيطة**: عشان تشوف الفرق **عملياً** يعني إيه.

ليه؟ عشان فرق ممكن يبقى **معنوي إحصائياً** وهو **تافه عملياً**. مع 200 تكرار، فرق 0.2% ممكن يطلع معنوي. لازم القارئ يشوف ده.

من الآخر: بنختبر كل فرق، بنصح للمقارنات المتعددة، وبنقول حجم الفرق مش بس هل هو معنوي.

3.6 The Pre-registered Hypotheses — الفرضيات المسجلة مسبقاً

قبل أي تنبؤ، في **8 سبتمبر 2026**، اكتب البروتوكول واتجمّد، وفيه **5 فرضيات** (زي ما هي بالضبط):

- **H1** : في **D1 - D5** (الكلاسيكي صح بالبناء)، **AutoARIMA / AutoETS** أدق من **TimesFM-3** ، والفرق أكبر عند **n = 24**.

- **H2** : في D6 - D8 (مفیش شکل کلاسیکی صح)، TimesFM-3 أدق من كل الطرق الكلاسيكية.
- **H3** : في D9 العيلتين متعادلين في المتوسط، بس فترات الكلاسيكي بتقصر في التغطية.
- **H4** : الدمج أحسن من كل طريقة كلاسيكية لوحدها، وهو أصعب خصم لـ TimesFM-3 .
- **H5** : فترات الـ 80% في العيلتين بتقصر، و TimesFM-3 أكثر في الآفاق الأطول.

البروتوكول ماحددش قواعد قرار رقمية — فالأحكام في آخر القسم 4 هي حكم على نمط الاختبارات. وكل حاجة في القسم 5 (التحليلات البعدية) اتضافت بعد ما النتائج ظهرت، ومنتسجلة كانحرافات.

4. The Pre-registered Comparison — المقارنة المسجلة مسبقاً

التصميم طلع 7,200 سلسلة، ومع 6 طرق و 3 شرائح أفق = 129,600 تقييم.

4.1 A Split Decision, Not a Rout — قرار منقسم مش كاسح

لو عدّينا مين كسب في كل سيناريو من الـ 36 سيناريو (DGP × طول):

الطريقة	عدد السيناريوهات اللي كسبتها
TimesFM3	16
AutoARIMA	10
SeasonalNaive	4
Theta	2
Combination	2
AutoETS	2

يعني الكلاسيكي كسب 20 والموديل كسب 16. القراءة السطحية: "الكلاسيكي كسب".

بس دي قراءة ناقصة، وهنا بيت القصيد: الـ 20 دول متوزعين على 5 طرق مختلفة! يعني عمود الكلاسيكي هو عمود فايزين مختلفين، وإنت معندكش طريقة تعرف مقدماً مين منهم هيكسب على سلسلتك من غير ما تعمل الشغل اللي الـ foundation model المفروض يوفره عليك.

ولما نختبر ضد أحسن طريقة كلاسيكية في كل سيناريو: 18 من 36 فرق نجوا من تصحيح BH — 7 لصالح TimesFM-3 و 11 لصالح الكلاسيكي، و 18 سيناريو تعادل.

4.2 Who Actually Holds Their Ground — مين بيصمد قدامه فعلاً؟


خلينا نبص على الـ 180 مقارنة الثنائية. منها 132 معنوية: 113 لصالح TimesFM-3 و 19 لصالح الكلاسيكي. التفصيل حسب الخصم:

الخصم	مقارنات معنوية	كسب TimesFM-3	كسب الخصم
AutoARIMA	20	11	9
SeasonalNaive	26	22	4
AutoETS	27	25	2
Theta	29	28	1
Combination	30	27	3

الجدول ده هو رسالة الورقة المركزية. بَص على السطر الأول: **AutoARIMA** هو الوحيد اللي بيصمد (11 مقابل 9، يعني عملة معدنية). كل اللي غيره — حتى دمج الثلاثة مع بعض — بيتغلب في الغالبية العظمى.


يعني إيه عملياً؟

- محلل بيختار **AutoARIMA** صح كل مرة → مش هيخسر حاجة لو فضل كلاسيكي.
 - محلل مش بيعرف يختار، أو معندوش وقت يظبط كل سلسلة → أحسن له بكتير يستخدم الـ foundation model.
- من الآخر: الموديل مش بيكسب على أحسن طريقة، لكنه بيكسب على متوسط الطرق — وقيمتة إنك مش محتاج تعرف أنهي طريقة تختار.



شكل 2 — دقة **TimesFM-3** بالنسبة لأحسن طريقة كلاسيكية في كل سيناريو. العمود اللي تحت الصفر معناه **TimesFM-3** أدق، واللي فوق الصفر معناه الكلاسيكي أدق. شوف **D8** (الطلب المتقطع) نازل تحت بوضوح في الأطوال الأربعة، و **D4** (الموسمية) طالع فوق في الأربعة — دول النظامين الحاسمين اللي هنتكلم عنهم في 4.5. والباقي قريب من الصفر، يعني تعادل.

رسم الغابة (forest plot): بدل ما نقول "كسب 11 وخسر 9"، رسمنا لكل سيناريو حجم الفرق وفترة ثقته:



إزاي تقراه؟ كل سطر سيناريو (عملية × طول). النقطة = الفرق النموذجي بين **TimesFM-3** والمنافس، والخط = فترة الثقة. شمال الخط الرأسي = **TimesFM-3** أحسن. النقطة المليانة = فرق معنوي. قدام **AutoARIMA** معظم الخطوط بتعدي على الـ 1 (يعني متعادلين)، والسيناريوهات اللي **AutoARIMA** كسب فيها هي الموسمية من $n = 48$.

Effect Sizes and a Sensitivity Check 4.3 — أحجام الأثر وفحص الحساسية

القسم ده بيسأل سؤالين مختلفين خالص عن اللي فات:

1. الفروق دي كبيرة قَدْ إيه فعلاً؟ (مش: هل هي معنوية)
2. لو غيّرنا الاختبار الإحصائي، النتيجة هتفضل زي ما هي؟

الجزء الأول: "معنوي" ≠ "مهم"

دي أكثر نقطة بتلخبط في الأوراق العلمية. الاختبار الإحصائي بيقولك إن الفرق مش صدفة. مابقولكش إن الفرق يستاهل تغيير شغلك عشانه.

عشان نقيس حجم الفرق استخدمنا **Hodges-Lehmann تقدير**، وهو ببساطة: الفرق الوسيط بين الطريقتين على السلاسل. (السالب لصالح **TimesFM-3**).

الخصم	الفرق الوسيط في MASE	يعني إيه؟
Theta	-0.227	فرق واضح
AutoETS	-0.183	فرق واضح
SeasonalNaive	-0.133	فرق ملحوظ
Combination	-0.091	فرق صغير
AutoARIMA	-0.010	فرق لا يُذكر

اقرأ السطر الأخير كويس. قدام **AutoARIMA** الفرق النموذجي هو واحد من مئة من وحدة MASE — والـ MASE النموذجي في الدراسة حوالي 1.05. يعني الفرق حوالي 1% من مستوى الخطأ.

ده فرق بيتقاس (وبيطلع معنوي إحصائياً لأن عندنا 200 تكرار)، بس مش فرق محلل هيلاحظه في شغله ولا هيغيّر قراره عشانه. المعنوية جت من حجم العينة، مش من حجم الأثر.

الجزء الثاني: نفس البيانات، اختبارين، نتيجتين
استخدمنا **Wilcoxon** كاختبارنا الأساسي (مسجل مسبقاً). وعشان نتأكد إن النتائج مش معتمدة على الاختيار ده، أعدنا كل حاجة بـ **t-test**.


اللاتنين اتفقوا في 163 من 180 مقارنة (90.6%). كويس.

بس الـ 17 اللي اختلفوا فيهم مش عشوائيين — فيهم نمط مهم جداً:

في **D8** (الطلب المتقطع) قدام **SeasonalNaive** : الـ **t-test** يقول **TimesFM-3** أحسن بشكل معنوي في كل طول ($p > 0.0001$)، بينما **Wilcoxon** يقول مفيش فرق معنوي أصلاً (p من 0.11 لـ 0.92)!

نفس الأرقام بالظبط. اختبارين محترمين. نتيجتين متضادين. مين الغلطان؟

الجزء الثالث: ولا واحد فيهم — دول بيجابوا على سؤالين مختلفين
عشان تفهم، لازم تبص على الـ 200 سلسلة واحدة واحدة بدل ما تبص على رقم مجمّع:



شكل 10 — حجم الأثر، والسبب الحقيقي وراء اختلاف الاختبارين. (أ) الفروق الوسيطة قدام الخمس طرق.

AutoARIMA عند -0.010 — شعرة على مقياس MASE النموذجي (≈ 1.05). (ب) دي اللوحة المهمة: الـ 200 سلسلة في D8 عند $n=48$ ، مرتبة من الأسوأ للأحسن. الأخضر = TimesFM-3 أحسن، الأحمر = أسوأ. معظم الأعمدة حمرا وصغيرة، وشوية أعمدة خضرا ضخمة على الشمال. (ج) النتيجة: t-test بيدي p صغيرة جداً في كل طول، و Wilcoxon بيدي p فوق 0.05 في كلهم.

والأرقام اللي بتفتّر كل حاجة:

إيه اللي بيشفه	القيمة	
يقيسه Wilcoxon أسوأ بشعرة ← ده اللي TimesFM-3	+0.005	وسيط الفروق
يقيسه t-test أحسن بكثير ← ده اللي TimesFM-3	-0.358	متوسط الفروق
يعني تلتين السلاسل!	66%	نسبة السلاسل اللي TimesFM-3 أسوأ فيها
عشر سلاسل بس بتحرّك المتوسط	42%	مساهمة أسوأ 5% من السلاسل في المتوسط

فالحكاية كده: على تلتين السلاسل TimesFM-3 أسوأ من SeasonalNaive — بس بفروق تافهة (حوالي 0.005). وعلى أقلية صغيرة من السلاسل، SeasonalNaive بيقع بشكل كارثي و TimesFM-3 أحسن منه بوحدات MASE كاملة.

- المتوسط بيتأثر بالأقلية الكارثية ← فيقول "TimesFM-3 كسب بفارق كبير".
- الوسيط بيتبع الأغلبية ← فيقول "مفيش فرق يُذكر".

اللاتنين صح. الاختلاف مش عيب في اختبار — ده حقيقة عن الشكل الحقيقي للبيانات: توزيع غير متماثل بذييل طويل. والاختبارين بيلخّصوه بطريقتين مختلفتين، وكل واحدة مفيدة لقرار مختلف:

- لو بتخاف من الكوارث النادرة (نفاد مخزون كبير) ← المتوسط هو اللي يهملك، و TimesFM-3 أحسن.
- لو بتهتم بـ الأداء في اليوم العادي ← الوسيط هو اللي يهملك، واللاتنين متعادلين.

وعشان كده بنعامل نتيجة D8 كنتيجة مشروطة مش حاسمة — وده السبب الثالث المستقل اللي يخلينا نقول كده (الأول: RMSSE يقلب النتيجة؛ الثاني: SMAPE يقلبها كمان).

4.4 ★ Specification Is Not Estimability — التخصيص الصحيح مش زي القابلية للتقدير

دي أهم نتيجة في الورقة كلها. وعشان تبقى واضحة، خلينا نبني الفكرة من الأول بالراحة قبل ما نشوف أي رقم.

الخطوة 1: يعني إيه "الموديل مخصّص صح"؟

التخصيص (Specification) = الشكل الرياضي اللي إنت افترضته.

في المحاكاة بتاعتنا، عملية D5 بتولّد البيانات من معادلة $ETS(A,A,A)$ — يعني مستوى + اتجاه + موسمية. وطريقة AutoETS هي بالضبط اللي بتفترض الشكل ده.

يعني إيه؟ يعني الشكل مضبوط 100%. مش تقريب ولا اجتهد — دي الحقيقة نفسها. الموديل عارف إن فيه مستوى، وعارف إن فيه اتجاه، وعارف إن فيه موسمية بفترة 12. كل ده صح.

فالمفروض يكسب، صح؟ ده اللي إحنا كمان توقّعناه وسجّلناه كفرضية H1.

الخطوة 2: بس الشكل الصح مش كفاية — لازم تعرف الأرقام
هنا المفتاح اللي بيغيّر كل حاجة.

معرفة الشكل حاجة، ومعرفة الأرقام اللي جوه الشكل حاجة تانية خالص. والأرقام دي إنت لازم تقدّرّها من البيانات اللي قدامك.

فخلينا نعدّ: ETS(A,A,A) بموسمية 12 — كام رقم لازم يتقدّر؟

اللي لازم يتقدّر	العدد
معاملات التنعيم: γ, β, α	3
المستوى الابتدائي ℓ_0	1
الاتجاه الابتدائي b_0	1
الحالات الموسمية الابتدائية (11 حرّة من 12)	11
الإجمالي	16 رقم

دلوقتي السؤال الحاسم: عندك كام نقطة بيانات عشان تقدّر الـ 16 رقم دول؟

- عند $n = 200$ ← عندك 12.5 نقطة لكل رقم. مرتاح جداً.
- عند $n = 24$ ← عندك 1.5 نقطة لكل رقم فقط!


تخيّل الموقف: إنت بتحاول تحدّد 16 مجهول من 24 معادلة. ده رياضياً ممكن بالعافية، بس البيانات فيها ضوضاء (noise)، فاللي بيحصل إن الموديل بيحفظ الضوضاء بدل ما يتعلّم النمط — وده اسمه **overfitting**. وبيطلع تنبؤ كارثي.

تشبيه: عندك وصفة أكل مضبوطة 100% من شيف عالمي — الوصفة بتقول "حط 16 نوع بهارات بنسب معيّنة". بس مطبخك فيه مكوّنين بس. الوصفة صح، إنما إنت مش قادر تنفّذها. والراجل اللي بيطبخ بالفطرة من غير وصفة أصلاً هيطلع أكل أحسن منك.

الخطوة 3: الفرق بين الاثنين في جملة

السؤال	التخصيص (Specification)	القابلية للتقدير (Estimability)
الشكل الرياضي صح؟	عندي بيانات تكفي أحدّد أرقامه؟	
بيعتمد على	العملية اللي ولّدت البيانات	طول السلسلة اللي قدامي
D5 على AutoETS	صح دائماً ✓	صح عند $n \geq 48$ ، فاشل عند $n = 24$

الخطوة 4: الدليل — نفس الموديل، من الأسوأ للأحسن



شكل 6 — ليه الموديل المخصص صح ممكن يقع. الشمال: AutoETS لازم يقدر 16 رقم؛ عند $n = 24$ عنده 1.5 نقطة لكل رقم (الأحمر) وعند $n = 200$ عنده 12.5 (الأزرق). اليمين: النتيجة — على D5 ، وهي العملية اللي AutoETS مخصص ليها صح، ببدا كارثة عند 3.03 (أسوأ واحد في الستة!) وينتهي الأحسن عند 0.68.

بص على الخط البرتقالي كويس: الموديل متغيرش. البيانات جاية من نفس العملية بالظبط. اللي اتغير هو طول السلسلة بس. ومع ذلك النتيجة اتقلبت من الأسوأ للأحسن.

والأرقام بالتفصيل عند $n = 24$:

الطريقة	MASE على D5 عند $n=24$	إيه اللي بتقدره؟
AutoETS	3.025 ← المخصص صح!	16 رقم من 24 نقطة
SeasonalNaive	1.139 ← أغبي قاعدة	صفر — مفيش حاجة تتقدر
TimesFM3	1.152	صفر — متدرب قبل كده

العمود الثالث هو التفسير كله. SeasonalNaive بتقول "النهاره زي نفس الشهر السنة اللي فاتت" — مفيش أي رقم بتقدره، فمفيش حاجة تغلط فيها. و TimesFM-3 كمان مبيقدرش حاجة من سلسلتك — هو جاي ومعاها معرفة مسبقه من تريليون نقطة. الاتنين محصنين ضد مشكلة قلة البيانات، و AutoETS مش محصن.

يعني AutoETS خسر بفارق 2.7 مرة قدام قاعدة من سطر واحد — على بيانات عملية ETS هي اللي ولدتها بنفسها!

الخطوة 5: نفس الحكاية في D4

مش حالة شاذة. في D4 (الموسمية الـ SARIMA) نفس الحاجة:

- عند $\text{AutoARIMA} = 2.284$: $n = 24$ ، و $\text{SeasonalNaive} = 1.029$. الكلاسيكي الأوتوماتيكي المخصص صح خسر قدام القاعدة الغبية.
- عند $\text{AutoARIMA} = 0.886$: $n = 200$ ، بقى الأحسن بفارق كبير.

نفس النمط: الشكل صح من الأول لآخر، بس القدرة على تقديره هي اللي بتتغير مع الطول.

الخطوة 6: وليه ده مهم عملياً؟

الفرضية H1 اللي سَجَلناها كانت بتقول: "الكلاسيكي هيكسب على أرضه، والفرق هيبقى أكبر في السلاسل القصيرة". طلعت **مفندة** — والفرق في السلاسل القصيرة راح في **الاتجاه المعاكس**.

والدرس اللي تاخده معاك:

السؤال مش "الموديل بتاعي صح؟" — السؤال "عندي بيانات تكفي أقدره؟"

وده بيقولك **فين** ال foundation models بتنفع بالضبط: **في المكان اللي التقدير الكلاسيكي فيه جعان بيانات**. مش لأنها "أذكى"، لكن لأنها **مش محتاجة تقدّر حاجة أصلاً** من سلسلتك — هي جاية ومعها المعرفة جاهزة.

وبالعكس: لما يبقى عندك بيانات كتير ومرتاحة، الكلاسيكي بيرجع يكسب — زي ما شفنا عند $n = 200$.

من الآخر: الموديل الصح + بيانات قليلة = نتيجة وحشة. والقاعدة الغيبة + صفر تقدير = نتيجة معقولة. ال foundation model بيلعب في الخانة الثانية دي — بيحسب نتيجة معقولة من غير ما يقدر أي حاجة.

Two Decisive Regimes 4.5 — النظامين اللي فيهم قرار واضح

أ) موسمية قوية + بيانات تكفي ← استخدم **AutoARIMA** عند $n = 48, 96, 200$ في **AutoARIMA**، **D4** أحسن بـ 21.8% و 21.1% و 23.7% على الترتيب، وكلها بـ p مصحّح عند > 0.0001 .

⚠ **وخد بالك من قراءة النسبة — دي غلطة شائعة.** النسبة 1.28 معناها إن **TimesFM-3** أسوأ بـ 28%، لكنها مش معناها إن **AutoARIMA** أحسن بـ 28%.

$$\underbrace{1.28 - 1 = 28\%}_{\text{TimesFM-3 worse by}} \neq \underbrace{1 - \frac{1}{1.28} = 22\%}_{\text{AutoARIMA better by}}$$

عشان كده بنقول **AutoARIMA** أحسن بـ 21-24%. والقاعدة العامة: لو **أ** أسوأ من **ب** بنسبة r ، يبقى **ب** أحسن من **أ** بنسبة $1 - \frac{1}{1+r}$ — وهي دائماً أصغر من r .

والتوصية بتنقلب عند $n = 24$! بدورتين موسميتين بس:

• أحسن طريقة كلاسيكية مش **AutoARIMA** أصلاً — دي (1.029) **SeasonalNaive**

• و **TimesFM-3** بيكسب على **AutoARIMA** بـ 42% (1.321 مقابل 2.284)

يعني نصيحة "استخدم ARIMA للموسمية" صح **بس بعد** ما يبقى الموديل الموسمي قابل للتقدير. تحت الحد ده هي نصيحة **وحشة**.

ب) الطلب المتقطع (D8) — الحكاية أعقد، والمقاييس بتتخاّنق

على **TimesFM-3**، **MASE**، بيقلّل الخطأ بـ 21.7% و 26.5% و 26.0% و 26.2% على الأطوال الأربعة، وكلها $p > 0.0001$.

وعلى الـ **pinball loss** كمان هو الأحسن في كل طول **من بين الطرق المسجلة مسبقاً** — وهنشوف في 9.8 إن الميزتين دول ليهم تفسير أبسط بكتير.

بس على RMSSE هو بيخسر في كل طول. وعلى **sMAPE** هو أوحش واحد في الستة بفارق كبير.

ليه؟ فيه ميكانيزم حقيقي مش صدفة:


70% من قيم **D8** أصفار. والقاعدة الرياضية بتقول:

- مقاييس **الخطأ المطلق** (زي **MASE**) بتتصغر عند الـ **median** بتاع التوزيع — وده هنا صفر أو قريب منه.
- مقاييس **الخطأ التربيعي** (زي **RMSSE**) بتتصغر عند الـ **mean** — وده أكبر من صفر بالتأكيد.

فالطريقة اللي بتتنبأ قريب من الـ **median** بتكسب MASE وتخسر RMSSE، والعكس صحيح. ودي بالضبط المصيدة اللي **Kolassa (2016)** وثّقها للطلب المتقطع في التجزئة.

من الآخر: في الطلب المتقطع، **مفیش رقم واحد بيحسم الموضوع** — اللي يحسمه هو دالة الخسارة اللي قرارك التجاري بيواجهها فعلاً.

(القاعدة دي متحسوبة على بياناتنا نفسها ومرسومة في **الجزء 8.6**. مع الطرق المتخصصة للطلب المتقطع.)



شكل 4 — الدقة حسب طول الأفق، مقسومة على النظامين. الشمال: العمليات اللي فيها موديل كلاسيكي صح (D1 - D5). اليمين: اللي مفياهاش (D6 - D9). كل الطرق بتسوء كل ما الأفق يطول — وده طبيعي.

⚠ **بس خد بالك من قراءة غلط هنا: TimesFM-3** مبين الأقل في **اللوحتين**، وده مش بيناقض إن الكلاسيكي كسب سيناريوهات أكثر — لأن **المتوسط** بيخلط السيناريوهات اللي الكلاسيكي كسبها بالسيناريوهات اللي وقع فيها، وسيناريو واحد كارثي (زي **Theta** بـ 4.16 على **D4**) بتحرك المتوسط أكثر بكثير من كذا مكسب صغير.

4.6 Interval Reliability — ثبات الفترات: هل الـ 80% فعلاً 80%؟

كلمة عن المصطلح الأول: الموديل مايبديكش رقم واحد بس — بيديك كمان **فترة** (interval) ومعاها **وعد**. وعد إيه؟ إن الحقيقة هتقع جوه الفترة دي بنسبة معيّنة من المرات. اختبار الوعد ده اسمه **المعايرة** (calibration)، وهو المقصود بـ **ثبات الفترة** هنا: الفترة اللي مكتوب عليها 80% — هل بتوفي بالـ 80% فعلاً؟

الخطوة 1: التغطية مش رأي — دي عدّة


نسبة التغطية (coverage) مش حاجة نظرية تتناقش. دي **حاجة تتعدّ بالإيد**:

شوف كذا حالة تنبؤ، وفي كل حالة بص: الحقيقة وقعت **جوه** الفترة ولا **بره**؟ اقسم عدد اللي جوه على العدد الكلي.

وخلص. لو الموديل صادق في وعده، الرقم ده لازم يطلع قريب من 0.80.

الخطوة 2: نعدّها بنفسنا

خدنا 20 حالة تنبؤ حقيقية من عملية D6 (الكسر الهيكلي) عند $n = 96$ ، على أفق 12 خطوة، ورسمنا لكل حالة الفترة اللي الموديل قال عليها 80%، وطينا الحقيقة جواها أو بره.



شكل 8 — التغطية والعرض، بالعدّ والأرقام. (أ) TimesFM-3: الحقيقة وقعت جوه الفترة في 18 من 20 حالة = 90%، بمتوسط عرض 11.5. **(ب) AutoARIMA:** على نفس الحالات بالظبط: 20 من 20 = 100% — بس بفترة أعرض 1.8 مرة (20.2 مقابل 11.5). **(ج) الانحراف عن الـ 0.80 المطلوبة:** الرمادي لو حسب المتوسط الأول، والمملون هو الانحراف الحقيقي لكل سيناريو. **(د) على D6:** التغطية على المحور الرأسي والعرض على الأفقي. الكلاسيكي كله متجمع فوق على اليمين — تغطية شبه كاملة، بأوسع الفترات.

الخطوة 3: طب مش AutoARIMA كده أحسن؟ لأ.
هنا المصيدة اللي القسم ده كله عنه.

AutoARIMA مسك كل الحالات — 100%. ودي على ورق تبان أحسن من 90%. بس افكر: الوعد كان 80%، مش 100%. الموديل اللي بيغطي 100% وهو واعد بـ 80% مش دقيق زيادة — هو بيكذب في الاتجاه الثاني: بيقولك "أنا مش متأكد" أكثر مما هو فعلاً مش متأكد.

وإزاي عمل كده؟ بانه وسّع الفترة. الفترة الواسعة بتمسك كل حاجة — لأنها بتشمل كل حاجة.

التشبيه: لو قتللك "بكرة الجو هيبقى بين 50- و 80+ درجة" — كلامي هيطلع صح 100% من المرات. وهيبقى بلا فائدة 100% من المرات كمان. مقدرش أخطّط ليوم بكرة بالمعلومة دي.

القاعدة: رقم التغطية لوحده **مايتقريش**. لازم تبص عليه **مع عرض الفترة**. تغطية 100% بفترة ضعف العرض = خسارة، مش مكسب.

الخطوة 4: والفخ الثاني — المتوسط بيداري الانحراف

النظرة المتوسطة (على العمليات التسعة): تغطية TimesFM-3 للفترة 80% بتفضل بين 0.802 و 0.834 عبر كل الأطوال — أقرب للمطلوب من أي طريقة ثانية. بينما SeasonalNaive بتنجرف من 0.777 عند $n=24$ ل 0.869 عند $n=96$.

بس الرقم ده مجاملة للكل. ليه؟ لأن لما تاخد **متوسط** التغطية عبر تسع عمليات مختلفة، العملية اللي فيها تغطية 0.95 (زيادة) بتلغي العملية اللي فيها 0.65 (نقص)، والمتوسط بينهم يطلع 0.80 — **رقم مثالي من موديل بيغلط في الاتجاهين!** المقياس الأمين هو إنك تحسب الانحراف **في كل سيناريو لوحده الأول** (بالقيمة المطلقة، عشان الزيادة والنقص مايلغوش بعض)، **وبعدين** تاخد المتوسط. والفرق بين الطريقتين **حوالي 3 أضعاف:**

الطريقة	لو حسبت المتوسط الأول (مجامل)	الانحراف الأمين لكل سيناريو	الفرق
TimesFM3	0.015	0.047	3.2×
AutoARIMA	0.021	0.066	3.1×
Combination	0.032	0.089	2.8×
AutoETS	0.021	0.101	4.8×
Theta	0.040	0.127	3.2×
SeasonalNaive	0.038	0.144	3.8×

الترتيب متغيّرش و TimesFM-3 فضل الأحسن معايرةً — **بس المستوى مش قريب من المطلوب:** تغطيته لكل سيناريو بتتراوح من 0.583 ل 0.921! يعني فيه سيناريو بيوعده فيه ب 80% وبيوفي 58% بس، وسيناريو ثاني بيوفي فيه 92%. **مفيش ولا طريقة** في الدراسة دي بتدي فترات 80% موثوقة عبر العمليات التسعة.

الخطوة 5: الحالة اللي بتوضح كل حاجة — الكسر الهيكلي (D6)


التغطية (المطلوب 0.80)	عرض الفترة (مقيس)	
0.966 - 0.999	4.81 - 10.36	كل الطرق الكلاسيكية
0.828 - 0.889	3.00 - 5.07	TimesFM3

بصّ للكلاسيكي: تغطية 99.9%؟! ده مش "ثبات" — ده **عرض مرضي**. الكسر الهيكلي بيضخّم تقدير التباين، فالفترات بتبقى **ضخمة**. هي بتحتوي الحقيقة دايماً لأنها بتحتوي **كل حاجة**.

TimesFM-3 بيغطي 82.8-88.9% (فوق المطلوب برضه) بفترات **نص العرض تقريباً**. الاتنين بيزودوا، بس واحد بيزود **شوية** والثاني بيزود لدرجة إن الفترة بقت بلا معنى.

الخطوة 6: اللي تاخده معاك

1. التغطية حاجة تتعدّ، مش تتفلسف. جوه ولا بره، واقسم.
2. 80% معناها 80% — مش 100%. الزيادة غلط زي النقص بالظبط.
3. عمرك ما تقرا تغطية من غير عرض جنبها.
4. متوسط التغطية بيداري. اطلب الانحراف لكل سيناريو — هتلاقيه حوالي 3 أضعاف.
5. في الدراسة دي: **TimesFM-3** الأحسن معاييرةً، ومحدثش فيهم كويس بما فيه الكفاية.



شكل 3 — التغطية الفعلية للفترات مقابل المطلوب (الخط المتقطع)، بمتوسط على العمليات التسعة. لاحظ إن **TimesFM-3** ماشي على الخط المطلوب تقريباً في كل الأطوال، بينما الكلاسيكي **بيقصّر** عند $n = 24$ و**بيزود** من $n = 96$ ⚠. وده **المتوسط** اللي اتكلمنا عنه في الخطوة 4 — الانحراف الحقيقي لكل سيناريو أكبر 3 مرات، زي ما في شكل 8 (ج).

درجة الفترات (interval score) — تحليل بعدي: بدل ما نبص على التغطية لوحدها، حسبنا **interval score** — بيكافئ الفترة الضيقة وبيعاقب لما القيمة الحقيقية تطلع برّه. **TimesFM-3** طلع الأحسن في 22 من 36 سيناريو، ومنهم كل أطوال **D6** (الكسر الهيكلي): تغطية معقولة بفترات قد نص عرض فترات الكلاسيكي.

The Hypotheses, Judged 4.7 — حكم الفرضيات

#	المتوقع	الحكم	الدليل
H1	الكلاسيكي الصح يكسب في D1 - D5 ، أكثر عند n صغير	✗ مش مدعومة	عند $n = 24$ الفرق يبروح بالعكس؛ الكلاسيكي ييكسب بس لما الموديل كمان قابل للتقدير (D4 و D5 من $n = 48$)
H2	يكسب في TimesFM-3 D6 - D8	⚠ جزئياً	شوية في الكسر الهيكلي؛ في اللوجستي حسب الطول؛ في المتقطع قدام الكلاسيكي بس، مش قدام معايير التاريخ
H3	تعادل في المتوسط : D9 والكلاسيكي يقصّر	⚠ جزئياً	التعادل صح، بس AutoARIMA لوحده اللي يقصّر
H4	الدمج يكسب الكل وهو أصعب خصم	✗ متناقضة في الشقين	أدق منه، وهو الخصم الأصعب (9-11 مقابل AutoARIMA 3-27)
H5	الطرفين يقصّروا، TimesFM-3 و أكثر مع الأفق	✗ مش مدعومة	قريب من المطلوب في المتوسط TimesFM-3 ومايسوءش جوه الـ 12 خطوة؛ الكلاسيكي بيزود من $n = 96$

النقطة المهمة: إن **ولا فرضية** نجت سليمة هو أقوى حجة للتسجيل المسبق — لو الفرضيات اتكتبت **بعد** النتائج، الجدول ده كان هيبّلغ 5 تأكيدات.

5. Post-hoc Analyses — التحليلات البعدية

كل اللي في القسم ده اتصمّم **بعد** ما نتايج القسم 4 ظهرت — أغلبه ردّاً على أسئلة المحكّمين — ومتسجّل كانحراف عن البروتوكول. بنفصله عن القسم 4 عشان القارئ يعرف دايمًا: ده **مسجّل مسبقاً** ولا **بعدي**.

5.1 Precision of the Numbers — دقة الأرقام نفسها

الدقة الإحصائية للأرقام نفسها (Monte Carlo): كل متوسط MASE في سيناريو ليه خطأ معياري بين 1.5% و 6.2% من قيمته. وبال bootstrap: أسوأ نسبة لـ TimesFM-3 = 1.31 (1.28-1.36) ، ولـ AutoARIMA = 2.22 (2.05-2.38) — يعني الفرق **حقيقي** مش صدفة. أما عدد السيناريوهات اللي كسبها (16) TimesFM-3 ففترته من 13 لـ 20 — فمانقدرش نبني حاجة على "16 مقابل 20".

فترات ثقة "متزامنة": الفترة العادية لكل سيناريو بتغطّي 95% **لوحدها**؛ بس لو بصّيت على 36 سيناريو مع بعض، فرصة إن واحدة على الأقل تغلط بتكبر. فحسبنا فترات **متزامنة** (max-t) بتضمن الـ 95% للمجموعة كلها. طلعت **أعرض بحوالي 1.9 مرة** — فقدام AutoARIMA بيفضل 8 سيناريوهات لصالح TimesFM-3 و 4 ضده بدل 11 و 9. بس **الاتجاه** ماتغيّرش قدام أي منافس.

5.2 Implementation and Configuration Checks — فحص التنفيذ والإعدادات

إعدادات TimesFM-3 ومخرجاته: - الورقة كانت بتستخدم الإعدادات الافتراضية للمكتبة. بإعدادات المطوّرين نفسها (positivity + averaging symmetric) أسوأ نسبة بتتحسّن من 1.31 لـ 1.27 — ومفيش استنتاج بيتغيّر. - المخرجات سليمة: 9 كوانتايلات بالظبط، والتنبؤ النقطي = الوسيط بالظبط، والتقاطع بين الكوانتايلات بيحصل بس في D8. - ولما **أديناه الشهر كمعلومة إضافية (covariates)** — نفس المعلومة اللي الكلاسيكي بياخذها — **ماتحسنش**، بالعكس اتدهور شوية في 7 من 8 سيناريوهات. يعني تفوّق AutoARIMA الموسمي **مش** بسبب إنه واخذ معلومة زيادة.

هل المشكلة في المكتبة؟ جربنا نفس الطرق في R: محكم سأل: يمكن فشل AutoETS و Theta جاي من مكتبة Python (StatsForecast) مش من الطريقة نفسها؟ فأعدنا D4 و D5 بمكتبة forecast في R — المرجع الأصلي للطرق دي. R كثر كل الإخفاقات (وأحياناً أسوأ). بس لقينا حالة واحدة الغلط فيها من المكتبة: AutoETS في D4 عند $n = 96$ — في Python طلع 2.41 وفي R 1.04، لأن ال optimizer بتاع Python وقف عند حل ضعيف. وده اتقال في الورقة بوضوح.

Was the Combination a Straw Man — هل ال Combination كان خصم ضعيف؟

TimesFM-3 كسب على ال Combination في 27 من 30 مقارنة معنوية. وقبل ما نفرح بالرقم ده، فيه اعتراض وجيه لازم نرد عليه. بس الأول لازم نفهم ال Combination ده إيه أصلاً.

الخطوة 1: يعني إيه "Combination"؟

فكرة قديمة وبسيطة: بدل ما تختار طريقة واحدة، خذ أكثر من طريقة واحسب متوسط تنبؤاتهم.

في دراستنا ال Combination بياخد ثلاث طرق — Theta و AutoETS و AutoARIMA — ويحسب متوسط تنبؤاتهم بأوزان متساوية. (SeasonalNaive مش فيه).

الخطوة 2: وليه المتوسط ده يبساعد أصلاً؟

لأن الطرق الثلاثة بتغلط في اتجاهات مختلفة. واحد بيزود، والتاني بيقلل، فلما تجمعهم على 3 الأخطاء بتلغي بعضها جزئياً. ده مبدأ قديم في التنبؤ اسمه error cancellation.

وده مش كلام نظري — ده حصل عندنا في كل سيناريو بلا استثناء:

الدمج بالمتوسط طلع أحسن من متوسط أعضاءه في 36 من 36 سيناريو.

يعني الدمج بيدي قيمة حقيقية، مش مجرد جمع أرقام.

بس خد بالك من التفصيلة دي: الدمج بيكسب على العضو المتوسط، لكنه مش بيكسب على أحسن عضو — كسب على أحسن عضو في 4 سيناريوهات بس من 36. يعني الدمج مش سحر؛ هو تأمين ضد إنك تختار غلط، مش طريقة لتبقى الأحسن.

الخطوة 3: الاعتراض (وهو وجيه فعلاً)

المراجعة قالت: "المتوسط مش محصن ضد عضو بايظ. عندكم Theta بيقع بشكل كارثي في سيناريوهات معينة (زي D4 بـ $MASE = 4.15$) — يبقى المتوسط بتاعكم مسحوب لتحت بسببه، وانتوا بتقارنوا TimesFM-3 بخصم إتنوا اللي أضعفتوه."

الاعتراض ده منطقي 100%. لو الوسيط (median) بدل المتوسط، هيبقى محصن: عضو واحد يقع مايأثرش.

الخطوة 4: فجرّبناه فعلاً — والنتيجة عكس المتوقع

أعدنا المقارنة كلها ضد combination بالوسيط بدل المتوسط، بنفس الأعضاء ونفس السيناريوهات:

متوسط MASE على الـ 36 سيناريو	
1.439	TimesFM-3
1.656	الدمج بالمتوسط
1.712 ← أسوأ!	الدمج بالوسيط (المفروض المحصّن)


والوسيط طلع أحسن من المتوسط في 8 سيناريوهات بس من 36.

الخطوة 5: طب ليه؟ دي أهم نقطة في القسم
السبب حسابي وبسيط جداً، ومربوط بعدد الأعضاء:

الـ Combination عندنا 3 أعضاء. ووسيط 3 أرقام = الرقم اللي في النص.

يعني لما تقول "خد الوسيط بدل المتوسط"، إنت فعلياً بتقول: "خد تنبؤ واحد وارمي الاثنين التانيين".

وده بالضبط بيلغي السبب اللي خلاك تدمج من الأول! الدمج بيشغل لأن الأخطاء بتلغي بعضها — ولما تسيب عضو واحد بس، مافيش حاجة تلغي حاجة. إنت اشتريت الحماية من عضو بايظ، ودفعت تمنها آلية الدمج كلها.



شكل 9 — ليه "الدمج المحصّن" خسر. (أ) سيناريو واحد بالتفصيل (D5, n=24): الأعضاء الثلاثة (رمادي)، الدمج بالمتوسط 2.47 — أحسن من متوسطهم (2.58) ✓، والدمج بالوسيط 2.98 — اللي هو (3.03) AutoETS تقريباً بالضبط X. (ب) نفس المقارنة على الـ 36 سيناريو: النقط تحت القطر معناها الوسيط أحسن — 8 بس. (ج) البرهان: الدمج بالوسيط بيقع على قطر "العضو الأوسط لوحده" (متوسط الفرق 0.059 بس)، بينما الدمج بالمتوسط بعيد عنه (0.172). يعني الوسيط ما بيدمجش — بيختار.

الخطوة 6: والخلاصة

TimesFM-3 كسب على الدمج بالوسيط في 25 من 29 مقارنة معنوية — يعني الاعتراض مش بيغيّر النتيجة:

- لو قارناه بالدمج بالمتوسط: TimesFM-3 كاسب.
- لو قارناه بالدمج بالوسيط (المحصّن): TimesFM-3 كاسب برضه، ويفارق أوسع شوية.

فتفوّق الموديل على الدمج مش ناتج عن طريقة تكوين الدمج. الاعتراض اتقفل.

والدرس اللي يتاخذ بره الورقة دي: "استخدم الوسيط عشان يبقى محصّن" نصيحة كويسة — **لما يكون عندك أعضاء كثير**. مع 3 أعضاء بس، الوسيط بيرمي ثلثين البيانات. عدد الأعضاء جزء من القرار.

(والتحليل ده بعدي/post-hoc — عملناه بعد ما شفنا النتائج، ردّا على المراجعة، ونبلّغه صراحةً.)

Stronger Benchmarks and Other Foundation Models 5.3 — طرق أقوى وموديلات أساس تانية

طرق كلاسيكية أقوى — والنتيجة ماتغيرتش: ضفنا DOTM (نسخة محسّنة من Theta)، ومعيار Comb بتاع مسابقة M4، ودمج تاني. ولا واحد فيهم بقى أمتن: DOTM أسوأ نسبته 4.66، وال 4.45 Comb — وال اثنين بيوقعوا في نفس السيناريو اللي Theta بيوقع فيها (D4 عند $n = 200$)، لأنهم كلهم ييفترضوا نمط موسمي ثابت، والعملية دي نمطها الموسمي بيتحرك.

★ **موديلات أساس تانية — والمتانة طلعت خاصة بـ TimesFM-3:** ضفنا TimesFM-2.5 و Chronos-Bolt :

الموديل	أسوأ نسبة لأحسن طريقة
TimesFM-3	1.31
TimesFM-2.5	2.18
AutoARIMA	2.22
Chronos-Bolt	3.06


يعني: المتانة مش صفة في "الموديلات الأساس" كفتة — دي صفة في TimesFM-3 بالذات. وده بالظبط اللي الإطار الاستكشافي كان متوقّعه: بنوصف سلوك موديل معيّن، مش قانون عام.

★ **موديلات أحدث:** ضفنا Chronos-2 و TiRex (أحدث من Chronos-Bolt)، وشغلنا TimesFM-2.5 كمان بنفس إعدادات TimesFM-3 بالظبط عشان المقارنة تبقى عادلة:

الموديل	أسوأ نسبة لأحسن طريقة
TimesFM-3	1.31
TimesFM-2.5	2.18 (وبنفس إعدادات TimesFM-3 : 2.26)
TiRex	2.24
Chronos-2	2.75
Chronos-Bolt	3.06

يعني: حتى مع خمس موديلات أساس، المتانة لسه خاصة بـ TimesFM-3 — ومش بسبب الإعدادات.

الصورة الكاملة في رسمة واحدة:



إزاي تقراها؟ كل نقطة طريقة من الخمستاشر. المحور الأفقي = الأداء المعتاد (قد إيه بعيد عن الأحسن في المتوسط)، والرأسي = أسوأ سيناريو. تحت وشمال = أحسن في الاتنين. TimesFM-3 (بالإعدادين) قاعد لوحده في الركن ده؛ الموديلات الأساس الثانية متجمعة مع AutoARIMA عند حوالي 2.2.

Intermittent Demand Re-examined 5.4 — الطلب المتقطع من تاني

المراجعة قالت لنا حاجة وجيهة: "مجموعة المقارنة بتاعتكم مفيهاش ولا طريقة متصممة للطلب المتقطع!" وده اعتراض عادل — Croston وعيلته موجودين بالظبط للحالة دي.

فضفناهم: CrostonClassic , CrostonOptimized , CrostonSBA , ADIDA , IMAPA , TSB — بنفس ال seeds ونفس ال 200 تكرار.

والنتيجة طلعت غريبة لأول وهلة: TimesFM-3 كسب عليهم كلهم على مقياس، وخسر قدامهم كلهم على مقياس ثاني — بنفس التنبؤات بالظبط. الجزء ده بيشرح ليه ده حصل، وليه هو مش تناقض أصلاً.

الخطوة 1: يعني إيه "طلب متقطع"؟

تخيل إنك بتبيع قطع غيار. أغلب الأيام مبتبعش ولا قطعة، وفجأة بيجي يوم تباع 5 أو 6. دي عملية D8 بتاعتنا.

خد الأرقام الحقيقية من المحاكاة (200 تكرار × 200 نقطة = 42,400 مشاهدة):

الخاصية	القيمة
نسبة الأيام اللي المبيعات فيها صفر	69.8%
متوسط الطلب (mean)	1.51
وسيط الطلب (median)	0

بصّ على آخر سطرين كويس. المتوسط 1.51 والوسيط صفر. في بيانات عادية الاتنين بيقوا قريبين من بعض؛ هنا بعد خالص. والبُعد ده هو اللي هيوَلد كل اللي جاي.

الخطوة 2: السؤال اللي بيقلب كل حاجة — "أحسن تنبؤ" مش رقم واحد
خليني أسألك سؤال بسيط:

لو **مجبور** تديني رقم واحد ثابت تتنبأ بيه لكل الأيام الجاية — تقول إيه؟

الإجابة الطبيعية: "أقول 1.51، ده المتوسط." تمام. بس **استنى** — الإجابة الصح بتعتمد على إنت هتتألف إزاي. فيه طريقتين مشهورتين للمحاسبة:

- **خطأ مطلق** (absolute error): بتجمع $|actual - forecast|$. ده اللي **MASE** مبني عليه.
- **خطأ تربيعي** (squared error): بتجمع $(actual - forecast)^2$. ده اللي **RMSSE** مبني عليه.

طب يعني إيه الفرق؟ التربيع بيعاقب الأخطاء الكبيرة بعنف. لو غلطت بـ 2 بدل 1، الخطأ المطلق بيتضاعف (من 1 لـ 2)، لكن التربيعي بيتربّع أربع مرات (من 1 لـ 4). فالمقياس التربيعي بيخاف من اليوم اللي المبيعات فيه 6 أكثر بكثير ما بيعتم بالـ 70% أيام اللي فيها صفر.

وخيلنا نحسبها فعلاً بدل ما نتكلم. هنجرب أرقام مختلفة للتنبؤ الثابت ونشوف كل مقياس بيفضّل مين:




التنبؤ الثابت	الخطأ المطلق	الخطأ التربيعي
0 (= الوسيط)	1.510 ← الأقل	8.775
0.5	1.708	7.515
1.0	1.906	6.755
1.51 (= المتوسط)	2.115	6.496 ← الأقل
2.0	2.315	6.736
3.0	2.768	8.717

دي الفكرة كلها في جدول واحد. المقياسين مش بيختلفوا في التقدير — دول عايزين إجابتين مختلفتين حرفياً:

- الخطأ المطلق بيوصل لأقل قيمة عند **صفر** — يعني بيقولك: "قول صفر، لأن 70% من الأيام فعلاً صفر."
- الخطأ التربيعي بيوصل لأقل قيمة عند **1.51** — يعني بيقولك: "لأ، قول المتوسط، عشان تغطي أيام الـ 5 و 6 اللي هتأذي." هتأذي.

ودي مش صدفة في بياناتنا؛ دي **قاعدة رياضية معروفة**: الخطأ المطلق أقل ما يكون عند **الوسيط**، والخطأ التربيعي أقل ما يكون عند **المتوسط**. في البيانات العادية الاتنين قريبين فمحدث بيلاحظ. في الطلب المتقطع الاتنين بعداً جداً، فالفرق يبقى صارخ.

الخطوة 3: شوفها بعينك



شكل 7 — له المقياسين بيختلفوا على الطلب المتقطع. (أ) شكل الطلب في D8: عمود واحد ضخمة عند الصفر (69.8%)، وديل صغير ممتد لغاية 14. الوسيط (برتقالي) عند 0 والمتوسط (أخضر) عند 1.51. (ب) البرهان: بنجرب كل تنبؤ ثابت c من 0 لـ 4 ونرسم الخسارتين. الخط البرتقالي (خطاً مطلق) يلمس القاع عند صفر، والخط الأزرق (خطاً تربيعي) يلمس القاع عند 1.5. نقطتين مختلفتين — يعني مافيش تنبؤ واحد يرصّي الاثنين. (ج) النتيجة على تنبؤاتنا الحقيقية: نسبة خطأ TimesFM-3 لخطأ أحسن طريقة من عيلة Croston. تحت خط الـ 1.0 يعني TimesFM-3 أحسن؛ فوقه يعني Croston أحسن. المقياس المطلق بيحطه تحت الخط في كل طول، والتربيعي بيحطه فوق الخط في كل طول.

الخطوة 4: الأرقام بالتفصيل

طول السلسلة	Croston أحسن ÷ TimesFM-3 MASE	Croston أحسن ÷ TimesFM-3 RMSSE
n = 24	0.80 ✓	1.07 X
n = 48	0.75 ✓	1.08 X
n = 96	0.75 ✓	1.12 X
n = 200	0.74 ✓	1.13 X

على TimesFM-3 : MASE كسب على الستة كلهم في الأطوال الأربعة — 24 من 24 مقارنة معنوية. أحسن منافس متخصص كان TSB عند n=96 بـ 0.916، مقابل 0.683 لـ TimesFM-3 .

على ADIDA : RMSSE و CrostonSBA سجلوا الأقل في كل طول (0.694–0.769) مقابل 0.774–0.806 لـ TimesFM-3 .

والسبب دلوقتي واضح: طرق Croston متصممة من أساسها إنها تقدر معدل الطلب المتوسط (mean demand rate) — يعني هي بتصوّب على المتوسط، وده بالضبط اللي الخطأ التربيعي بيكافئه. و TimesFM-3 بيطلع تنبؤ أقرب لسلوك الوسيط على البيانات دي، وده اللي الخطأ المطلق بيكافئه.

فالطرفين مش بيتنافسوا على نفس الهدف أصلاً. كل واحد بيكسب تحت المقياس اللي بيوافق الحاجة اللي هو بيصوّب عليها. مفيش حد منهم غلط — الغلط الوحيد الممكن هنا هو إنك تختار المقياس بعد ما تشوف النتيجة.

فالاكتراض اتقفل: الموديل مش بس بيكسب على الطرق العامة — هو بيكسب على الأدوات المتخصصة كمان وبفارق قريب من فارقته على الطرق العامة (أقل بـ 19.6–25.7% من أحسن طريقة Croston، مقابل 21.7–26.5% من أحسن طريقة عامة)، لكن على المقياس التربيعي بيخسر لهم.

الخطوة 5: طب أنا في شغلي أختار مين؟ القرار مش إحصائي، ده قرار محاسبي. اسأل نفسك: تكلفة الغلطة عندك بتكبر إزاي؟

لو التكلفة عندك...	يبقى قياسك	واختارك
خطية — كل قطعة ناقصة بتكلفتك نفس المبلغ (مثلاً 10 جنيه للقطعة، سواء نقصت 1 أو 10)	خطأ مطلق (MASE)	TimesFM-3
تربيعية — النقص الكبير بيكلفك أضعاف النقص الصغير (خط إنتاج يوقف، عميل بيمشي، غرامة تأخير)	خطأ تربيعي (RMSSE)	Croston-SBA / ADIDA

مثال يوضح الفرق: لو عندك مسمار سعره جنيه وناقصك 10 مسامير، خسرت 10 جنيه — دي **خطية**. لكن لو عندك قطعة غيار لماكينة، ونقصانها بيوقف المصنع يوم كامل، فنقص قطعتين **مش ضعف** خسارة قطعة واحدة — دي **تربيعية** (أو أسوأ).

القاعدة: حدّد شكل تكلفتك **الأول**، وهو اللي هيحدّد المقياس، والمقياس هو اللي هيحدّد الطريقة. مش العكس.

★ ★ **الطلب المتقطع — تصحيح كبير:** المحكّم الأول سأل سؤال بسيط: "جربتوا تنبأوا بصفر؟"

الطريقة (D8)	MASE	الانحياز	periods in stock
تنبؤ "صفر" دائماً	0.668-0.718 (الأحسن!)	-0.67 ل -0.72	-81 ل -91
(الوسيط) TimesFM-3	0.683-0.780	-0.57 ل -0.67	-74 ل -81
(متوسط الكوانتايلات) TimesFM-3	0.915-1.002	قريب من صفر	معقول

يعني إيه؟ الـ MASE بيكافئ **الوسيط**، ووسيط الطلب المتقطع = **صفر** تقريباً. فـ "تفوّق" TimesFM-3 على Croston في MASE (اللي في 4.5 و5.4) كان في الحقيقة **تفوّق تنبؤ قريب من الصفر** — وده في الواقع معناه **نفاد مخزون مستمر**. فالنتيجة دي مابقتش بتتقدّم كدقة مفيدة.

وفي الجولة الثانية من المراجعة، اتسأل السؤال اللي بعده: "طب جربتوا الماضي نفسه؟" — يعني من غير أي موديل: **خُد العُشيرات (deciles) بتاعة التاريخ كتوزيع تنبؤي، ومتوسط التاريخ كنتنبؤ نقطي.**

الطريقة (D8)	pinball (SPL)	RMSSE
عُشيرات التاريخ + متوسطه	0.282-0.314	0.692-0.744
TimesFM-3	0.288-0.325	0.694-0.760 (بمتوسط الكوانتايلات)
أحسن طريقة كلاسيكية (فترات جاوسية)	0.341-0.380	—

يعني إيه؟ الـ 15% اللي TimesFM-3 كان بيكسبها في الـ pinball كانت **قدام فترات جاوسية** — فترات بتدي احتمال لطلب **سالب**، وده مستحيل في عدّ الطلب. أول ما اتقارن بتوزيع الماضي البسيط، **اتعادل أو خسر شوية** في كل الأطوال.

ليه ده منطقي؟ **D8** عملية مستقلة عبر الزمن — كل فترة ملهاش علاقة باللي قبلها. فأحسن حاجة تعملها إنك توصف الماضي كويس، وده تقريباً اللي **TimesFM-3** بيعمله.

من الآخر للطلب المتقطع: مفيش ميزة لـ **TimesFM-3** قدام معايير بسيطة من التاريخ نفسه. ميزته قدام الكلاسيكي كانت بسبب الفترات الجاوسية بتاعة الكلاسيكي، مش بسبب فهم خاص للطلب المتقطع. والعملية دي مستقلة عبر الزمن — أسهل حالة ممكنة للمعايير اللي بتعتمد على التاريخ.

وموديل مخصوص للطلب المتقطع؟ جربنا **iETS** (موديل حالة للطلب المتقطع ببيختار احتمال الطلب لوحده)، وكمان توزيع ذي الحدين السالب وتوزيع TSB المركب. **iETS** طلع أحسن من **TimesFM-3** في الـ pinball في كل الأطوال — بس قد عُشيرات التاريخ بالضبط، لأنه في 791 من 797 سلسلة اختار احتمال طلب ثابت، يعني رجع عملياً لتوزيع التاريخ. والتوزيعين التانيين أسوأ من التاريخ. الخلاصة ماتغيرتش: في عملية مستقلة عبر الزمن، توزيع الماضي هو المعيار اللي لازم تغلبه.

5.5 Randomised Parameters and Departures — قيم عشوائية وبيانات مش مثالية

ربط باللي فات: في القسم 4 طلعنا نتائج واضحة: **TimesFM-3** بيشتري المتانة مش الدقة القصوى، و **AutoARIMA** بيكسب في الموسمية لما الدورات تكفي، والمقاييس بتتخاق في الطلب المتقطع. بس كل ده اتعمل على 9 عمليات، كل عملية ليها قيم بارامترات ثابتة — يعني **D1** مثلاً دايماً $\phi = 0.7$.

فأني محكّم محترم هيسأل أسئلة زي دي:

1. السلاسل المولدة دي شبه البيانات الحقيقية ولا عايشة في عالم لوحدها؟

2. لو غيّرنا القيم، أو البيانات مابقتش "نضيفة" — النتائج هتفضل زي ما هي؟

3. الأرقام دي دقيقة قد إيه؟ ولو جربنا طرق أقوى أو موديلات أساس تانية؟

القسم ده بيجابوب بالأرقام. وخلي بالك: كل التحليلات هنا بعدية (post hoc) — اتصمّمت بعد ما النتائج الأساسية ظهرت، ومسجلة كده في **DEVIATIONS.md** (من **D-10** لـ **D-14**)؛ المقارنة المسجلة مسبقاً هي اللي في القسم 4.

تشبيه: تخيل شركة عربيات جربت العربية على طريق واحد بس — أسفلت ناعم، جو معتدل، سرعة 80. العربية طلعت ممتازة. الأسئلة الطبيعية: الطريق ده شبه الطرق اللي الناس بتسوق عليها فعلاً؟ ولو فيه مطبات أو مطر أو السواق مايعرفش الطريق؟ وهل العربيات التانية من نفس الفئة هتعمل زيها؟ القسم ده هو التجربة على طرق تانية ومع عربيات تانية.

Why Fixed Values Are a Risk — ليه القيم الثابتة مخاطرة؟

لما **D1** دايماً $\phi = 0.7$ ، النتيجة بتقولك إيه اللي بيحصل عند 0.7 بالضبط. طب لو $\phi = 0.95$ (عملية قريبة جداً من حدود الاستقرار؟ أو $\phi = 0.2$ (شبه ضوضاء؟) ممكن الترتيب يتقلب.

والقيم الثابتة ليها عيب تاني: كل عملية بتطلع سحابة صغيرة ومتلّمة من السلاسل المتشابهة. فالمسافات بين السحابات دي — واللي فيها سلاسل حقيقية كتير — مفيهاش أي سلسلة متجربة.

من الآخر: القيم الثابتة بتديك إجابة دقيقة على سؤال ضيق. عشان نوسّع السؤال لازم نغيّر القيم.

Randomised Parameters — كل سلسلة بقيمها الخاصة

الفكرة: بدل $\phi = 0.7$ لكل سلاسل **D1**، كل سلسلة بتسحب قيمها بنفسها عشوائياً من مدى واسع. وكل مدى جواه القيمة الثابتة القديمة — يعني التصميم القديم حالة خاصة من الجديد.

العملية	المدى الجديد (توزيع منتظم)	ليه المدى ده
D1 AR(1)	من 0.10 لـ 0.95 ϕ	بيوصل لقرب حدود الاستقرار
D2 ARMA(1,1)	لـ 0.8 -0.6 من θ ، من 0.10 لـ 0.90 ϕ	يشمل θ سالبة
D3 ARIMA(1,1,1)	لـ 0.6 drift، من 0 لـ 0.6 -0.5 من θ ، لـ 0.8 -0.5 من ϕ	
D4 SARIMA	من 0.1 لـ 0.8، سعة الموسمية من 5 لـ 20 و Φ و ϕ	موسمية ضعيفة لحد قوية
D5 ETS(A,A,A)	من 0.05 لـ 0.3 γ ، من 0.001 لـ 0.03 β ، من 0.05 لـ 0.5 α	
D6 كسر هيكلي	حجم الكسر من 3 لـ 15 انحراف معياري، بإشارة عشوائية، ومكانه من 50n.0 لـ 85n.0	كسور صغيرة صعب تتشاف لحد كبيرة واضحة
D7 نمو لوجستي	من 0.04 لـ 0.15، نقطة الانقلاب من 0.4 لـ 0.8 من طول السلسلة r	
D8 طلب متقطع	احتمال الطلب p من 0.1 لـ 0.6، و λ من 1 لـ 8	من متقطع جداً لحد شبه مستمر
D9 AR + GARCH	من 0.75 لـ 0.90 (بشرط b ، من 0.05 لـ 0.15 a ، من 0.1 لـ 0.9 ϕ) ($a + b < 0.98$)	عشان التباين يفضل مستقر

الحجم: 200 سلسلة لكل (عملية × طول) = $7,200 = 9 \times 4 \times 200$ سحبة بارامترات — نفس حجم التصميم الأساسي بالظبط. وال seeds منفصلة تماماً عن بتاعة الدراسة الأساسية.

من الآخر: بدل ما نسأل "إيه اللي بيحصل عند 0.7؟" بقينا بنسأل "إيه اللي بيحصل في أي مكان من 0.1 لـ 0.95؟".

Four Departures from the Assumptions — أربع نسخ: لما البيانات مابتقاش مثالية

نفس الـ 7,200 سحبة اتشغلت في أربع نسخ. كل نسخة بتكسر فرضية واحدة من فرضيات التصميم الأساسي:

(1) **Random parameters — القيم العشوائية بس:** الضوضاء طبيعية (Gaussian) زي الأصل. دي نقطة المرجع.

(2) **Heavy tails — ذيول ثقيلة:** الضوضاء بقت من توزيع Student-t بـ 3 درجات حرية، ومعدلة عشان يبقى ليها نفس التباين بالظبط.

- **يعني إيه ذيل ثقيل؟** التوزيع الطبيعي نادراً جداً ما بيطلع قيمة بعيدة عن المتوسط. الـ t_3 بيطلع قيم متطرفة كتير — صدمات كبيرة مفاجئة، زي اللي بتحصل في الأسواق فعلاً.

- **ليه "نفس التباين"؟** عشان الفرق يبقى في شكل التوزيع بس، مش في حجمه.

- **وإزاي اتبنت؟** من نفس الأرقام الطبيعية بتاعة النسخة الأولى بالظبط، مضروبة في عامل عشوائي (أرقام عشوائية مشتركة — common random numbers). يعني الفرق بين النسختين هو الذيل الثقيل بس.

- وفي D8 : أحجام الطلب بقت Negative Binomial بنفس المتوسط و3 أضعاف تباين الـ Poisson.

(3) **Outliers — قيم شاذة:** كل نقطة في الـ context بس، باحتمال 3%، بتتروق بـ 4 لـ 6 انحرافات معيارية "متينة" في اتجاه عشوائي. (وفي D8 ، الطلب بيتضرب في 5).

- **ليه في ال context بس؟** عشان عايزين نقيس: هل القيم الشاذة بتلخبث تقدير الموديل؟ لو حطيناها في المستقبل كمان، هنبقى بنقيس مين بيعرف يتنبأ بحاجة مستحيل تتوقعها أصلاً.
- **ليه انحراف معياري "متين"؟** لأنه بيتحسب من ال MAD — فالقيم الشاذة نفسها مابتأثرش على المقياس اللي بنحدد بيه حجمها.

Tested seasonality (4) — الموسمية لازم تختبر: نفس سلاسل النسخة الأولى بالظبط، بس الطرق الكلاسيكية مابقتش بتاخذ الفترة الصح ($m = 12$) هدية.

- **افتكر الملاحظة من القسم 3.3:** الطرق الكلاسيكية كانت واخدة معلومة مسبقة (oracle) — إن D4 و D5 موسمين بفترة 12 — و TimesFM-3 مكانش واخد أي حاجة.
 - **دلوقتي:** الفترة بتتحدد ب اختبار الموسمية بتاع M4 (ارتباط ذاتي عند الإبطاء 12 مقارنةً بحد ثقة 90%)، ومايبتطبّقش غير لو فيه 3 دورات كاملة على الأقل (يعني $n \geq 36$).
 - **و TimesFM-3؟** تنبؤاته ماتغيرتش — هو أصلاً عمره ما خد فترة موسمية.
- الحجم الكلي:** 182,400 تقييم لكل سلسلة.

من الآخر: بدل ما نختبر الطرق على أسفلت ناعم بس، جربناها على مطبات (ذيول ثقيلة)، وخُفّر (قيم شاذة)، ومن غير خريطة (فترة مجهولة).

The Verdict — النتيجة: إيه اللي صمد وإيه اللي لأ؟

الاستنتاج	عشوائي	ذيول ثقيلة	قيم شاذة	موسمية مختبرة
سيناريوهات كسبها TimesFM-3 (من 36)	14	15	16	16
وسيط نسبته لأحسن طريقة في السيناريو	1.029	1.038	1.004	1.017
أسوأ نسبة لـ TimesFM-3	1.56	1.54	1.49	1.55
أصغر "أسوأ نسبة" لأي طريقة كلاسيكية	2.12	2.32	2.09	1.58
مقارنات معنوية (كسب-خسارة) من 180	93-29	100-28	101-27	100-27
أحسن (من 3) AutoARIMA : $n \geq 48$ عند D4	3	3	2	3
أحسن على RMSSE (من 4) Croston : D8	4	4	4	4
AutoETS ÷ SeasonalNaive : $n = 24$ عند D5 (بالفترة الصح)	2.03	2.05	1.91	2.25

نقرا الجدول استنتاج استنتاج:

- ✓ (1) **المتانة مش الدقة القصوى — صمد في 3 نسخ.** أسوأ حالة لـ TimesFM-3 طلعت من 1.31 (التصميم الثابت) لـ 1.49-1.56 (وفترات الثقة بتوصل لحد حوالي 1.75)، ودايمًا في D7 عند $n = 96$ ، اللي فيها ال Combination هو الأحسن. وأقل "أسوأ نسبة" كلاسيكية 2.09 لـ 2.32 — يعني الفرق لسه واضح.

⚠️ (2) مع الموسمية المختبرة — الفرق "اتقفل"، بس على الورق. أسوأ حالة كلاسيكية نزلت لـ 1.58 (1.48-1.67)، قد (1.55) TimesFM-3 . بس بص على السبب: AutoARIMA في أسوأ سيناريو ليه (D4 عند n = 24) MASE بتاعه ماتغِيرش خالص (2.30). اللي اتغِير هو المسطرة: عند n = 24 الاختبار مايتطَبَّقش، فـ SeasonalNaive نفسه بيخسر الفترة الصح (MASE بتاعه بيطلع من 1.09 لـ 4.26)، فأحسن طريقة في السيناريو بقت (1.45) TimesFM-3 — والنسبة بتتחסب قدامه هو.

الدرس: "أسوأ نسبة" مقياس نسبي — بيعتمد على مين موجود في المقارنة. وجزء كبير من عجز الكلاسيكي كان متقاس قدام SeasonalNaive اللي عارف الفترة. ولو شلنا سيناريوهات الدوريتين خالص (D4 و D5 عند n = 24): أسوأ نسبة لـ TimesFM-3 لسه 1.31، ولـ AutoARIMA 1.62 — الفرق موجود، بس أصغر بكثير من 1.31 مقابل 2.22.

✅ (3) المقارنات الزوجية — صمد. TimesFM-3 كسب 93 لـ 101 وخسر 27 لـ 29 من 180 في كل نسخة. و AutoARIMA لسه أصعب خصم (7-7، 7-6، 4-10، 6-8 في النسخ الأربعة بالترتيب).

✅ (4) الموسمية مع دورات كفاية — صمد، واتضعف مع القيم الشاذة. AutoARIMA أحسن في D4 في كل الأطوال من 48 في 3 نسخ، بفارق 21-26%. لكن مع القيم الشاذة: في طولين بس من 3، وبفارق 5%. ليه؟ لأن القيم الشاذة بتبُوظ تقدير الموديل الموسمي أكثر ما بتأثر على TimesFM-3 .

✅ (5) الطلب المتقطع: عيلة Croston أحسن على RMSSE في كل الأطوال في كل النسخ. أما مقارنة MASE هنا فـ مالهش معنى — وده هنشرحه بالتفصيل في 5.4 (الموضوع ليه علاقة بتنبؤ "صفر").

★ The Two-Cycle Collapse, Corrected — انهيار الدوريتين: الصورة الصح

افتكر من 4.4: في D5 عند n = 24 (دورتين بس)، AutoETS — الموديل الصح للبيانات دي — طلع MASE بتاعه 2.7 مرة قد SeasonalNaive . وقلنا: المشكلة مش في الشكل، المشكلة في التقدير.

النتيجة الجديدة: مع القيم العشوائية النسبة 1.91 لـ 2.05 — الانهيار لسه موجود بس أصغر شوية.

وماذا لو الفترة اتقدّرت؟ عند n = 24 مفيش 3 دورات، فاختبار الموسمية مايتطَبَّقش وكل سلسلة بتتعامل كأنها مش موسمية. هنا لازم نقارن بـ SeasonalNaive بالفترة الصح — لأن الـ naive العادي (m = 1) نفسه بيفشل بنفس الدرجة، فالمقارنة بيه تخبي المشكلة.

الأرقام عند n = 24 :

D4	D5	
4.25	2.55	من غير موسمية (الاختبار مايتطَبَّقش) AutoETS
3.14	2.29	وهو واخذ الفترة الصح (m = 12) AutoETS
1.09	1.13	بالفترة الصح SeasonalNaive
1.45	1.11	TimesFM-3

يعني إيه؟ بدورتين بس، الطرق الأوتوماتيكية الكلاسيكية فاشلة في الحاليتين:

- لو ادّيته الفترة ← بدورتين بس بيرفض يقدر موديل موسمي أصلاً: في التصميم الأساسي AutoETS اختار شكل موسمي في 8.5% بس من سلاسل D4 وصفر من D5، و AutoARIMA ولا مرة ← فبيطلع موديل مش موسمي ←

- لو شلت الموسمية خالص ← نفس النتيجة تقريباً: بتجاهل أهم حاجة في البيانات ← 2.55.
- الناجين الوحيدين: **SeasonalNaive** (اللي بيكرر السنة اللي فاتت) و **TimesFM-3**.

تشبيه: واحد عايز يتوقع حرارة الشهر الجاي، ومعاها بيانات **سنتين** بس. لو حاول يحسب 12 متوسط شهري من نقطتين لكل شهر ← أرقام مجنونة. ولو قال "مفيش مواسم" وخذ المتوسط العام ← هيتوقع حرارة ربيع في عز الصيف. الحل البسيط اللي بيشتغل: "**الشهر الجاي هيبقى زي نفس الشهر السنة اللي فاتت**" — وده بالضبط الـ **SeasonalNaive**.


من الآخر: بدورتين بس، المشكلة مش إن موديل موسمي "اتفرض" غلط — المشكلة إن الطرق الأوتوماتيكية **ما بتقدرش تقدره أصلاً**، فبترجع لموديل مش موسمي، سواء أدّيتها الفترة أو لأ. اللي بيفضل واقف: أبسط قاعدة، والموديل الأساس.

النسخة الخامسة — المصيبتين مع بعض: ذيول ثقيلة وقيم شاذة في نفس الوقت (بنفس السحبات). النتيجة صمدت: أسوأ نسبة لـ **TimesFM-3** 1.56، وأصغر أسوأ نسبة كلاسيكية 2.30، والمقارنات المعنوية 104 مكسب مقابل 24 خسارة.

هل TimesFM-3 "شاف" عائلات زي دي قبل كده؟ بيانات تدريبه فيها سلاسل مولّدة صناعياً. فسألنا: عند نفس الصعوبة، هل ميزته أكبر في العمليات اللي مفيش موديل كلاسيكي بيوصفها (D6 - D8)؟ الإجابة: أيوه، بحوالي 5-6%. وده متّسق مع فكرة "الألفة" — بس مابيثبتهاش.

How the Answer Moves with the Parameters — النتيجة بتتغير إزاي مع القيم؟

دلوقتي إن كل سلسلة ليها قيمها الخاصة، نقدر نسأل: **الفرق بين TimesFM-3 و AutoARIMA** بيتغير إزاي لما البارامتر يتغير؟



شكل 12 — وسيط $\log_2$ لنسبة MASE ($\text{TimesFM-3} \div \text{AutoARIMA}$) حسب خُمس البارامتر المسحوب. تحت الخط المنقط = **TimesFM-3** أحسن. كل خط = طول سلسلة مختلف.

إزاي تقرا المحور الرأسى؟ $\log_2$ للنسبة: 0 = متعادلين، **TimesFM-3** = -1 غلظه نص غلط +1، **AutoARIMA** = غلظه الضعف.

- **D1 (معامل AR) و D9 (استمرارية GARCH):** الخط مسطح — القيم الثابتة ماكانتش بتحدد النتيجة.
- **D6 (حجم الكسر):** كل ما الكسر يكبر، **TimesFM-3** بيتحسن شوية قدام **AutoARIMA**.
- **D7 (مكان نقطة الانقلاب):** الإشارة بتتقلب حسب مكان الانقلاب.
- **D8 (احتمال الطلب p):** الخط بيتحرك جامد مع **p** — بس زي ما هنشوف في 9.8، مقارنة MASE في **D8** **مالهاش معنى**، فاللوحة دي للعرض بس.


وبالأرقام — انحدار سطح الاستجابة (response surface): عملنا لكل عملية انحدار لـ $\log_2$ النسبة على البارامترات المسحوبة وطول السلسلة والنسخة:

- أكبر أثر منتظم هو الطول: كل ما n يتضاعف، النسبة يتميل ضد TimesFM-3 بـ 20% في D4 و 11% في D5 — يعني الكلاسيكي بيستفيد من البيانات الإضافية أكثر.
- القيم الشاذة في العمليات الموسمية يتميل لصالح 14% TimesFM-3 في D4 و 10% في D5).
- باقي الآثار صغيرة، والـ R^2 كله أقل من 0.26 — يعني معظم الفرق بين الطريقتين على أي سلسلة واحدة ضوضاء خاصة بالسلسلة، مش دالة في الإعدادات.

من الآخر: النتائج مابتعتمدش على القيم اللي اخترناها في معظم العمليات، والأثر الوحيد الكبير والمنتظم هو طول السلسلة.

5.6 ★★ A Longer Horizon — أفق أطول: 48 خطوة بدل 12

دي أهم إضافة. أعدنا المحاكاة كلها بأفق 48 خطوة:



- أول 12 خطوة: نفس الصورة — TimesFM-3 الأمتن (1.31 مقابل 1.11 لـ AutoARIMA).

- من الخطوة 25 لـ 48: الصورة بتتقلب — AutoARIMA أمتن (1.41 مقابل 1.80).

- وحصل حاجة غريبة في D7 (النمو اللوجستي): السلسلة وصلت للسقف وثابتة عند حوالي 200، والتلات موديلات أساس اللي اتجربت هنا توقعت إنها هتنزل: TimesFM-3 لحد 128، و TimesFM-2.5 لحد 98! بينما SeasonalNaive ("زي آخر قيمة") كان الأحسن بفرق كبير.

تشبيه: واحد شاف منحني طالع وبعدين ثابت، فافتكر إن "كل اللي بيطلع لازم ينزل" — وكمل الرسم كأنه جبل. ليه الموديلات عملت كده؟ مانقدرش نعرف — ده صندوق أسود. بنوصف اللي حصل بس.

5.7 What the Post-hoc Analyses Do NOT Prove — اللي التحليلات دي مابتثبتوش

عشان نبقي أمناء:

1. ده كله تحليل بعدي. اتصمم بعد ما النتائج الأساسية ظهرت، ومسجل كده (D-14 لـ D-10).
2. العمليات نفسها لسه ثابتة. غيّرنا القيم، بس لسه 9 عائلات أحادية المتغير بفترة 12. حوالي الربع من سلاسل M4 الشهرية برّا التغطية، وأي بيانات بتتردد ثاني برّا الدراسة كلها.
3. الانحرافات اتجربت واحدة واحدة. ماجربناش مثلاً ذيول ثقيلة مع موسمية مختبرة في نفس الوقت.
4. خصائص مش كل حاجة. سلسلتين ممكن يتشابهوا في الأربعة ويختلفوا في حاجات تانية.
5. وده الأهم: إحنا بنوصف السلوك، مش بنفسره. TimesFM-3 صندوق أسود: أوزانه علنية وتقدر تعيد كل تنبؤ، بس الـ 330 مليون بارامتر مالههمش تفسير فردي، وبيانات تدريبه مش متاحة لفحصها. عشان كده الورقة بتسمي نفسها دراسة استكشافية (exploratory): بتقيس إيه اللي الموديل بيعمله، مش ليه.

من الآخر خالص: غيّرنا القيم، وصعّبنا البيانات، وشيلنا الميزة الظالمة من الكلاسيكي، وضمنا موديلات وطرق أقوى، واختبرنا على فترة M4 الرسمية. **المتانة صمدت** — بس طلعت خاصة بـ **TimesFM-3** ، وبتختفي لما الكلاسيكي يستخدم اختبار موسمية. **وتفوق الطلب المتقطع اتصحح:** الميزة في التوزيع مش في النقطة. ده وصف دقيق لسلوك صندوق أسود في مناطق محددة — مش قانون عام عن الـ foundation models.

6. The Real-Data Tier: M4 Monthly — البيانات الحقيقية

المحاكاة بتشتري النقاء بثمان الواقعية. القسم ده بيرجع جزء من الثمن ده.

6.1 Representativeness: the Instance Space — هل سلاسلنا شبه الحقيقية؟

الفكرة (من Smith-Miles 2017 & Kang, Hyndman): بدل ما نقارن السلاسل **نقطة بنقطة**، نوصف كل سلسلة بـ 4 أرقام بتلخص "شخصيتها"، ونحط السلاسل المولدة والحقيقية في **نفس الفضاء** ونشوف هل بيغطوا بعض.

الخصائص الأربعة، واحدة واحدة:

الخاصية	بتقيس إيه	لو قيمتها عالية	لو قيمتها واطية
Spectral entropy (الإنتروبيا الطيفية)	قد إيه السلسلة عشوائية ومش متوقعة	قريبة من 1 = ضوضاء بيضا، صعب تتنبأ بيها	قريبة من 0 = نمط واضح وسهل التنبؤ
Trend strength (الاتجاه قوة)	قد إيه فيه اتجاه عام طالع أو نازل	السلسلة ماشية في اتجاه واضح	مفیش اتجاه، بتتذبذب حوالين مستوى
Seasonal strength (قوة الموسمية)	قد إيه فيه نمط بيتكرر كل 12 نقطة	موسمية قوية	مفیش موسمية
ACF1 of differences	الارتباط بين تغيّر النهارده وتغيّر امبارح	التغيّرات بتكمل بعض	التغيّرات بتعكس بعض (سالب)

قوة الاتجاه وقوة الموسمية بتتحتسبوا من تفكيك **STL**: السلسلة بتتقسم لـ اتجاه **T** + موسمية **S** + باقي **R** ، وبعدين:

$$\text{Trend strength} = \max \left(0, 1 - \frac{\text{Var}(R)}{\text{Var}(T + R)} \right)$$


- $\text{Var}(R)$: تباين الباقي، يعني الجزء اللي **مش** متفسّر.
 - $\text{Var}(T + R)$: تباين الاتجاه والباقي مع بعض.
 - **لو الباقي صغير جداً** قدام الاتجاه ← الكسر قريب من 0 ← القوة قريبة من 1 (اتجاه قوي).
 - **لو الباقي هو كل حاجة** ← الكسر قريب من 1 ← القوة قريبة من 0 (مفیش اتجاه).
- وقوة الموسمية نفس الفكرة بالظبط بس بـ **S** مكان **T** .

إزاي قارنّا؟

1. خدنا الـ **1,000 سلسلة M4 شهرية** (نفس بتاعة القسم 6)، وقصّينا كل واحدة لآخر 96 نقطة من **فترة التدريب بس** — من غير الـ 18 شهر بتوع الاختبار الرسمي.

2. حسبنا الخصائص الأربعة لكل سلسلة حقيقية ومولدة، ووحدنا المقاييس باستخدام متوسط وانحراف سلاسل M4 بس — عشان المسطرة ماتتغيرش حسب التصميم اللي بنقيسه.
3. تعريف "مغطاة": سلسلة M4 تعتبر مغطاة لو فيه سلسلة مولدة قريبة منها على الأقل قد ما السلاسل الحقيقية بتبقى قريبة من بعض. بالتحديد: المسافة لأقرب سلسلة مولدة $\geq$ المئين الـ 95 لمسافة أي سلسلة M4 لأقرب سلسلة M4 ثانية (وطلع الحد ده 0.533).

ليه التعريف ده بالذات؟ عشان المقياس يبقى عادل: مش بنطلب من المحاكاة تقرب أكثر مما الواقع نفسه بيقرّب لنفسه.



شكل 11 — السلاسل المولدة وسلاسل M4 في فضاء الخصائص (أول مكوّنين رئيسيين). النقط الرمادي = سلاسل M4 الحقيقية، والمملونة = سلاسلنا المولدة عند $n = 96$. (أ) التصميم الثابت: كل عملية سحابة صغيرة متلمّة، وفيه فراغات كبيرة بين السحابات مليانة نقط رمادي. (ب) التصميم العشوائي: السحابات اتفردت ومَلّت جزء كبير من الفراغات دي.

النتيجة بالأرقام:

التصميم العشوائي	التصميم الثابت	
نسبة سلاسل M4 المغطاة	48.5% (فترة ثقة 45.2–51.4%)	75.8% (73.2–78.4%)
وسيط المسافة لأقرب سلسلة مولدة	0.55	0.38

وهل الأرقام دي بتعتمد على اختياراتنا؟ جربنا نغيّر كل حاجة:

- الحد: من المئين 80 لحد 99.
- طول السلسلة: 48 و 96 و 200.
- عدد الخصائص: 4 أو 6 (بإضافة الارتباط الذاتي للسلسلة نفسها و"التكتّل" lumpiness).
- حجم العينة: صغّرنا التصميم الثابت لنفس حجم العشوائي.

وفي كل الحالات دي: التصميم العشوائي بيغطّي من 76% لـ 89% من M4، ودايمًا أكثر من الثابت. وبالعكس كمان: من 60% لـ 92% من السلاسل المولدة واقعة جوه منطقة البيانات الحقيقية — وأقل نسبة عند $n = 200$ ، لأن السلاسل الطويلة الحقيقية فيها اتجاه أقوى من سلاسلنا.

وتلات ملاحظات مهمة:

- **سلاسل M4 أكثر اتجاهاً** من سلاسلنا: وسيط قوة الاتجاه **0.87** عندهم مقابل **0.63** عندنا.
- **1.5% بس** من سلاسل M4 أقرب حاجة ليها هي **D8** (الطلب المتقطع) — لأن **M4 مفياش سلاسل متقطعة أصلاً**.
فنتائج الطلب المتقطع **بتعتمد على المحاكاة لوحدها** (وعلى الأدبيات بتاعة الموضوع ده).
- **حوالي الربع** من سلاسل M4 لسه بزا التغطية، ومسجل ده كحد من حدود الدراسة في القسم 7.4.

من الآخر: التصميم الثابت كان بيغطي **أقل من النص** من الواقع الشهري؛ لما خَلينا القيم عشوائية بقي بيغطي **حوالي ثلاث أرباعه** — والنتيجة دي بتصمد مهما غيّرنا طريقة الحساب.

بس خد بالك: إن المحاكاة بتغطي فضاء خصائص M4 **مش معناه** إن نتايجها بتنتقل **سلسلة بسلسلة**. جربنا نتوقع نتيجة كل سلسلة M4 من أقرب 10 سلاسل محاكاة ليها — الارتباط طلع **0.06** بس، يعني **مفيش تقريباً**. التغطية شرط **ضروري** للتشابه، **مش كافي**.

6.2 What Is M4 Anyway? — إيه هي بيانات M4 أصلاً؟

الـ **M4** هي **مسابقة تنبؤ عالمية** نظمها Spyros Makridakis سنة 2018. حطوا **100,000 سلسلة زمنية حقيقية** من الاقتصاد والمالية والصناعة والديموغرافيا، وخلصوا الناس كلها تتنافس عليها. دي مش بيانات لعبة — دي المرجع المعياري اللي أي ورقة تنبؤ جادة بتتقاس عليه.

السلاسل مقسومة بالتردد: سنوية، ربع سنوية، **شهرية**، أسبوعية، يومية، بالساعة. إحنا أخذنا **الشهرية** — وهي أكبر مجموعة فيهم: **48,000 سلسلة**.

ليه الشهرية بالذات؟ لأنها أقرب حاجة للواقع اللي المحلل بيشتغل عليه (مبيعات شهرية، طلبات شهرية، مؤشرات اقتصادية شهرية)، وفيها **موسمية حقيقية** بفترة 12 — وده بيخليها الاختبار الطبيعي للنتائج اللي طلعت من **D4** و **D5** في المحاكاة.

6.3 How We Picked the Series — إزاي اخترنا السلاسل بالضبط

مخدناش الـ 48,000 كلهم — لأن ده هياخد أيام حساب من غير فائدة إضافية. المواصفات بالتفصيل:

الخطوة	القيمة	ليه
المجموعة الأصلية	48,000 سلسلة شهرية	كل الشهرية في M4
شرط الطول	السلسلة لازم تكون ≤ 138 شهر	عشان تكفي لـ context محترم + 18 شهر مختبين
المؤهلة بعد الشرط	32,581 سلسلة	اللي عدت الشرط
العينة	1,000 سلسلة عشوائي	بـ seed ثابتة 20260908

ليه seed ثابتة؟ عشان أي حد يشغل الكود يجيب نفس **الألف سلسلة بالضبط** — مش عينة ثانية. لو مكانش فيه seed، كل واحد هيجيب نتيجة مختلفة شوية والمقارنة تبقى مالهش معنى.

طول السلاسل اللي طلعت: الأقصر 138 شهر، الوسيط 299 شهر (يعني حوالي 25 سنة!)، والأطول 1,808 شهر. يعني دي سلاسل **طويلة ومحترمة** مش أمثلة صغيرة.

6.4 What Is an "Origin" and a "Window"? — يعني إيه "origin" و "window"؟

دي أهم نقطة محتاجة توضيح، وهي بسيطة جداً لما تتشرح صح.

ال Origin (نقطة الأصل) = اللحظة اللي بتقف فيها عن المشاهدة وتبدأ تتنبأ.

تخيل إنك واقف في شهر معيّن. كل اللي قبله إنت شايفه (ده ال context)، وكل اللي بعده مخبي عنك (ده ال truth اللي هنتقاس عليه). النقطة اللي إنت واقف عندها دي اسمها ال origin.

ال Window (النافذة) = زوج واحد: (البيانات اللي شفتها، الحقيقة المخبية).

مثال حقيقي بالأرقام من بياناتنا

خد سلسلة حقيقية من العينة، اسمها M10046 ، طولها 346 شهر. إحنا بنأخذ منها 3 نوافذ:

النافذة	الموديل يشوف	بيتنبأ بـ	العدد
origin 1	شهور 1 → 328	شهور 329 → 346	18 شهر
origin 2	شهور 1 → 316	شهور 317 → 334	18 شهر
origin 3	شهور 1 → 304	شهور 305 → 322	18 شهر

شوف النمط: كل مرة بنرجع 12 شهر لورا (سنة كاملة)، وبنطلب منه يتنبأ بـ 18 شهر من النقطة دي.

ليه بنرجع 12 شهر مش شهر واحد؟ عشان لو رجعنا شهر واحد، النوافذ هتبقى متداخلة جداً وكأننا بنقيس نفس الحاجة 3 مرات. الرجوع سنة كاملة بيدّي مواقف مختلفة فعلاً في السلسلة.

ليه 3 نوافذ مش واحدة؟ عشان لو قيّمنا على نقطة واحدة بس، ممكن نكون وقعنا على شهر استثنائي (أزمة، عيد، حاجة غريبة) والنتيجة كلها تبقى حظ. ثلاث نقاط بتقلّل الحظ ده.

وليه 18 شهر بالذات؟ لأن ده الأفق الرسمي اللي مسابقة M4 نفسها حدّته للسلاسل الشهرية. يعني نتايجنا تبقى قابلة للمقارنة مع أي نتيجة منشورة على M4.

وليه 2,932 نافذة مش 3,000؟

سلسلة $\times 3$ نوافذ = 3,000 1,000 — بس الرقم الحقيقي 2,932. الفرق 68 نافذة. ليه؟

السبب في جملة: مش كل سلسلة طولها يسمح بـ 3 نوافذ. السلاسل القصيرة بتدي أقل، وإحنا مرميناهاش — أخذنا منها اللي طولها يسمح بيه.

الشرط بالظبط، ومن فين جه

عشان النافذة رقم k تعدي (يعني $k = 0$ للأولى، 1 للتانية، 2 للتالثة)، لازم اللي يفضل للموديل يشوفه ما يقلش عن 120 شهر. والحساب:

• إحنا بنرجع لورا $12k$ شهر عشان نوصل لل origin بتاع النافذة دي.

• وبنشيل 18 شهر (الأفق) عشان نخبيهم.

• فاللي يفضل للموديل $n - 12k - 18$.

فالشرط:

$$n - 12k - 18 \geq 120 \iff n \geq 138 + 12k$$


نطبّقه على النوافذ الثلاثة:

النافذة	k	الشرط	يعني السلسلة لازم تكون
الأولى	0	$n \geq 138 + 0$	≤ 138 شهر
الثانية	1	$n \geq 138 + 12$	≤ 150 شهر
الثالثة	2	$n \geq 138 + 24$	≤ 162 شهر


ودي بالظبط الأرقام اللي في الشكل تحت. ولاحظ إن شرط النافذة الأولى (138) هو نفسه شرط اختيار العيّنة من الأول —
عشان كده مفيش ولا سلسلة طلعت بصفر نوافذ.

الشكل: إزاي السلسلة بتتقسّم لنوافذ


سلسلة طويلة (346 شهر) — التلات نوافذ كلها بتعدي



سلسلة قصيرة (145 شهر) — نافذة واحدة بس بتعدي



$$951 \times 3 + 30 \times 2 + 19 \times 1 = 2,932 \text{ كل طول بيدي كام نافذة؟}$$



اللي بيتنبأ بيه (18 شهر) اللي الموديل بيشوفه (context)

شكل 5 — إزاي السلسلة الواحدة بتتحول لنوافذ، وليه القصيرة بتدي أقل. اللون الأزرق = اللي الموديل بيشوفه، والبرتقالي = الـ 18 شهر اللي بيتنبأ بيهم. الخط الأحمر المتقطع = الحد الأدنى للتاريخ (120 شهر).

• **فوق:** سلسلة طولها **346 شهر**. كل مرة بنرجع 12 شهر لورا، ولسه فاضل للموديل 328 ثم 316 ثم 304 شهر — كلهم فوق الـ 120 بكتير. فالتلات نوافذ بتعدي.

• **في النص:** سلسلة طولها **145 شهر** بس. النافذة الأولى تمام (بيفضل 127 شهر). لكن الثانية هيفضل فيها **115 شهر** — أقل من 120، ف **مرفوضة**. والثالثة 103، مرفوضة كمان. فالسلسلة دي بتدي **نافذة واحدة** وخلص.

• تحت: التوزيع النهائي على الألف سلسلة.

الحساب النهائي

عدد النوافذ	شرط الطول	عدد السلاسل	إجمالي النوافذ
3 نوافذ	$n \geq 162$	951	$951 \times 3 = 2853$
نافذتين	$150 \leq n < 162$	30	$30 \times 2 = 60$
نافذة واحدة	$138 \leq n < 150$	19	$19 \times 1 = 19$
الإجمالي		1,000	2,932

$$2853 + 60 + 19 = 2932$$

★ وليه ده مهم أصلاً؟

ممکن تقول: "طب ما كنت تشيل الـ 49 سلسلة القصيرة وتخليها $2,853 = 3 \times 951$ وخلص، الرقم يبقى مضبوط!" — وده بالضبط اللي معملناهوش، وليه سببين:

1. رمي البيانات القصيرة **بيحيز النتيجة**. السلاسل القصيرة هي أصعب حالة على الطرق الكلاسيكية (فاكر درس الـ **estimability** في القسم 4.4). لو شلناها، نبقى شلنا بالضبط الحالات اللي **TimesFM-3** بيتفوق فيها — يعني **حيزنا النتيجة ضد نفسنا** من غير ما ناخد بالناس.

2. الرقم "الوحش" **أصدق من الرقم المضبوط**. لما تلاقي في ورقة رقم زي 2,932 بدل 3,000 المستديرة، ده مؤشر إن الباحث **مزوقش** — وصف اللي حصل فعلاً. الأرقام المستديرة أوي في الأوراق أحياناً بتبقى علامة إن حد رمى بيانات عشان الجدول يبقى شكله حلو.

من الآخر: الرقم 2,932 مش غلط ولا نقص — ده **نتيجة قاعدة واضحة** ($n \geq 138 + 12k$) اتطبقت على أطوال حقيقية مختلفة، وكل سلسلة أخذت اللي طولها يسمح بيه بالضبط.

6.5 ★ ★ Why Use Data the Model May Have Seen? — ليه نستخدم بيانات الموديل يمكن يكون شافها؟

ده أهم سؤال في القسم كله، وسؤال وجيه جداً. الإجابة من ثلاث حتت:

الحتة الأولى: إحنا مش بنبني الادعاء الأساسي عليها
الادعاء الرئيسي للورقة مبني على **المحاكاة** — لأن هناك التلوث **مستحيل بالبناء**. القسم ده يجاوب على سؤال **تاني خالص وأضيق:**

السلاسل الحقيقية بتشبه أنهى نظام من الأنظمة التسعة اللي حاكيناها؟

وده سؤال مشروع تماماً حتى لو البيانات ملوثة، لأنه سؤال عن **شكل البيانات** مش عن **مين أدق**.

الحتة الثانية: المحاكاة لوحدها ممكن تكون **منفصلة عن الواقع**
لو الورقة اكتفت بالمحاكاة، أول اعتراض من أي محكم هيبقى: "كلامكم حلو على بيانات صناعية — بس الدنيا الحقيقية مش كده". فلازم نوريه إن نتايجنا **بتتكرر** على بيانات حقيقية.

وده اللي حصل بالظبط: نفس النمط ظهر في الاتنين. والاتفاق ده قيمته أكبر من أي طبقة لوحدها، لأن ضعف كل طبقة معاكس للتانية:

التلوث	المحاكاة	M4 الحقيقية
مستحيل بالبناء	محتمل جداً	
الواقعية	صناعية ومبسطة	حقيقية 100%

يعني لو حاجة طلعت صح في الاتنين، تبقى مش صدفه تصميم ولا صدفه تلوث.

الحته الثالثة ★ — التعادل نفسه دليل

دي النقطة الذكية اللي تستاهل تفتكرها.

لو كان TimesFM-3 بيغش فعلاً (يعني حافظ سلاسل M4 من التدريب)، كنا هنتوقع إيه؟ كنا هنتوقع إنه يسحق الطرق الكلاسيكية سحق — لأنه حرفياً شايف الإجابة.

بس ده مش اللي حصل. هو اتعادل مع $p = 0.27$ ، (52.6% AutoARIMA) واتعادل مع الـ 48.5% Combination ($p = 0.27$). يعني حتى على البيانات اللي هو "متهم" إنه شافها، مكسبش عليهم.

فالتعادل ده في حد ذاته دليل ضد فرضية إن الموديل بيستفيد استفادة ضخمة من الحفظ. مش دليل قاطع — يمكن حافظ حته صغيرة — بس هو أقوى حاجة تقدر تستنتجها من بيانات عامة.

من الآخر: إحنا بنستخدم M4 عارفين إنها ملوثة، وقايلين كده بصراحة في الورقة، ومش بانيين عليها الادعاء الرئيسي. بنستخدمها عشان نعرف شكل الواقع ونشوف هل المحاكاة بتوصف الدنيا الحقيقية ولا لأ. والنتيجة إن الاتنين بيقولوا نفس الكلام.

النتيجة

الطريقة	متوسط MASE	التغطية 80%	pinball
Combination	0.9027	0.8006	0.3653
TimesFM3	0.9114	0.7655	0.3627
AutoARIMA	0.9182	0.7851	0.3744
AutoETS	0.9465	0.7909	0.3840
Theta	0.9672	0.7344	0.3977
SeasonalNaive	1.2768	0.7867	0.5135

والاختبارات (Wilcoxon مزدوج عبر الـ 1,000 سلسلة، مصحح بـ BH):

المقارنة	% سلاسل TimesFM-3 أحسن فيها	p مصحح	الحكم
ضد SeasonalNaive	80.1%	< 0.0001	TimesFM-3 كسب
ضد Theta	56.8%	< 0.0001	TimesFM-3 كسب
ضد AutoETS	54.1%	0.0043	TimesFM-3 كسب
ضد AutoARIMA	52.6%	0.27	تعاذل
ضد Combination	48.5%	0.27	تعاذل

ملاحظتين مهمتين

الأولى — الطبقتين يتفقا. النمط ده نفس نمط المحاكاة بالظبط: بيكسب على كل حاجة ما عدا **AutoARIMA** اللي بيتعاذل معاه. وسلاسل **M4** الشهرية **طويلة وموسمية** — يعني بالظبط النظام "القابل للتقدير" اللي المحاكاة اتنبأت إن الكلاسيكي هيبقى منافس فيه. والاتفاق ده قيمته أكبر من أي طبقة لوحدها، لأن الاتنين **ضعفهم معاكس لبعض**: المحاكاة نضيفة بس صناعية، والحقيقية واقعية بس ملوثة.

الثانية — نتيجة الفترات مانتقلتش. على البيانات المولدة كان **TimesFM-3** الأحسن معايرة؛ هنا هو **ثاني أسوأ واحد**: تغطية **0.765** مقابل مطلوب 0.80، بينما الـ **Combination** وصل **0.801**. يعني على سلاسل حقيقية فيها بنية مش موجودة في عملياتنا التسعة، الـ quantiles المتعلّمة بتاعته **بتقصّر**. وده بيخفّف من نتيجة المعايرة اللي فوق، ومتسق مع اللي **وزماليه (2026) Adler** بلّغوا عنه.

لكن لاحظ: على الـ **pinball loss** — وهو proper scoring rule ومسجل مسبقاً — **TimesFM-3** طلع **الأحسن** (0.3627). فالصورة مش "فترات وحشة" على طول، دي "التغطية وحشة والتوزيع ككل كويس".

من الآخر: على بيانات حقيقية طويلة وموسمية، الموديل والكلاسيكي **متعادلين** في الدقة، والكلاسيكي أحسن في معايرة الفترات.

6.6 ★ The Official M4 Test Period — فترة الاختبار الرسمية وأبطال المسابقة

بدل النوافذ المتدرجة، اتنبأنا بفترة الاختبار **الرسمية** (18 شهر) لنفس الـ 1,000 سلسلة، وحسبنا **OWA** زي المسابقة بالظبط (نسبة لـ Naive2). وفي الجولة الثانية نزلنا كمان **التنبؤات المنشورة لأحسن 10 مشاركات في M4** وتأكدنا إنها بتدّي نفس نتائج المسابقة المنشورة بالظبط على الـ 48,000 سلسلة:

الطريقة	OWA
FFORMA (المركز الثاني في M4)	0.831
Prakash & Jaganathan (الرابع)	0.841
ES-RNN بتاع Smyl (الفايز الأول)	0.848
Pawlikowski وزملاؤه (الثالث)	0.849
TiRex	0.855
Svetunkov & Petropoulos (السادس)	0.858
Chronos-2	0.860
TimesFM-3	0.862
TimesFM-2.5	0.864
الدمج الكلاسيكي	0.868
AutoARIMA	0.891

يعني إيه؟ أربع مشاركات من أبطال M4 قدام كل الموديلات الأساس. TimesFM-3 من غير أي تطبيق قد أصحاب المراكز من الخامس للسابع — كويس جداً، بس مش قد الأحسن. واختبار الترتيب (MCB) — بعد ما خَلينا إعداد واحد لكل موديل — لقي 10 طرق مايتفرقوش إحصائياً عن الأول: 5 من أبطال M4، والدمج، و TimesFM-3، و Chronos-2، و TiRex.

6.7 ★ Truncated Histories — تجربة القصّ

أدينا كل طريقة آخر 24 نقطة بس من كل سلسلة M4:

طول التاريخ	TimesFM-3	AutoARIMA	أحسن كلاسيكي
آخر 24 بس	1.046 (و1.027 TiRex)	1.175	1.096
آخر 48	0.961	1.019	0.955
كامل	0.929	0.939	0.928

مع 24 نقطة بس الموديلات الأساس في المقدمة: TimesFM-3 أحسن من AutoARIMA بـ 11% ومن أحسن كلاسيكي (الدمج) بـ 4.6%. ومع التاريخ الكامل الكل متقارب. ده بالظبط درس القابلية للتقدير من القسم 4.4 — لكن المرة دي على بيانات حقيقية.

6.8 ★★ Data After the Training Cut-offs — بيانات بعد ما الموديلات اتدربت

السؤال اللي فاضل: على M4، يمكن الموديل يكون حافظ قيم الاختبار. طب لو جينا بيانات حقيقية اتسجلت بعد ما بيانات تدريب الموديلات اتقفلت؟

جبنا **FRED-MD** — قاعدة بيانات اقتصاد كلي شهرية من بنك الاحتياطي الفيدرالي في سانت لويس (نسخة أغسطس 2026).
101 سلسلة كاملة، وكل طريقة اتنبأت بالفترة من **يناير 2025 لـ يونيو 2026** — بعد آخر بيانات موثقة لتدريب **TimesFM-3** (نوفمبر 2023).

الطريقة	متوسط MASE
AutoARIMA	0.540
TiRex	0.556
الدمج	0.556
TimesFM-3	0.607
SeasonalNaive	0.896

يعني إيه؟ على بيانات **مستحيل** يكون حافظها، **TimesFM-3** **متعادل إحصائياً** مع الطرق الكلاسيكية — يغلب **SeasonalNaive** بس. ومتوسطه اتأثر بكام سلسلة **كَمَل** فيها **اتجاه قديم لبعيد** — زي تخفيضات الفائدة في 2024.

من الآخر: الميزة اللي شفناها في المحاكاة **مابتظهرش** هنا. ده مش يبلغها — التصميمين مختلفين — بس بيقول إن على بيانات اقتصادية حقيقية وجديدة، **الكلاسيكي** **لسه منافس قوي جداً**.

7. Discussion — المناقشة

7.1 Summary of Findings — ملخص النتائج في جدول

النتيجة	فين في الورقة	مسجلة مسبقاً؟	صحيحة في حدود
مفيش عيلة كسبت؛ AutoARIMA الوحيد اللي TimesFM-3 مايبغلبوش بوضوح	4.1، رسم الغابة	✓ مسجلة	9 عمليات، أفق 12
أسوأ نسبة لـ $1.31 = \text{TimesFM-3}$ ، وكل كلاسيكي ≤ 2.2	جدول 3، 5.1	ملخص بعدي	أفق 12؛ نسبي للطرق المقارنة
أكبر إخفاقات الكلاسيكي من موسمية مش قابلة للتقدير بدورتين	4.3، 5.2	مسجلة، واتفحصت بعدياً	$m = 12$ ، $n = 24$ R اكررت في
مع ≤ 4 دورات AutoARIMA أدق بـ 21-24%	4.4	✓ مسجلة	D4 ، D5
المتانة خاصة بـ TimesFM-3 من بين 5 موديلات أساس	5.3، شكل 5	بعدي	أفق 12
في الطلب المتقطع مفيش ميزة قدام معايير التاريخ	5.4	بعدي	عملية مستقلة عبر الزمن
في الخطوات 25-48 AutoARIMA أمتن، والتلات موديلات أساس اللي اتجربت هناك بتتوقع نزول لسلسلة ثابتة	5.6	بعدي	التصميم المعاد توليده
على M4: قد المراكز 5-7، ورا أحسن أربعة	6.3	بعدي	1,000 سلسلة شهرية طويلة
على بيانات بعد تدريب الموديلات: متعادل مع الكلاسيكي	6.5	بعدي	101 سلسلة FRED-MD، 2026-2025

(الأرقام في العمود الثاني هي أقسام الورقة نفسها.)

7.2 Robustness, Not Peak Accuracy — الموديل يشتري المتانة مش الدقة القصوى

إزاي نقيس المتانة دي بشكل عادل؟

⚠ **خد بالك: أسوأ MASE مطلق هو المقياس الغلط هنا.** ليه؟ لأن **D3** صعبة على كل الطرق، فأسوأ الحالات المطلقة بتبقى محكومة **بالعملية دي** مش بهشاشة أي طريقة. الدليل: أسوأ حالة مطلقة عند **Theta** هي 4.483 — **أحسن** من بتاعة (4.656) **TimesFM-3** ! ولو مشينا بالمقياس ده يبقى **Theta** أثبت طريقة، وده كلام مايتقالش لما تبص على أدائه في **D4** (4.155 مقابل 0.886).

المقياس الصح: نسبة كل طريقة لـ **أحسن طريقة في نفس السيناريو**. ده بيعزل الهشاشة لوحدها:

الطريقة	النسبة الوسيطة	المتوسط	أسوأ نسبة	أسوأ سيناريو
TimesFM3	1.008	1.054	1.31	D4, n=200
AutoARIMA	1.032	1.137	2.22	D4, n=24
Combination	1.108	1.273	3.00	D4, n=24
AutoETS	1.194	1.366	3.50	D4, n=24
SeasonalNaive	1.200	1.470	5.65	D7, n=48
Theta	1.251	1.614	4.69	D4, n=200

اقرأ الجدول ده كويس:

- **TimesFM-3** عمره ما بقى أسوأ من 1.31 مرة من أحسن طريقة في أي سيناريو في التصميم كله.
- وفي السيناريو الوسيط هو في حدود 0.8% من الأحسن.
- بينما كل طريقة كلاسيكية بتبقى في مكان ما 2.2 مرة أسوأ على الأقل، وبعضها 4.7 و 5.6 مرة.

تشبيه: لاعب بيجيب 8/10 في كل ماتش، مقابل لاعب بيجيب 10/10 مرة و 3/10 مرة. اللي عايز يكسب البطولة كلها بياخد الأول.

من الآخر: TimesFM-3 نادراً ما يبقي الأحسن، وأبدأ مش يبقي كارثة. الكلاسيكي الأوتوماتيكي أحياناً ممتاز وأحياناً بيقع.

7.3 Practical Considerations — اعتبارات عملية (مش قواعد)

الورقة شالت جدول القرار القديم وحطت مكانه فقرات حذرة — لأن جدول "استخدم كذا" بيدّي ثقة أكبر من اللي دراسة محاكاة استكشافية تقدر تديها. فخد دول كنقط بداية تفحصها على بياناتك، مش كقوانين:

- **آلاف السلاسل من غير وقت تضبط كل واحدة:** هنا متانة TimesFM-3 فرقت أكثر — عمره ما بعد كثير عن الأحسن. بس لو قدامك سلسلة واحدة تقدر تحدد موديلها، الكلاسيكي مايبخسرش كثير قدام AutoARIMA، وبيديك معاملات وتشخيص تقدر تشرحها وتراجعها.
- **سلاسل موسمية:** مع 4 دورات أو أكثر AutoARIMA كان في المقدمة بوضوح (و SeasonalNaive كمان قدام TimesFM-3 في D4). مع دورتين الكلاسيكي الأوتوماتيكي رجع لموديلات مش موسمية ووقع — و SeasonalNaive أو TimesFM-3 كانوا الأمن.
- **طلب متقطع:** المعايير البسيطة من التاريخ كانت قد أي حاجة جربناها — عُشيرات التاريخ أقل pinball، ومتوسطه (زي عيلة Croston) أقل، RMSSE والتنبؤ الوسيط لـ TimesFM-3 مكانش أحسن من تنبؤ صفر.
- **آفاق طويلة:** بعد حوالي سنتين من الخطوات الشهرية AutoARIMA بقى الأمتن، والتلات موديلات الأساس توقعت نزول لسلسلة ثابتة — فراجع تنبؤاتها الطويلة قدام المستوى الأخير قبل ما تستخدمها.

★ Speed — والنتيجة بالعكس تماماً من المتوقع

الطبيعي إنك تفتكر إن موديل بـ 330 مليون parameter هو الغالي، والموديل الإحصائي بـ 3 parameters هو الرخيص. العكس تماماً على الجهاز ده:

الطريقة	زمن لكل سلسلة	النسبة لـ TimesFM-3
SeasonalNaive	3.1 ms	0.13×
Theta	9.0 ms	0.39×
TimesFM3 (GPU, batched)	23.2 ms	1×
AutoETS	102.0 ms	4.4×
AutoARIMA	2382.7 ms	102.8×

AutoARIMA أبطأ 103 مرة من **TimesFM-3** لكل سلسلة!

ليه؟ السبب بنيوي مش عرضي: الـ **AutoARIMA** بيعمل بحث تدريجي على الـ orders، وبيركّب كل مرشح بـ maximum likelihood، لكل سلسلة لوحدها. بينما **TimesFM-3** بيعمل مرور أمامي واحد مجمّع (batched) وبيوزّع تكلفته على الدفعة كلها.

⚠ بس التحفظ الثاني أهم من الرقم الرئيسي

الرقم ده لكل سلسلة على نواة واحدة — والصورة بتتغير لما تشغل الكل بالتوازي. الأرقام الحقيقية من الـ log بتاع التشغيل:

- الطرق الكلاسيكية الأربعة على الـ 7,200 سلسلة كلها بـ 22 نواة: 7.3 دقيقة

- TimesFM-3** على نفس الشغل بـ GPU واحد: 3.2 دقيقة

- النسبة: 2.3× — مش 103×!

يعني: الـ 103× صح لكل سلسلة على نواة واحدة، لكن الكلاسيكي بيتوازي ببساطة، والتوازي بيسترد معظم الفرق. الرقمين يجاوبوا على سؤالين مختلفين، وإني أقول الأول بس يبقى مبالغه. (وكمان **TimesFM-3** محتاج GPU أصلاً).

من الآخر: الموديل الجبار مش الخيار الغالي — لا لكل سلسلة ولا في الإجمالي. بس الفرق الإجمالي 2.3× مش 103×.

★ ★ Licensing — وده أهم بند عملي في الورقة كلها

أوزان **TimesFM-3** صادرة تحت رخصة **timesfm-non-commercial-license-v1.0** — يعني استخدام غير تجاري وغير إنتاجي فقط.

الكود نفسه Apache-2.0، وأوزان **TimesFM-2.5** كانت Apache-2.0 كمان. لكن أوزان النسخة 3 لأ.

النتيجة العملية مطلقة وسابقة لأي كلام عن الدقة: لو إنت بتشتغل في تطبيق تنبؤ تجاري، فـ **TimesFM-3** بشكله المنشور مش متاح لك أصلاً — عند أي مستوى دقة. أي ميزة في الدقة ملهاش أي معنى لتاجر تجزئة مش مسموح له قانونياً ينشر الموديل ده.

الخيارات المتاحة: تستخدم **TimesFM-2.5** تحت Apache-2.0، أو تتفاوض على شروط منفصلة مع Google، أو تستخدم طريقة كلاسيكية. كل طريقة كلاسيكية في المقارنة دي خالية من القيود دي.

بنقول ده مش كنقد لـ Google — بنقله لأنه بيتشال دايماً من مقارنات الموديلات، وهو بيقلب الترتيب رأساً على عقب لفئة كاملة من المستخدمين.

من الآخر: قبل ما تسأل "أدق؟" اسأل "مسموح لي أصلاً؟"

Interpretability — القابلية للتفسير والتشخيص

ARIMA يقولك ال orders والمعاملات والأخطاء المعيارية بتاعتها. **ETS** يقولك معاملات التنعيم والحالات. ودول بيسمحوها بشغل التشخيص العادي: تفحص ال residuals، تختبر الارتباط الذاتي المتبقي، تفسّر لصاحب القرار **ليه** التنبؤ بيلف هنا، وتكتشف إن الموديل **بطل** يضبط.

TimesFM-3 **مبيديش حاجة من دول**. لما يتنبأ غلط، مفيش parameter تبصله ولا تشخيص تشغله — اللي تقدر تعمله إنك **تلاحظ** الأخطاء وتغيّر الطريقة. وفي بيئة منظّمة (regulated) لازم تبرّر التنبؤ مش بس تنتجه — الفرق ده لوحده ممكن يترجّح على المقارنة كلها.

Prediction Intervals in Theory — الفترات نظرياً

الفترات الكلاسيكية مشتقة من **بنية الخطأ المفترضة**، فتقدر تناقشها تحليلياً. أما **TimesFM-3** quantiles فهي **مخرجات متعلّمة** من رأس شبكة، من غير نظرية. أثبتنا فوق إنها في الواقع أحسن معايير في المتوسط — **بس تجريبياً، على العمليات دي**، مش بالبناء. وسلوكها على عملية شبيهة بحاجة مش موجودة في corpus التدريب **مجهول بالتعريف**.

Threats to Validity 7.4 — حدود الدراسة (بصراحة)

الورقة قسّمتها لتلات أنواع:

- **حدود "المقياس" (construct):** الملخصات اللي شايلة نتيجة المتانة — **أسوأ نسبة وعدد السيناريوهات المكسوبة** — اتعرّفت **بعد** البروتوكول، وبتعتمد على الطرق المقارنة (خصوصاً **SeasonalNaive** اللي عارف الفترة)؛ وفي **D8** الحكم بيتقلب حسب مقياس الخطأ.
 - **حدود "داخلية" (internal):** مفيش تطبيق يدوي لأي طريقة، والكلاسيكي اتشغل بمكتبة واحدة بإعداداتها الافتراضية — مراجعة R كرّرت الإخفاقات بس لقت **خطأ تنفيذ واحد**؛ والبروتوكول متجمّد بس محفوظ في الأرشيف مش في سجل خارجي؛ وكل القسم 5 بعدي.
 - **حدود "خارجية" (external):** السلاسل المولّدة نضيفة وما فيها ش خطأ قياس ولا مواسم تقويمية ولا تغيّرات نظام؛ حوالي **ربع** سلاسل M4 الشهرية وكل الترددات الثانية برّا التغطية؛ 9 عائلات ثابتة بفترة 12؛ الأفق المسجّل 12 خطوة والأطول اتفحص مرة واحدة؛ والانحرافات اتجربت واحدة واحدة. **TimesFM-3** اتقيّم zero-shot وأحادي المتغير بس، و**خمس** موديلات أساس بس اتقيّمت وبيتصرفوا **مختلف** — فمفيش تعميم على الفئة.
- وفوق ده كله:** دي دراسة استكشافية عن صندوق أسود — بتقيس إيه اللي الموديل بيعمله، مش **ليه**.

8. الخلاصة الكبيرة — لو هتفتكر 5 حاجات بس

1. **مفيش عيلة كسبت.** **TimesFM-3** كسب أغلب المقارنات المعنوية — **ما عدا** قدام (9-11) **AutoARIMA** — ومع 4 دورات موسمية أو أكثر **AutoARIMA** أدق بوضوح.
2. **اللي بيميز TimesFM-3 هو أسوأ حالة ليه:** عمره ما بقى أسوأ من **1.31x** من الأحسن، وكل كلاسيكي $\leq 2.2x$ في سيناريو ما — ومن بين **خمس** موديلات أساس هو الوحيد اللي كده.
3. **بس الميزة دي ليها حدود:** نسبة للطرق المقارنة، صحيحة **لحد حوالي سنتين** من الخطوات الشهرية (بعدها **AutoARIMA** أمتن والتلات موديلات أساس اللي اتجربت هناك بتتوقع نزول لسلسلة ثابتة)، وفي الطلب المتقطع **معايير التاريخ البسيطة** قدها.

4. على M4 الحقيقية: TimesFM-3 قد أصحاب المراكز من 5 لـ 7 في المسابقة، ورا أحسن أربعة — وعلى بيانات اقتصادية بعد تدريبه، متعادل مع الكلاسيكي.

5. الدرس الأعظم عن الكلاسيكي: المهم مش بس إن الموديل صح، المهم إنه يتقدّر من البيانات اللي قدامك — بدورتين AutoETS خسر 2.7 مرة قدام قاعدة من سطر واحد، على بيانات هو اللي ولّدها. والرخصة غير التجارية ممكن تحسم الموضوع لفئة كاملة قبل أي كلام عن دقة.

من الآخر خالص: مش "الجديد أحسن من القديم" ولا العكس — الجديد أثبت في الأفق القصير، والقديم أدق لما يقدر يتقدّر، والرخصة ممكن تحسم الموضوع قبل الاتنين.

9. Honesty & Reproducibility — إعادة الإنتاج والأمانة

9.1 Pre-registration and Deviations — التسجيل المسبق والانحرافات

- PREREGISTRATION.md متجمّد قبل أي تنبؤ، ومتعدّلش أبداً بعد كده.
- DEVIATIONS.md فيه 12 انحراف، كل واحد بتاريخه وسببه، مقسومين مجموعتين:
- D-01 لـ D-03: اتعملوا قبل وجود أي نتيجة (تصليح توزيعات البيانات).
- D-04 لـ D-14: اتعملوا بعد وجود نتائج، وكل واحد بيقول كده في مدخله (آخريهم D-10 لـ D-14: دراسة المتانة، وخط الأساس Oracle ARIMA، ومراجعة R، والأفق الأطول، والتحليلات البعدية في القسم 5).
- ⚠️ والتقسيم دي مهمة، مش شكلية: انحراف اتعمل قبل ما تشوف أي نتيجة مختلف تماماً عن انحراف اتعمل بعدها. الأول مستحيل يكون متحيّز لنتيجة معيّنة، لأنها لسه مش موجودة أصلاً؛ الثاني ممكن يكون. عشان كده كل مدخل في المجموعة الثانية بيقول صراحة إنه بعدي، وإيه اللي دفعه، وهل بيأثر على نتيجة مسجلة مسبقاً ولا لا.

9.2 Real Bugs Caught — أخطاء حقيقية اتمسكت، وإزاي

- ★ الغلط الأخطر: اختلال محاذاة صامت. لما رتبنا سلاسل M4 بـ `unique_id = str(i)`، مكتبة statsforecast رجّعت الصفوف بترتيب أبجدي: "0"، "1"، "10"، "100"، "1000"... بينما الكود بيعيد التشكيل على أساس ترتيب رقمي. النتيجة: كل تنبؤ اتقرن بالسلسلة الغلط. ومفيش أي رسالة خطأ — الكود اشتغل عادي!
- اكتشفناه إزاي؟ لأن SeasonalNaive طلع MASE = 28.9، وده مستحيل: هو أساساً مقام الـ MASE، فلازم يبقى حوالي 1.
- الدرس (وده أهم درس هندسي في المشروع): لازم يبقى معاك دايماً رقم واحد على الأقل تعرف قيمته الصحيحة مسبقاً. عشان الغلط الصامت يبقى مستحيل مش بس مستغرب. والحل: `f"{i:07d}"` — أصفار في الأول عشان الترتيب الأبجدي = الرقمي.

غلط ثاني: الـ Diebold-Mariano غير الصالح (شرحناه في 3.5) — اتمسح.

غلط ثالث: ادعاء إن "كل DOI اتحقق منه عبر Crossref" كان غير دقيق — السكربت كان بيراجع قائمة مكتوبة بالإيد موازية للـ refs.bib، والاتنين افترقوا، و6 DOIs في المراجع مراجعوش خالص (كلهم arXiv، و Crossref ميخدمهاش أصلاً). اتصلّح: السكربت دلوقتي بيقرأ الـ bib نفسه ويحلّ الـ DOI عبر doi.org اللي بيرد عن Crossref و DataCite دلوقتي 30 من 30 بيتحلّوا.

9.3 Archiving and Publication — الأرشفة والنشر

- **المستودع العام:** (172//https: github.com/ebrahimkhaled/timesfm-classical-paper ملف، 115 ميجا: الكود كامل + المقاييس لكل سلسلة في الـ 129,600 تقييم + التنبؤات الخام + الأشكال + مصدر المخطوطة).
- **Zenodo:** بالطريقة المعتادة — تفعيل المستودع من موقع Zenodo، وبعدين عمل release على GitHub، والـ webhook ببسك الـ DOI لوحده. وملف `zenodo.json`. موجود في جذر المستودع فـ Zenodo بياخد العنوان والـ ORCID والرخصة منه أوتوماتيك.
- **ليه ننشر التنبؤات الخام؟** مش للكمال — عشان نتيجة الطلب المتقطع **بتنقلب** بين المقاييس، فأني قارئ عايز يعيد التقييم بدالة خسارة مختلفة يقدر **من غير ما يعيد الدراسة كلها**.
- **arXiv:** الحزمة اتبنت واثققت في **غرفة نظيفة** (extract في مجلد فاضي + compile) — صفر أخطاء، صفر مراجع غير معرّفة. الفئة الأساسية `stat.ME` مع cross-list على `stat.AP` و `cs.LG`.
- **أوزان الموديل مش متعادة نشرها** — رخصتها غير تجارية، والكود بينزلها من Hugging Face.

الملف ده شرح مصاحب للورقة. الأرقام كلها متطابقة مع ملفات النتائج في `results/`.