

شرح الورقة بالمصري — Foundation or Formula?

يعني إيه "Formula" و يعني إيه "Foundation"؟

عنوان الورقة بيحط كلمتين قدام بعض. خرينا نفهمهم الأول، لأن الورقة كلها مبنية على المقارنة بينهم.

1) ال Formula — "الصيغة"، الطريقة القديمة

ال Formula معناها **معادلة رياضية** إنت بتفترضها وبعدين بتطبط أرقامها على بياناتك.

مثال: **ARIMA** بتقول لك إن قيمة النهارده = معادلة فيها قيم الأيام اللي فاتت + الأخطاء اللي فاتت. المعادلة نفسها إنت اللي بتختارها، والكمبيوتر بيحدد الأرقام (ال parameters) اللي جواها من بياناتك إنت لوحدك.

خصائصها:

- صغيرة جداً — 3 أو 4 أرقام بس.
- بتتعلم من سلسلتك إنت بس — معندهاش أي معرفة سابقة بالدنيا.
- مفهومة — تقدر تبص على الأرقام وتفهم الموديل بيقول إيه وليه.
- قديمة ومجربة — بقالها 50 سنة في الكتب والصناعة.

من ديه: **ARIMA** ، **ETS** ، **Theta** ، **Seasonal Naive**.

2) ال Foundation — "الأساس"، الطريقة الجديدة

ال Foundation Model معناها شبكة عصبية ضخمة اتدربت مرة واحدة على ملايين السلاسل الزمنية من الدنيا كلها، وبعدين بتديها سلسلتك إنت فتتنبأ ليك من غير ما تدربها من أصله. ودي اللي بيسمونها **zero-shot**.

TimesFM-3 من ديه: 330 مليون رقم جواه، متدرب على أكثر من تريليون نقطة زمنية.

خصائصها:

- ضخمة — 330 مليون رقم مقابل 3.
- بتعرف حاجات من بره سلسلتك — شافت ملايين السلاسل قبل كده.
- مقفولة — مش هتتعرف تبص جواها وتفهم قرارها.
- جديدة — الحاجات دي طلعت في آخر سنتين.

الكلمة المفتاحية: مصدر المعرفة

الفرق الحقيقي بينهم مش "قديم وجديد" ولا "صغير وكبير" — الفرق هو المعرفة جاية منين:

Foundation	Formula	
من ملايين السلاسل التي اتدربت عليها	من سلسلتك إنت بس	بتعرف من فين؟
مفیش — بتشتغل على طول	بيانات كفاية عشان تقدّر معادلتها	محتاجة إيه؟
لما بياناتك قليلة أو شكلها غريب	لما يبقى عندك بيانات كتير وشكلها واضح	بتنفع إمتى؟

تشبيه: ال Formula زي **دكتور خريج لسه** بس معاه كتاب مطبوط: لو الحالة موصوفة في الكتاب بالطبط، هيبقى ممتاز. وال Foundation زي **دكتور شاف مليون حالة:** مش معاه كتاب، بس عنده **حدس** قوي — ولو الحالة نادرة هيبقى أحسن منه بكتير.

وعشان كده العنوان سؤال

"Foundation or Formula?" يعني: **أستخدم الوحش الضخم اللي شاف الدنيا، ولا المعادلة الصغيرة المفهومة؟**

والورقة **مش** بتجاوب "ده أحسن من ده". بتجاوب: **إمتى ده وإمتى ده** — وبأرقام متختبرة إحصائياً مش بآراء.

من الآخر: Formula = معادلة صغيرة بتتعلّم من بياناتك إنت. Foundation = شبكة ضخمة اتعلّمت من بيانات الدنيا. والسؤال هو مين فيهم ينفعك، **إمتى**.

0. The Big Idea in One Breath — الفكرة الكبيرة في نفس واحد

قبل ما ندخل في أي تفصيلة، خد الصورة كلها في دقيقة:

Google نزلت موديل اسمه **TimesFM-3** بيتنبأ بالسلاسل الزمنية (time series) من غير ما تدّربه على بياناتك خالص — بيسمّوا ده **zero-shot**. السؤال العملي: أنا ك محلل، لو قدامي سلسلة زمنية، أستخدم الموديل الجبار ده ولا أستخدم **ARIMA** القديمة الكويسة؟

الورقة دي بتجاوب على السؤال ده. وأهم حاجة فيها إننا **مخترعناش طريقة جديدة** — دي دراسة مقارنة (comparative study)، وقلناها بصراحة في الورقة. اللي يخليها تستاهل النشر حاجة ثانية: **إحنا مولّدا البيانات بنفسنا**، والسبب هنشره بعد شوية وهو قلب الموضوع كله.

النتيجة باختصار: **مفیش طرف كسب**. لكن الطريقة اللي "مكسبش" بيها كل طرف هي الحكاية الحلوة.

من الآخر: الورقة مش بتقول "ال AI كسب" ولا "الكلاسيكي أحسن" — بتقول **إمتى** ده وإمتى ده، وبأرقام متختبرة إحصائياً.

1. What Is TimesFM-3? — إيه هو ال TimesFM-3 أصلاً؟

في 31 أغسطس 2026 نزلت Google الجيل الثالث من موديلها **TimesFM**. خصائصه:

- **330 مليون parameter** (بالطبط 330,710,976 — إحنا عدّيناهم من ال checkpoint نفسه مش نقلاً عن حد).
- متدرّب على **أكثر من تريليون نقطة زمنية** (time points)، بيانات حقيقية و بيانات صناعية (synthetic).

- أول واحد في العيلة متدرّب أصلاً على الـ **multivariate** — يعني ياخذ أكثر من سلسلة مع بعض، ويقدر ياخذ **covariates** (متغيرات مساعدة) سواء من الماضي أو معروفة للمستقبل.
- يستخدم **attention** بالتبادل: مرة على المحور الزمني (causal-temporal) ومرة على محور المتغيرات (full-variant).
- **بيطلع الأفق كله في مرة واحدة** (non-autoregressive) — يعني مش بيتنبأ بخطوة ويرجع يدخلها عشان يتنبأ باللي بعدها.
- **quantiles 9** (من **q0.1** لـ **q0.9**) — يعني مش رقم واحد، دا توزيع.
- طول الـ context بيوصل **16k** نقطة.
- **تشبيه:** تخيل دكتور اتخرج ومشتغلش في مستشفى واحدة بس — لأ، ده اتفرّج على مليون حالة من مستشفيات الدنيا كلها. لما ييجي يشوف مريضك، هو معندوش ملف مريضك بس عنده **حدس** اتبنى من كل اللي شافه. ده بالطبط معنى **zero-shot** : مشافش سلسلتك، بس شاف حاجات شبهها كتير أوي.
- **من الآخر:** **TimesFM-3** = موديل ضخم بيتنبأ من غير تدريب، وبيديك توزيع مش رقم.

2. Why the Published Evidence Is Not Enough — ليه الأدلة المنشورة مش كفاية؟

هنا لب المشكلة، وده اللي بنى عليه البحث كله.

لما شركة تنزل موديل، بتقولك "بص، كسبت على الـ benchmarks الفلانية". المشكلة إن الـ benchmarks دي بيانات عامة **ومنشورة على الإنترنت**، والموديل اتدرّب على... الإنترنت.

باحثين اسمهم Meyer وزماليه (2025) عملوا حاجة مهمة: تتبّعوا **نسب البيانات** لـ 22 موديل foundation model للسلاسل الزمنية. لقوا إن من **dataset 401** استُخدمت في تقييمهم، **6% بس** هي اللي **مظهرتش** في corpus التدريب بتاع أي موديل منهم.

يعني إيه؟ يعني 94% من التقييمات دي، الموديل يمكن يكون **شايف الإجابة قبل الامتحان**.

وأكثر من كده: لقوا إن تداخل بنسبة **0.1% بس** بين بيانات التدريب وبيانات الاختبار ممكن يحرك الـ MAPE بمقدار **8 لـ 29 نقطة مئوية**. ودي مش نسبة صغيرة، دي فرق بين موديل ممتاز وموديل فاشل.

وكمان — والنقطة دي ذكية — التسريب (leakage) مش لازم يكون **مباشر**. لو الموديل اتدرّب على سلسلة تانية **متداخلة زمنياً** ومرتبطة سببياً بسلسلتك، هو كده أخذ ميزة على سلسلتك حتى لو عمره ما شافها.

تشبيه: طالب ذاكر من بنك أسئلة، والامتحان جه 94% منه من بنك الأسئلة ده. درجته العالية معناها إيه بالطبط؟ مش عارفين. ودي بالطبط مشكلة الـ benchmarks.

فيه كمان انتقاد تاني اتقال كتير على الأوراق دي: بيقدروا الموديل الجبار بـ baselines كلاسيكية **مفكوكة وغير متظبطة** — يعني ياخدوا **ARIMA** لوحدها بدل ما ياخدوا الـ **combination** اللي بتكسب في مسابقات التنبؤ زي **M4**. ده زي ما تقارن فريقك بلاعب واحد من الفريق التاني.

من الآخر: أي رقم من benchmark عام = قياس **مجهول المصدر**، ولازم نلاقي طريقة تانية.

3. The Idea That Closes Both Objections — الفكرة اللي بتقفل الاعتراضين مع بعض

الحل اللي الورقة اختارته: إحنا نوّلد البيانات بنفسنا.

لما نوّلد سلسلة من عملية معروفة (Data-Generating Process — واختصارها DGP)، بيحصل حاجتين في نفس اللحظة، وده اللي بيدي المقارنة قوتها:

1. **الموديل قطعاً مشافش السلسلة دي** — مش "على الأغلب"، لأ؛ السلسلة دي **معملتش أصلاً** غير لما شغلنا التجربة. فمستحيل تكون في corpus التدريب.

2. **الموديل الكلاسيكي بيبقى "صح بالتعريف"** (correctly specified by construction) — لو البيانات فعلاً **ARIMA(1,1,1) with drift**، بيبقى **AutoARIMA** مش تقرب للحقيقة، دي هي الحقيقة نفسها، وفاضل بس إنه يقدر ال parameters.

النقطة الثانية دي هي السر. عشان كده السؤال بقى حاد ومحدد:

- الموديل بيخسر قد إيه لما يلعب على أرض الكلاسيكي (يعني الشكل الرياضي صح 100%)؟
- ويكسب قد إيه لما مفيش شكل كلاسيكي صح (كسر هيكل، لا خطية، طلب متقطع، تقلّب)؟

⚠️ تفرقة مهمة جداً — لازم تكون أمينة

فيه حاجة لازم نقولها بصراحة، وقلناها في الورقة:

- اللي التصميم بتاعنا **بيمنعه** هو التلوث على مستوى **التحقق الفردي** (the realisation) — السلسلة دي بالذات مكتتش موجودة.
- اللي التصميم **مش** بيمنعه هو الألفة على مستوى **العيلة** (the family). يعني **TimesFM-3** اتدرب على بيانات **صناعية** كمان، والبيانات الصناعية لل time-series models عادةً بتتولد من نفس العائلات دي بالظبط (AR, ARMA, seasonal..). فهو **يعرف الشكل العام** حتى لو مشافش النسخة دي.

عشان كده عنوان الورقة بيقول "**A Simulation-Based Comparison**" — بيوصف الطريقة (محاكاة) من غير ما يدّعي إن الموديل مايعرفش نوع البيانات، لأن ده ادعاء أوسع من اللي التصميم بيثبتته.

من الآخر: إحنا مولدنا البيانات عشان نضمن حاجتين: الموديل مشافهاش، والكلاسيكي صح بالتعريف. بس مدّعينا إن الموديل مش عارف نوع البيانات — دي أمانة علمية مش تواضع.

4. Design of the Simulation — تصميم دراسة المحاكاة

4.1 The Nine DGPs — التسع عمليات المولدة للبيانات

اخترنا 9 عمليات بحيث تغطي المدى من "الكلاسيكي صح تماماً" لـ "مفيش كلاسيكي صح":

الرمز	العملية	الشرح بالمصري	مين "صح" فيها؟
D1	AR(1), $\phi=0.7$	القيمة النهارده = $0.7 \times$ امبارح + عشوائية. أبسط حاجة ممكنة.	ARIMA
D2	ARMA(1,1)	زي فوق + بتفتكر الخطأ بتاع امبارح كمان.	ARIMA
D3	ARIMA(1,1,1) + drift	فيها اتجاه (trend) — بتمشي لفوق بمعدل ثابت + عشوائية.	ARIMA
D4	SARIMA(1,0,0)(1,1,0)[12]	فيها موسمية قوية كل 12 شهر (زي مبيعات رمضان).	ARIMA
D5	ETS(A,A,A)	مستوى + اتجاه + موسمية، بس بصيغة الـ state-space.	ETS
D6	Local level + كسر هيكلي	ماشية عادي وفجأة تقفز قفزة (زي زيادة سعر).	ولا واحد
D7	Logistic growth	نمو بيتشبع (S-curve) — بيطلع بسرعة وبعدين يقف.	ولا واحد
D8	Intermittent demand	طلب متقطع : 70% أصفار، وبين الحين والتاني طلبية.	ولا واحد
D9	AR(1) + GARCH(1,1)	المتوسط صح، بس التذبذب نفسه بيتغير (فترات هدوء وفترات جنون).	ARIMA في المتوسط بس


ليه اخترنا D6 بالكسر جوه الـ context مش في المستقبل؟ دي نقطة تصميم مهمة جداً. لو حطينا الكسر في الفترة اللي بنتنبأ بيها، مفيش طريقة في الدنيا تقدر تتنبأ بيه — فالتجربة كانت هتقيس بس "مين أكثر واحد محافظ ومش بيتحرك". لكن لما نحطه جوه البيانات اللي الموديل شافها (عند $0.7 \times n$)، السؤال يبقي عادل ومحترم: "إنت شفت المستوى اتغير — هتتنبأ من المستوى الجديد ولا هترجع للقديم؟"

ليه D7 نقطة الانقلاب عند 0.6 من السلسلة؟ عشان الفترة اللي بنتنبأ بيها تقع في الجزء اللي بيتشبع. أي طريقة بتركب خط مستقيم (drift) هت تعدي فوق (overshoot). وده بالضبط اللي عايزين نكشفه.

4.2 Lengths, Replications, Horizon — الأطوال والتكرارات والأفق

- **أطوال السلاسل:** $n \in \{24, 48, 96, 200\}$. الـ 24 دي قاسية بشكل مقصود: مع موسمية 12، يبقى عندك دورتين موسميتين بس. وهنشوف بعدين إن ده بيفرق حاجة كانت الناس بتخلط بينها.
- **التكرارات:** 200 تكرار لكل خلية (DGP × طول).
- **إجمالي السلاسل:** $200 \times 4 \times 9 = 7,200$ سلسلة.
- **الأفق (horizon):** $H = 12$. بنولد $n + 12$ نقطة، أول n بندّيها للموديل، وآخر 12 بنخبّيها ونقارن بيها.
- **الـ Seeding:** كل سلسلة ليها seed محسوبة من هويّتها: رقم الطول + رقم التكرار × $1,000$ + DGP رقم الـ $seed = 1,000,000 \times$. يعني السلسلة بتتعداد بالضبط من غير ما يفرق عدد الأنوية اللي شغالة ولا ترتيب التنفيذ.

من الآخر: 9 عمليات × 4 أطوال × 200 تكرار = 7,200 سلسلة، كل واحدة ليها seed ثابتة، فأني حد يقدر يعيد نفس الأرقام بالضبط...



شكل 1 — عينة واحدة من كل عملية من التسعة (عند $n = 96$). الجزء الرمادي هو البيانات التي الموديل يبشورها، والجزء الملون في الآخر هو الـ 12 نقطة المخبئية التي بنقيس عليها. بَص على **D6** : الكسر الهيكلي واضح عند النقطة 67 تقريباً — يعني 96×0.7 بالظبط زي ما صمّمناه. وبَص على **D8** : معظمها أصفار، وده اللي هيبيّوظ الـ **MAPE** بعدين.

5. The Methods Compared — الطرق اللي اتقارنت

مفيش أي طريقة اتطبقت بالإيد. كل طريقة كلاسيكية شغالة بالاختيار الأتوماتيكي بتاعها — لأن ده الوضع اللي المحلل الحقيقي بيقابله.

الطريقة	الشرح بالمصري
TimesFM3	الموديل بتاع Google، zero-shot، من غير تدريب ولا تطبيق.
SeasonalNaive	أغبي طريقة ممكنة: "النهارده هيبقى زي نفس اليوم السنة اللي فاتت".
Theta	الطريقة اللي كسبت مسابقة M3 — بتفكك السلسلة وتعيد تركيبها.
AutoETS	Exponential smoothing بيختار الشكل أوتوماتيك (Hyndman-Khandakar).
AutoARIMA	ARIMA بيدور على ال orders أوتوماتيك.
Combination	متوسط ال 3 دول: AutoARIMA. + AutoETS + Theta

ليه ال Combination إجباري مش اختياري؟

عشان أشهر انتقاد بيتقال على أوراق ال foundation models هو إنهم بيقارنوا نفسهم بطرق كلاسيكية مفكوة. ال state of the art الكلاسيكي هو **الدمج** مش الطريقة الواحدة. لو شلناه، يبقى إحنا بنينا النتيجة اللي عايزينها **جوه التصميم** نفسه — وده غش منهجي.

⚠ ملاحظة أمانة: عدم تماثل في المعلومات

فيه حاجة قلناها في الورقة بصراحة لأنها في **صالح الكلاسيكي**: كل الطرق الكلاسيكية بندّيها **الفترة الموسمية الحقيقية** (m = 12) كمعلومة جاهزة، بينما **TimesFM-3** بياخد السلسلة الخام من غير ما نقوله إن فيها موسمية أصلاً ولا طولها كام. يعني الكلاسيكي واخد مساعدة.

من الآخر: 6 طرق، الكلاسيكي واخد مساعدة (الموسمية جاهزة)، وال Combination موجود عشان المقارنة تبقى شريفة.

6. The Metrics — المقاييس، وإزاي بنقيس "الغلط"

6.1 Point Metrics — مقاييس النقطة الواحدة

MASE (المقياس الأساسي): الخطأ المطلق مقسوم على خطأ ال seasonal naive داخل العينة.

$$\text{MASE} = \frac{\frac{1}{h} \sum_{i=1}^h |y_i - \hat{y}_i|}{\frac{1}{n-m} \sum_{t=m+1}^n |y_t - y_{t-m}|}$$

تفكيك المعادلة رمز رمز:

- y_i — القيمة الحقيقية في الخطوة رقم i من الفترة اللي بنتنبأ بيها.
- $\hat{y}_i$ — القيمة المتوقعة من الموديل لنفس الخطوة. (القبعة فوق الحرف معناها "تقدير").
- h — طول الأفق، يعني كام خطوة بنتنبأ بيها. عندنا $h = 12$.
- n — طول السلسلة المعروفة اللي الموديل شافها.
- m — الفترة الموسمية. عندنا $m = 12$ للسلاسل الموسمية، و $m = 1$ لغيرها.

والكسر نفسه:

- **البسط** — متوسط الخطأ المطلق **بتناك** في الفترة المتنبأ بها. يعني: بتغلط بكام في المتوسط؟
- **المقام** — متوسط خطأ "أغبي طريقة" (ال: seasonal naive: ال) النهارده زي نفس اليوم في الدورة اللي فاتت"، محسوب على البيانات **الي إنت شايفها** مش على المستقبل.

وإزاي تقرا الرقم الناتج؟

- $MASE = 1$ — إنت **بالظبط زي** الطريقة الغبية.
 - $MASE < 1$ — إنت **أحسن** منها. يعني **0.68** معناها خطأك 68% من خطأها.
 - $MASE > 1$ — إنت **أوحش** من الطريقة الغبية! وده بيحصل فعلاً — شوف **AutoETS** في القسم 8.3.
- ليه القسمة دي مهمة؟** عشان تقدر تجمع نتايج من سلاسل مقاييسها مختلفة تماماً — سلسلة أرقامها بالملايين وسلسلة أرقامها بالعشرات — من غير ما الكبيرة تبلع الصغيرة.
- RMSSE** : نفس الفكرة بالظبط بس بالتربيع بدل المطلق (زي ما في مسابقة **sMAPE**). (**M5** : نسبة مئوية متماثلة، مدى من 0 لـ 200.

6.2 Why MAPE Is Not the Headline — ليه ال MAPE مش المقياس الأساسي

ال **MAPE** هو أشهر مقياس عند الناس، ومع ذلك حظينه في **الملحق** بس. ليه؟

1. **غير معرّف عند الصفر** — القسمة على صفر. وفي **D8** (الطلب المتقطع) 70% من القيم أصفار!
 2. **غير متماثل** — بيعاقب المبالغة في التقدير أكثر من التقليل. فهو **بيحابي** الطرق المتحفظة.
 3. **بيقلب الترتيب** — وده مش كلام نظري، ده حصل في بياناتنا فعلاً.
- الرقم اللي بيثبت الكلام ده:** ال MAPE طلع **غير معرّف في 12,906 من 129,600** تقييم — يعني **9.96%** — وكلهم **بالظبط** في **D8**.

يعني لو كنا اعتمادنا على ال MAPE، كنا هنضطر **نшил النظام اللي فيه أقوى نتيجة عندنا** من المقارنة خالص، أو نخترع اتفاقية للأصفار من دماغنا.

من الآخر: ال MAPE مقياس مشهور لكنه بيكذب لما فيه أصفار — و **D8** كلها أصفار، فمينفعش يكون الأساس.

6.3 Probabilistic Metrics — مقاييس التوزيع مش النقطة

الموديلات دي مش بتديك رقم واحد، بتديك **توزيع**. فلازم نقيس التوزيع نفسه:

- **Pinball loss** (خسارة ال quantile): بنحسبها على ال 9 deciles كلها، ومقسومة على نفس مقام ال MASE عشان تبقى قابلة للمقارنة. دي **proper scoring rule** يعني مقياس شريف رياضياً.
- **Coverage** : الفترة اللي قلت عليها 80% — هل الحقيقة وقعت جواها 80% من المرات فعلاً؟
- **Width** : عرض الفترة. ودي مهمة أوي — هنشوف ليه كمان شوية.

⚠ **ليه 60% و 80% ومفيش 90%؟**

دي نقطة تصميم مقصودة: **TimesFM-3** بيطلع ال **deciles** بس (من **q0.1** لـ **q0.9**). فمفيش عندك **q0.05** ولا **q0.95** عشان تعمل فترة 90%. لو قارنا فترة 90% كلاسيكية بفترة معمولة بالاستقراء (extrapolation) من الموديل، تبقى

مقارنة **مش عادلة**. فأخذنا أوسع فترة **الاثنين** يقدروا يعبروا عنها: $[q0.1, q0.9]$.

من الآخر: بنقيس النقطة (MASE) والتوزيع (pinball) والفترة (width + coverage) — الثلاثة، مش واحد.

7. The Statistical Tests — الاختبارات الإحصائية

مش كفاية نقول "المتوسط ده أقل من ده". لازم **نختبر**.

7.1 Paired Wilcoxon — الاختبار الأساسي

جوه كل خلية (DGP × طول × أفق)، بنقارن **TimesFM-3** بكل طريقة كلاسيكية باختبار **Wilcoxon signed-rank** المزدوج على فروق الـ MASE بين الـ 200 تكرار.

ليه Wilcoxon مش t-test؟ لأنه **مش يفترض التوزيع الطبيعي**، وتوزيعات الخطأ في التنبؤ تبقى ملتوية (skewed) بشكل بشع. بس برضه بنحسب الـ **t-test** كـ **sensitivity check**.

7.2 Why NOT Diebold–Mariano — ليه رفضنا اختبار Diebold–Mariano

دي نقطة منهجية مهمة، والأدب المنشور يستخدم **DM** بشكل شبه تلقائي.

الـ **DM** **متصمم** لسلسلة فروق خسارة **مترابطة زمنياً** (autocorrelated) جاية من **سلسلة واحدة** عبر الزمن. عندنا في المحاكاة، الـ 200 تكرار دول **سحوبات مستقلة** من نفس العملية — مفيش ترتيب زمني بينهم أصلاً! فلو استخدمنا DM هنبقى بنوصف بنية اعتماد **مش موجودة**.

وفي بيانات **M4** الحقيقية، التصميم بتاعنا فيه **3 origins** بس لكل سلسلة، يعني الإحصاء هتبقى بـ **درجتين حرية** — يعني مفيش قوة إحصائية خالص.

⚠ **وحصل غلط حقيقي هنا اكتشفناه بالمراجعة:** في نسخة أولى، الكود حسب DM على **مقطع عرضي** (cross-section) من 1000 متوسط مرتبين **أبجدياً** بحسب اسم السلسلة! يعني التصحيح كان بيجمع autocovariances عبر سلاسل **مالهاش علاقة ببعض** وبترتيب **عشوائي تماماً**. الدليل القاطع: الإحصاء طلعت **-13.97** بالترتيب ده، وبين **-18** و **-23** لما نخلط الترتيب عشوائياً. حاجة بتتغير 30-70% لما تخلط فهرس عشوائي دي **مش اختبار**. فقررنا **نمسحها خالص** مش نصلحها، لأن مفيش نسخة منها التصميم ده بيسمح بيها.

7.3 Multiplicity — التصحيح للمقارنات المتعددة

إحنا بنعمل 180 مقارنة. لو كل واحدة عند 5%، يبقى متوقع نلاقي 9 نتائج "معنوية" **بالصدفة البحتة**. فبنستخدم **Benjamini–Hochberg** للتحكم في الـ False Discovery Rate عند 0.05، ونببلغ الـ p الخام والمصحح.

7.4 Effect Sizes — أحجام الأثر

مع كل اختبار نببلغ:

- **Hodges–Lehmann**: تقدير للفرق الوسيط.
- **نسبة الـ MASE الوسيطة**: عشان تشوف الفرق **عملياً** يعني إيه.

ليه؟ عشان فرق ممكن يبقى **معنوي إحصائياً** وهو **تافه عملياً**. مع 200 تكرار، فرق 0.2% ممكن يطلع معنوي. لازم القارئ يشوف ده.

من الآخر: بنختبر كل فرق، بنصح للمقارنات المتعددة، وبنقول حجم الفرق مش بس هل هو معنوي.

8. The Results — النتائج

التصميم طلع 7,200 سلسلة، ومع 6 طرق و 3 شرائح أفق = 129,600 تقييم.

8.1 A Split Decision, Not a Rout — قرار منقسم مش كاسح

لو عدّينا **مين كسب في كل خلية** من الـ 36 خلية (DGP × طول):

الطريقة	عدد الخلايا اللي كسبتها
TimesFM3	16
AutoARIMA	10
SeasonalNaive	4
Theta	2
Combination	2
AutoETS	2

يعني الكلاسيكي كسب 20 والموديل كسب 16. القراءة السطحية: "الكلاسيكي كسب".

بس دي قراءة ناقصة، وهنا بيت القصيد: الـ 20 دول **متوزعين على 5 طرق مختلفة!** يعني عمود الكلاسيكي هو عمود **فايزين مختلفين**، وإنت **معندكش طريقة تعرف مقدماً** مين منهم هيكسب على سلسلتك من غير ما تعمل الشغل اللي الـ foundation model المفروض يوفره عليك.

ولما نختبر ضد **أحسن** طريقة كلاسيكية في كل خلية: **18 من 36 فرق** نجوا من تصحيح BH — **7 لصالح TimesFM-3 و 11 لصالح الكلاسيكي**، و**18 خلية تعادل**.

8.2 Who Actually Holds Their Ground — مين بيصمد قدامه فعلاً؟


خلينا نبص على الـ 180 مقارنة الثنائية. منها **132 معنوية: 113 لصالح TimesFM-3 و 19 لصالح الكلاسيكي**. التفصيل حسب الخصم:

الخصم	مقارنات معنوية	كسب TimesFM-3	كسب الخصم
AutoARIMA	20	11	9
SeasonalNaive	26	22	4
AutoETS	27	25	2
Theta	29	28	1
Combination	30	27	3

الجدول ده هو رسالة الورقة المركزية. بَصّ على السطر الأول: **AutoARIMA** هو الوحيد اللي بيصمد (11 مقابل 9، يعني عملة معدنية). كل اللي غيره — حتى دمج الثلاثة مع بعض — بيتغلب في الغالبية العظمى.

يعني إيه عملياً؟

- محلل بيختار **AutoARIMA** صح كل مرة → مش هيخسر حاجة لو فضل كلاسيكي.
 - محلل مش بيعرف يختار، أو معندوش وقت يظبط كل سلسلة → أحسن له بكتير يستخدم الـ foundation model.
- من الآخر: الموديل مش بيكسب على أحسن طريقة، لكنه بيكسب على متوسط الطرق — وقيمتة إنك مش محتاج تعرف أنهي طريقة تختار.



شكل 2 — دقة **TimesFM-3** بالنسبة لأحسن طريقة كلاسيكية في كل خلية. العمود اللي تحت الصفر معناه **TimesFM-3** أدق، واللي فوق الصفر معناه الكلاسيكي أدق. شوف **D8** (الطلب المتقطع) نازل تحت بوضوح في الأطوال الأربعة، و **D4** (الموسمية) طالع فوق في الأربعة — دول النظامين الحاسمين اللي هنتكلم عنهم في 8.5. والباقي قريب من الصفر، يعني تعادل.

8.3 ★ Specification Is Not Estimability — التخصيص الصحيح مش زي القابلية للتقدير

دي أهم نتيجة في الورقة كلها. وعشان تبقى واضحة، خلينا نبني الفكرة من الأول بالراحة قبل ما نشوف أي رقم.

الخطوة 1: يعني إيه "الموديل مخصّص صح"؟
التخصيص (Specification) = الشكل الرياضي اللي إنت افترضته.

في المحاكاة بتاعتنا، عملية **D5** بتولّد البيانات من معادلة **ETS(A,A,A)** — يعني مستوى + اتجاه + موسمية. وطريقة **AutoETS** هي بالظبط اللي بتفترض الشكل ده.

يعني إيه؟ يعني **الشكل مضبوط 100%**. مش تقريب ولا اجتهد — دي **الحقيقة نفسها**. الموديل عارف إن فيه مستوى، وعارف إن فيه اتجاه، وعارف إن فيه موسمية بفترة 12. كل ده **صح**.

فالمفروض يكسب، صح؟ ده اللي إحنا كمان توقّعناه وسجّلناه كـ **فرضية H1**.

الخطوة 2: بس الشكل الصح مش كفاية — لازم تعرف الأرقام
هنا المفتاح اللي بيغيّر كل حاجة.

معرفة الشكل حاجة، ومعرفة **الأرقام اللي جوه الشكل** حاجة تانية خالص. والأرقام دي إنت لازم **تقدّر**ها من **البيانات اللي قدامك**.

فخلينا نعدّ: **ETS(A,A,A)** بموسمية 12 — كام رقم لازم يتقدّر؟

اللي لازم يتقدّر	العدد
معاملات التنعيم: γ, β, α	3
المستوى الابتدائي ℓ_0	1
الاتجاه الابتدائي b_0	1
الحالات الموسمية الابتدائية (11 حرة من 12)	11
الإجمالي	16 رقم

دلوقتي السؤال الحاسم: عندك كام نقطة بيانات عشان تقدّر الـ 16 رقم دول؟

- عند **$n = 200$** ← عندك **12.5 نقطة لكل رقم**. مرتاح جداً.
- عند **$n = 24$** ← عندك **1.5 نقطة لكل رقم فقط!**


تخيّل الموقف: إنت بتحاول تحدّد 16 مجهول من 24 معادلة. ده رياضياً ممكن بالعافية، بس البيانات فيها ضوضاء (noise)، فاللي بيحصل إن الموديل **بيحفظ الضوضاء** بدل ما يتعلّم النمط — وده اسمه **overfitting**. وبيطلع تنبؤ كارثي.

تشبيه: عندك وصفة أكل مضبوطة 100% من شيف عالمي — الوصفة بتقول "حط 16 نوع بهارات بنسب معيّنة". بس مطبخك فيه **مكوّنين بس**. الوصفة **صح**، إنما إنت **مش قادر تنفّذها**. والراجل اللي بيطبخ بالفطرة من غير وصفة أصلاً هيطلع أكل أحسن منك.

الخطوة 3: الفرق بين الاثنين في جملة

السؤال	التخصيص (Specification)	القابلية للتقدير (Estimability)
بيعتد على	العملية اللي ولدت البيانات	طول السلسلة اللي قدامي
D5 على AutoETS	صح دائماً ✓	صح عند $n \geq 48$ ، فاشل عند $n = 24$

الخطوة 4: الدليل — نفس الموديل، من الأسوأ للأحسن



شكل 6 — ليه الموديل المخصص صح ممكن يقع. الشمال: AutoETS لازم يقدر 16 رقم؛ عند $n = 24$ عنده 1.5 نقطة لكل رقم (الأحمر) وعند $n = 200$ عنده 12.5 (الأزرق). اليمين: النتيجة — على D5 ، وهي العملية اللي AutoETS مخصص ليها صح، بيبدا كارثة عند 3.03 (أسوأ واحد في الستة!) وينتهي الأحسن عند 0.68.

بص على الخط البرتقالي كويس: الموديل متغيرش. البيانات جاية من نفس العملية بالظبط. اللي اتغير هو طول السلسلة بس. ومع ذلك النتيجة اتقلبت من الأسوأ للأحسن.

والأرقام بالتفصيل عند $n = 24$:

الطريقة	MASE على D5 عند $n=24$	إيه اللي بتقدره؟
AutoETS	3.025 ← المخصص صح!	16 رقم من 24 نقطة
SeasonalNaive	1.139 ← أغبي قاعدة	صفر — مفيش حاجة تقدر
TimesFM3	1.152	صفر — متدرب قبل كده

العمود التالت هو التفسير كله. SeasonalNaive بتقول "النهارده زي نفس الشهر السنة اللي فاتت" — مفيش أي رقم بتقدره، فمفيش حاجة تغلط فيها. و TimesFM-3 كمان مبيقدرش حاجة من سلسلتك — هو جاي ومعاها معرفة مسبقه من تريليون نقطة. الاتنين محصنين ضد مشكلة قلة البيانات، و AutoETS مش محصن.

يعني AutoETS خسر بفارق 2.7 مرة قدام قاعدة من سطر واحد — على بيانات عملية ETS هي اللي ولدتها بنفسها!

الخطوة 5: نفس الحكاية في D4

مش حالة شاذة. في D4 (الموسمية الـ SARIMA) نفس الحاجة:

- عند $\text{AutoARIMA} = 2.284$: $n = 24$ ، و $\text{SeasonalNaive} = 1.029$. الكلاسيكي الأوتوماتيكي المخصّص صح **خسر** قدام القاعدة الغبية.
- عند $\text{AutoARIMA} = 0.886$: $n = 200$ ، بقى الأحسن بفارق كبير.

نفس النمط: الشكل صح من الأول لآخر، بس **القدرة على تقديره** هي اللي بتتغيّر مع الطول.

الخطوة 6: وليه ده مهم عملياً؟

الفرضية **H1** اللي سَجَلناها كانت بتقول: "الكلاسيكي هيكسب على أرضه، والفرق هيبقى أكبر في السلاسل القصيرة". طلعت **مفندة** — والفرق في السلاسل القصيرة راح في **الاتجاه المعاكس**.

والدرس اللي تاخده معاك:

السؤال مش "الموديل بتاعي صح؟" — السؤال "عندي بيانات تكفي أقدره؟"

وده بيقولك **فين** الـ foundation models بتنفع بالضبط: **في المكان اللي التقدير الكلاسيكي فيه جعان بيانات**. مش لأنها "أذكى"، لكن لأنها **مش محتاجة تقدّر حاجة أصلاً** من سلسلتك — هي جاية ومعاها المعرفة جاهزة.

وبالعكس: لما يبقى عندك بيانات كتير ومرتاحة، الكلاسيكي بيرجع يكسب — زي ما شفنا عند $n = 200$.

من الآخر: الموديل الصح + بيانات قليلة = نتيجة وحشة. والقاعدة الغبية + صفر تقدير = نتيجة معقولة. الـ foundation model بيلعب في الخانة الثانية دي — بيجيب نتيجة معقولة من غير ما يقدر أي حاجة.

8.4 Robustness, Not Peak Accuracy — الموديل بيشتري المتانة مش الدقة القصوى

إزاي نقيس المتانة دي بشكل عادل؟

⚠ **خد بالك: أسوأ MASE مطلق هو المقياس الغلط هنا.** ليه؟ لأن **D3** صعبة على كل الطرق، فأسوأ الحالات المطلقة بتبقى محكومة **بالعملية دي** مش بهشاشة أي طريقة. الدليل: أسوأ حالة مطلقة عند **Theta** هي 4.483 — **أحسن** من بتاعة **TimesFM-3** (4.656) ! ولو مشينا بالمقياس ده يبقى **Theta** أثبت طريقة، وده كلام مايتقالش لما تبص على أدائه في **D4** (4.155 مقابل 0.886).

المقياس الصح: نسبة كل طريقة لـ **أحسن طريقة في نفس الخلية**. ده بيعزل الهشاشة لوحدها:

الطريقة	النسبة الوسيطة	المتوسط	أسوأ نسبة	أسوأ خلية
TimesFM3	1.008	1.054	1.31	D4, n=200
AutoARIMA	1.032	1.137	2.22	D4, n=24
Combination	1.108	1.273	3.00	D4, n=24
AutoETS	1.194	1.366	3.50	D4, n=24
SeasonalNaive	1.200	1.470	5.65	D7, n=48
Theta	1.251	1.614	4.69	D4, n=200

اقرأ الجدول ده كويس:

- TimesFM-3 عمره ما بقى أسوأ من 1.31 مرة من أحسن طريقة في أي خلية في التصميم كله.
- وفي الخلية الوسيطة هو في حدود 0.8% من الأحسن.
- بينما كل طريقة كلاسيكية بتبقى في مكان ما 2.2 مرة أسوأ على الأقل، وبعضها 4.7 و 5.6 مرة.

تشبيه: لاعب بيجيب 8/10 في كل ماتش، مقابل لاعب بيجيب 10/10 مرة و 3/10 مرة. اللي عايز يكسب البطولة كلها بياخد الأول.

من الآخر: TimesFM-3 نادراً ما ييبقى الأحسن، وأبدأ مش ييبقى كارثة. الكلاسيكي الأوتوماتيكي أحياناً ممتاز وأحياناً بيقع.

Two Decisive Regimes 8.5 — النظامين اللي فيهم قرار واضح

أ) موسمية قوية + بيانات تكفي ← استخدم AutoARIMA عند $n = 48, 96, 200$ في AutoARIMA ، D4 أحسن بـ 21.8% و 21.1% و 23.7% على الترتيب، وكلها بـ p مصحح > 0.0001 .

⚠️ وخذ بالك من قراءة النسبة — دي غلطة شائعة. النسبة 1.28 معناها إن TimesFM-3 أسوأ بـ 28%، لكنها مش معناها إن AutoARIMA أحسن بـ 28%. دول رقمين مختلفين:

$$\underbrace{1.28 - 1 = 28\%}_{\text{TimesFM-3 worse by}} \neq \underbrace{1 - \frac{1}{1.28} = 22\%}_{\text{AutoARIMA better by}}$$

عشان كده بنقول AutoARIMA أحسن بـ 21-24%. والقاعدة العامة: لو أ أسوأ من ب بنسبة r ، يبقى ب أحسن من أ بنسبة $1 - \frac{1}{1+r}$ وهي دائماً أصغر من r .

والتوصية بتنقلب عند $n = 24$! بدورتين موسميتين بس:

- أحسن طريقة كلاسيكية مش AutoARIMA أصلاً — دي (1.029) SeasonalNaive
- و TimesFM-3 بيكسب على AutoARIMA بـ 42% (1.321 مقابل 2.284)

يعني نصيحة "استخدم ARIMA للموسمية" صح بس بعد ما يبقى الموديل الموسمي قابل للتقدير. تحت الحد ده هي نصيحة وحشة.

ب) الطلب المتقطع (D8) – الحكاية أعقد، والمقاييس بتتخاقل

على TimesFM-3 ، MASE ، يقلل الخطأ بـ 21.7% و 26.5% و 26.0% و 26.2% على الأطوال الأربعة، وكلها $p > 0.0001$. وعلى الـ pinball loss كمان هو الأحسن في كل طول.

بس على RMSSE هو بيخسر في كل طول. وعلى SMAPE هو أوحش واحد في الستة بفارق كبير.

ليه؟ فيه ميكانيزم حقيقي مش صدفة:


70% من قيم D8 أصفار. والقاعدة الرياضية بتقول:

- مقاييس الخطأ المطلق (زي MASE) بتتصغر عند الـ median بتاع التوزيع — وده هنا صفر أو قريب منه.
- مقاييس الخطأ التربيعي (زي RMSSE) بتتصغر عند الـ mean — وده أكبر من صفر بالتأكيد.

فالتريقة اللي بتتنبأ قريب من الـ median بتكسب MASE وتخسر RMSSE، والعكس صحيح. ودي بالضبط المصيدة اللي (Kolassa (2016 وثّقها للطلب المتقطع في التجزئة.

من الآخر: في الطلب المتقطع، مفيش رقم واحد يحسم الموضوع — اللي يحسمه هو دالة الخسارة اللي قرارك التجاري بيواجهها فعلاً.

(القاعدة دي متحسوبة على بياناتنا نفسها ومرسومة في الجزء 8.6، مع الطرق المتخصصة للطلب المتقطع.)



شكل 4 — الدقة حسب طول الأفق، مقسومة على النظامين. الشمال: العمليات اللي فيها موديل كلاسيكي صح (D1 - D5). اليمين: اللي مفياش (D6 - D9). كل الطرق بتسوء كل ما الأفق يطول — وده طبيعي.

⚠ بس خد بالك من قراءة غلط هنا: TimesFM-3 مبين الأقل في اللوحين، وده مش بيناقض إن الكلاسيكي كسب خلايا أكثر — لأن المتوسط بيخلط الخلايا اللي الكلاسيكي كسبها بالخلايا اللي وقع فيها، وخلية واحدة كارثية (زي Theta) بـ 4.16 على (D4) بتحرك المتوسط أكثر بكتير من كذا مكسب صغير.

8.6 Adding the Right Tool: Croston ★ — ضفنا الأدوات المتخصصة فعلاً

المراجعة قالت لنا حاجة وجيهة: "مجموعة المقارنة بتاعتكم مفياش ولا طريقة متصمة للطلب المتقطع!" وده اعتراض عادل — Croston وعيلته موجودين بالضبط للحالة دي.

فضفناهم: **CrostonClassic** , **CrostonOptimized** , **CrostonSBA** , **ADIDA** , **IMAPA** , **TSB** — بنفس ال seeds ونفس ال 200 تكرار.

والنتيجة طلعت **غريبة لأول وهلة**: **TimesFM-3** كسب عليهم كلهم على مقياس، وخسر قدامهم كلهم على مقياس ثاني — بنفس التنبؤات بالطبط. الجزء ده بيشرح ليه ده حصل، وليه هو **مش تناقض** أصلاً.

الخطوة 1: يعني إيه "طلب متقطع"؟

تخيل إنك بتبيع **قطع غيار**. أغلب الأيام **مبتبعش ولا قطعة**، وفجأة ييجي يوم تباع 5 أو 6. دي عملية **D8** بتاعتنا.

خد الأرقام الحقيقية من المحاكاة (200 تكرار × 200 نقطة = 42,400 مشاهدة):

الخاصية	القيمة
نسبة الأيام اللي المبيعات فيها صفر	69.8%
متوسط الطلب (mean)	1.51
وسيط الطلب (median)	0

بص على آخر سطرين كويس. المتوسط 1.51 والوسيط صفر. في بيانات عادية الاتنين بيبقوا قريبين من بعض؛ هنا **بعاد خالص**. والبُعد ده هو اللي هيوْلد كل اللي جاي.

الخطوة 2: السؤال اللي بيقلب كل حاجة — "أحسن تنبؤ" مش رقم واحد
خليني أسألك سؤال بسيط:

لو **مجبور** تديني رقم واحد ثابت تتنبأ بيه لكل الأيام الجاية — تقول إيه؟

الإجابة الطبيعية: "أقول 1.51، ده المتوسط." تمام. بس **استنى** — الإجابة الصح **بتعتمد على إنت هتتأاسب إزاي**. فيه طريقتين مشهورتين للمحاسبة:

- **خطأ مطلق** (absolute error): بتجمع $|actual - forecast|$. ده اللي **MASE** مبني عليه.
- **خطأ تربيعي** (squared error): بتجمع $(actual - forecast)^2$. ده اللي **RMSSE** مبني عليه.

طب يعني إيه الفرق؟ التربيع **بيعاقب الأخطاء الكبيرة بعنف**. لو غلطت بـ 2 بدل 1، الخطأ المطلق بيتضاعف (من 1 لـ 2)، لكن التربيعي **بيتربع أربع مرات** (من 1 لـ 4). فالمقياس التربيعي بيخاف من اليوم اللي المبيعات فيه 6 أكثر بكثير ما بيهتم بالـ 70% أيام اللي فيها صفر.

وخلينا نحسبها فعلاً بدل ما نتكلم. هنجرب أرقام مختلفة للتنبؤ الثابت ونشوف كل مقياس بيفضل مين:


التنبؤ الثابت	الخطأ المطلق	الخطأ التربيعي
0 (= الوسيط)	1.510 ← الأقل	8.775
0.5	1.708	7.515
1.0	1.906	6.755
1.51 (= المتوسط)	2.115	6.496 ← الأقل
2.0	2.315	6.736
3.0	2.768	8.717

دي الفكرة كلها في جدول واحد. المقياسين مش بيختلفوا في التقدير — دول عايزين إجابتين مختلفتين حرفياً:

- الخطأ المطلق بيوصل لأقل قيمة عند **صفر** — يعني بيقولك: "قول صفر، لأن 70% من الأيام فعلاً صفر."
- الخطأ التربيعي بيوصل لأقل قيمة عند **1.51** — يعني بيقولك: "لأ، قول المتوسط، عشان تغطي أيام الـ 5 و 6 اللي هتأذييني."

ودي مش صدفة في بياناتنا؛ دي قاعدة رياضية معروفة: الخطأ المطلق أقل ما يكون عند **الوسيط**، والخطأ التربيعي أقل ما يكون عند **المتوسط**. في البيانات العادية الاتنين قريبين فمحدثش بيلاحظ. في الطلب المتقطع الاتنين **بعاد جداً**، فالفرق بيبقى صارخ.

الخطوة 3: شوفها بعينك



شكل 7 — له المقياسين بيختلفوا على الطلب المتقطع. (أ) شكل الطلب في D8 : عمود واحد ضخم عند الصفر (69.8%)، وديل صغير ممتد لغاية 14. الوسيط (برتقالي) عند 0 والمتوسط (أخضر) عند 1.51. (ب) البرهان: بنجرب كل تنبؤ ثابت c من 0 لـ 4 ونرسم الخسارتين. الخط البرتقالي (خطاً مطلق) **يلمس القاع عند صفر**، والخط الأزرق (خطاً تربيعي) **يلمس القاع عند 1.5**. نقطتين مختلفتين — يعني مافيش تنبؤ واحد يرضي الاتنين. (ج) النتيجة على تنبؤاتنا الحقيقية: نسبة خطأ TimesFM-3 لخطأ أحسن طريقة من عيلة Croston. تحت خط الـ 1.0 يعني TimesFM-3 أحسن؛ فوقه يعني Croston أحسن. المقياس المطلق بيحطه تحت الخط في كل طول، والتربيعي بيحطه فوق الخط في كل طول.

الخطوة 4: الأرقام بالتفصيل

طول السلسلة	MASE: TimesFM-3 أحسن Croston	RMSSE: TimesFM-3 أحسن Croston
n = 24	0.80 ✓	1.07 ✗
n = 48	0.75 ✓	1.08 ✗
n = 96	0.75 ✓	1.12 ✗
n = 200	0.74 ✓	1.13 ✗

على **TimesFM-3** : MASE كسب على الستة كلهم في الأطوال الأربعة — 24 من 24 مقارنة معنوية. أحسن منافس متخصص كان TSB عند n=96 بـ 0.916، مقابل 0.683 لـ **TimesFM-3** .

على **ADIDA** : RMSSE و **CrostonSBA** سجلوا الأقل في كل طول (0.694–0.769) مقابل 0.774–0.806 لـ **TimesFM-3** .

والسبب دلوقتي واضح: طرق **Croston** متصممة من أساسها إنها تقدّر معدل الطلب المتوسط (mean demand rate) — يعني هي بتصوّب على المتوسط، وده بالظبط اللي الخطأ التربيعي بيكافئه. و **TimesFM-3** بيطلع تنبؤ أقرب لسلوك الوسيط على البيانات دي، وده اللي الخطأ المطلق بيكافئه.

فالطرفين مش بيتنافسوا على نفس الهدف أصلاً. كل واحد بيكسب تحت المقياس اللي بيوافق الحاجة اللي هو بيصوّب عليها. مفيش حد منهم غلط — الغلط الوحيد الممكن هنا هو إنك تختار المقياس بعد ما تشوف النتيجة.

فالاعتراض اتقفّل: الموديل مش بس بيكسب على الطرق العامة — هو بيكسب على الأدوات المتخصصة كمان وبفارق قريب من فارقته على الطرق العامة (أقل بـ 19.6–25.7% من أحسن طريقة Croston، مقابل 21.7–26.5% من أحسن طريقة عامة)، لكن على المقياس التربيعي بيخسر لهم.

الخطوة 5: طب أنا في شغلي أختار مين؟
القرار مش إحصائي، ده قرار محاسبي. اسأل نفسك: تكلفة الغلطة عندك بتكبر إزاي؟

لو التكلفة عندك...	يبقى قياسك	واختارك
خطية — كل قطعة ناقصة بتكلّفك نفس المبلغ (مثلاً 10 جنيه للقطعة، سواء نقصت 1 أو 10)	خطأ مطلق (MASE)	TimesFM-3
تربيعية — النقص الكبير بيكلّفك أضعاف النقص الصغير (خط إنتاج يوقف، عميل ييمشي، غرامة تأخير)	خطأ تربيعي (RMSSE)	Croston-SBA / ADIDA

مثال يوضّح الفرق: لو عندك مسمار سعره جنيه وناقصك 10 مسامير، خسرت 10 جنيه — دي خطية. لكن لو عندك قطعة غيار لماينة، ونقصانها بيوقّف المصنع يوم كامل، فنقص قطعتين مش ضعف خسارة قطعة واحدة — دي تربيعية (أو أسوأ).

القاعدة: حدّد شكل تكلفتك الأول، وهو اللي هيحدّد المقياس، والمقياس هو اللي هيحدّد الطريقة. مش العكس.

Interval Reliability 8.7 — ثبات الفترات: هل الـ 80% فعلاً 80%؟

كلمة عن المصطلح الأول: الموديل مايبديكش رقم واحد بس — بيديك كمان **فترة** (interval) ومعاها **وعد**. وعد إيه؟ إن الحقيقة هتقع جوه الفترة دي بنسبة معيّنة من المرات. اختبار الوعد ده اسمه **المعايرة** (calibration)، وهو المقصود بـ **ثبات الفترة** هنا: الفترة اللي مكتوب عليها 80% — هل بتوفي بالـ 80% فعلاً؟





الخطوة 1: التغطية مش رأي — دي عدّة
نسبة التغطية (coverage) مش حاجة نظرية تتناقش. دي **حاجة تتعدّد بالإيد**:

شوف كذا حالة تنبؤ، وفي كل حالة بصّ: الحقيقة وقعت **جوه** الفترة ولا **بره**؟ اقسم عدد اللي جوه على العدد الكلي. الناتج ده هو التغطية.

وخلص. لو الموديل صادق في وعده، الرقم ده لازم يطلع قريب من **0.80**.

الخطوة 2: نعدّها بنفسنا

خدنا 20 حالة تنبؤ حقيقية من عملية **D6** (الكسر الهيكلي) عند **n = 96**، على أفق 12 خطوة، ورسمنا لكل حالة **الفترة** اللي الموديل قال عليها 80%، وحتينا **الحقيقة** جواها أو بره.



شكل 8 — التغطية والعرض، بالعدّ وبالأرقام. (أ) TimesFM-3: الحقيقة وقعت جوه الفترة في 18 من 20 حالة = 90%، بمتوسط عرض 11.5. **(ب) AutoARIMA:** على نفس الحالات بالظبط: 20 من 20 = 100% — بس بفترة أعرض 1.8 مرة (20.2 مقابل 11.5). **(ج)** الانحراف عن الـ 0.80 المطلوبة: الرمادي لو حسب المتوسط الأول، والملون هو الانحراف الحقيقي لكل خلية. **(د)** على **D6**: التغطية على المحور الرأسي والعرض على الأفقي. الكلاسيكي كله متجمّع فوق **على اليمين** — تغطية شبه كاملة، بأوسع الفترات.

الخطوة 3: طب مش AutoARIMA كده أحسن؟ لأ.
هنا المصيدة اللي القسم ده كله عنه.

AutoARIMA مسك كل الحالات — 100%. ودي على ورق تبان أحسن من 90%. بس افكر: **الوعد كان 80%، مش 100%**. الموديل اللي بيغطي 100% وهو واعد بـ 80% **مش دقيق زيادة — هو بيكدب في الاتجاه الثاني**: بيقولك "أنا مش متأكد" أكثر مما هو فعلاً مش متأكد.

وإزاي عمل كده؟ **بانه وسّع الفترة**. الفترة الواسعة بتمسك كل حاجة — لأنها بتشمل كل حاجة.

التشبيه: لو قلتك "بكرة الجو هيبقى بين -50 و +80 درجة" — كلامي هيطلع صح 100% **من المرات**. وهيبقى بلا فائدة 100% **من المرات** كمان. مقدرش أخطّط ليوم بكرة بالمعلومة دي.

القاعدة: رقم التغطية لوحده **مايتقريش**. لازم تبص عليه **مع عرض الفترة**. تغطية 100% بفترة ضعيف العرض = خسارة، مش مكسب.

الخطوة 4: والفخ الثاني — المتوسط بيداري الانحراف

النظرة المتوسطة (على العمليات التسعة): تغطية **TimesFM-3** للفترة 80% بتفضل بين 0.802 و 0.834 عبر كل الأطوال — أقرب للمطلوب من أي طريقة ثانية. بينما **SeasonalNaive** بتنجرف من 0.777 عند $n=24$ لـ 0.869 عند $n=96$.

بس الرقم ده مجاملة للكل. ليه؟ لأن لما تاخد **متوسط** التغطية عبر تسع عمليات مختلفة، العملية اللي فيها تغطية 0.95 (زيادة) بتلغي العملية اللي فيها 0.65 (نقص)، والمتوسط بينهم يطلع 0.80 — **رقم مثالي من موديل بيغلط في الاتجاهين!** المقياس الأمين هو إنك تحسب الانحراف **في كل خلية لوحدها** الأول (بالقيمة المطلقة، عشان الزيادة والنقص مايلغوش بعض)، و**بعدين** تاخد المتوسط. والفرق بين الطريقتين **حوالي 3 أضعاف**:

الطريقة	لو حسبت المتوسط الأول (مجامل)	الانحراف الأمين لكل خلية	الفرق
TimesFM3	0.015	0.047	3.2×
AutoARIMA	0.021	0.066	3.1×
Combination	0.032	0.089	2.8×
AutoETS	0.021	0.101	4.8×
Theta	0.040	0.127	3.2×
SeasonalNaive	0.038	0.144	3.8×

الترتيب متغيّرش و **TimesFM-3** فضل الأحسن معايير — **بس المستوى مش قريب من المطلوب**: تغطيته لكل خلية بتتراوح من 0.583 لـ 0.921! يعني فيه خلية بيوعدها بـ 80% وبيوفي 58% بس، وخلية ثانية بيوفي فيها 92%. **مفيش ولا طريقة** في الدراسة دي بتدي فترات 80% موثوقة عبر العمليات التسعة.

الخطوة 5: الحالة اللي بتوضح كل حاجة — الكسر الهيكلي (D6)


التغطية (المطلوب 0.80)	عرض الفترة (مقيس)	
0.966 – 0.999	4.81 – 10.36	كل الطرق الكلاسيكية
0.828 – 0.889	3.00 – 5.07	TimesFM3

بصّ للكلاسيكي: تغطية 99.9%؟ ده مش "ثبات" — ده **عَرَض مرضي**. الكسر الهيكلي بيضخّم تقدير التباين، فالفترات بتبقى **ضخمة**. هي بتحتوي الحقيقة دايماً لأنها بتحتوي **كل حاجة**.

TimesFM-3 بيغطي 82.8-88.9% (فوق المطلوب برضه) بفترات **نص العرض تقريباً**. الاتنين بيزودوا، بس واحد بيزود **شوية** والتاني بيزود لدرجة إن الفترة بقت بلا معنى.

الخطوة 6: اللي تاخده معاك

1. التغطية حاجة تتعدّ، مش تتفلسف. جوه ولا بره، واقسم.
2. 80% معناها 80% — مش 100%. الزيادة غلط زي النقص بالطبط.
3. عمرك ما تقرا تغطية من غير عرض جنبها.
4. متوسط التغطية بيداري. اطلب الانحراف لكل خلية — هتلاقيه حوالي 3 أضعاف.
5. في الدراسة دي: **TimesFM-3** الأحسن معايرةً، ومحدش فيهم كويس بما فيه الكفاية.



شكل 3 — التغطية الفعلية للفترات مقابل المطلوب (الخط المتقطع)، بمتوسط على العمليات التسعة. لاحظ إن **TimesFM-3** ماشي على الخط المطلوب تقريباً في كل الأطوال، بينما الكلاسيكي **بيقصر** عند $n = 24$ و**بيزود** من $n = 96$ ⚠. وده **المتوسط** اللي اتكلمنا عنه في الخطوة 4 — الانحراف الحقيقي لكل خلية أكبر 3 مرات، زي ما في **شكل 8 (ج)**.

8.8 Was the Combination a Straw Man? — هل ال Combination كان خصم ضعيف؟

TimesFM-3 كسب على ال Combination في 27 من 30 مقارنة معنوية. وقبل ما نفرح بالرقم ده، فيه اعتراض وجيه لازم نرد عليه. بس الأول لازم نفهم ال Combination ده إيه أصلاً.

الخطوة 1: يعني إيه "Combination"؟

فكرة قديمة وبسيطة: بدل ما تختار طريقة واحدة، خذ أكثر من طريقة واحسب متوسط تنبؤاتهم.

في دراستنا ال Combination بياخذ ثلاث طرق — **Theta** و **AutoETS** و **AutoARIMA** — ويحسب متوسط تنبؤاتهم بأوزان متساوية. (**SeasonalNaive** مش فيه).

الخطوة 2: وليه المتوسط ده بيساعد أصلاً؟
لأن الطرق الثلاثة بتغلط في اتجاهات مختلفة. واحد بيزود، والثاني بيقلل، فلما تجمعهم على 3 الأخطاء بتلغي بعضها جزئياً. ده مبدأ قديم في التنبؤ اسمه **error cancellation**.

وده مش كلام نظري — ده حصل عندنا في كل خلية بلا استثناء:

الدمج بالمتوسط طلع أحسن من متوسط أعضاءه في 36 من 36 خلية.

يعني الدمج بيدي قيمة حقيقية، مش مجرد جمع أرقام.

بس خد بالك من التفصيلة دي: الدمج بيكسب على العضو المتوسط، لكنه مش بيكسب على أحسن عضو — كسب على أحسن عضو في 4 خلايا بس من 36. يعني الدمج مش سحر؛ هو تأمين ضد إنك تختار غلط، مش طريقة لتبقى الأحسن.

الخطوة 3: الاعتراض (وهو وجيه فعلاً)

المراجعة قالت: "المتوسط مش محصن ضد عضو بايظ. عندكم **Theta** بيقع بشكل كارثي في خلايا معينة (زي **D4** بـ $MASE = 4.15$) — يبقى المتوسط بتاعكم مسحوب تحت بسببه، وانتوا بتقارنوا **TimesFM-3** بخصم إنتوا اللي أضعفتوه." الاعتراض ده منطقي 100%. لو الوسيط (median) بدل المتوسط، هيبقى محصن: عضو واحد يقع مايأثرش.

الخطوة 4: فجرّبناه فعلاً — والنتيجة عكس المتوقع

أعدنا المقارنة كلها ضد combination بالوسيط بدل المتوسط، بنفس الأعضاء ونفس الخلايا:

متوسط MASE على ال 36 خلية	
1.439	TimesFM-3
1.656	الدمج بالمتوسط
1.712 ← أسوأ!	الدمج بالوسيط (المفروض المحصن)

والوسيط طلع أحسن من المتوسط في 8 خلايا بس من 36.


الخطوة 5: طب ليه؟ دي أهم نقطة في القسم

السبب حسابي وبسيط جداً، ومربوط بعدد الأعضاء:

ال Combination عندنا 3 أعضاء. ووسيط 3 أرقام = الرقم اللي في النص.

يعني لما تقول "خد الوسيط بدل المتوسط"، إنت فعلياً بتقول: "خد تنبؤ واحد وارمي الاثنين التانيين".

وده بالضبط بيلغي السبب اللي خلاك تدمج من الأول! الدمج بيشغل لأن الأخطاء بتلغي بعضها — ولما تسبب عضو واحد بس، مافيش حاجة تلغي حاجة. إنت اشتريت الحماية من عضو بايظ، ودفعت تمنها آلية الدمج كلها.



شكل 9 — ليه "الدمج المحصّن" خسر. (أ) خلية واحدة بالتفصيل (D5, n=24): الأعضاء الثلاثة (رمادي)، الدمج بالمتوسط 2.47 — أحسن من متوسطهم (2.58) ✓، والدمج بالوسيط 2.98 — اللي هو AutoETS (3.03) تقريباً بالظبط X. (ب) نفس المقارنة على الـ 36 خلية: النقط تحت القطر معناها الوسيط أحسن — 8 بس. (ج) البرهان: الدمج بالوسيط بيقع على قطر "العضو الأوسط لوحده" (متوسط الفرق 0.059 بس)، بينما الدمج بالمتوسط بعيد عنه (0.172). يعني الوسيط ما بيدمجش — بيختار.

الخطوة 6: والخلاصة

TimesFM-3 كسب على الدمج بالوسيط في 25 من 29 مقارنة معنوية — يعني الاعتراض مش بيغيّر النتيجة:

- لو قارناه بالدمج بالمتوسط: **TimesFM-3** كاسب.
- لو قارناه بالدمج بالوسيط (المحصّن): **TimesFM-3** كاسب برضه، ويفارق أوسع شوية.

فتفوّق الموديل على الدمج مش ناتج عن طريقة تكوين الدمج. الاعتراض اتقفل.

والدرس اللي يتاخذ بره الورقة دي: "استخدم الوسيط عشان يبقى محصّن" نصيحة كويسة — لما يكون عندك أعضاء كتير. مع 3 أعضاء بس، الوسيط بيرمي ثلثين البيانات. عدد الأعضاء جزء من القرار.

(والتحليل ده بعدي/post-hoc — عملناه بعد ما شغنا النتائج، رداً على المراجعة، ونبلّغه صراحةً.)

Effect Sizes and a Sensitivity Check 8.9 — أحجام الأثر وفحص الحساسية

القسم ده بيسأل سؤالين مختلفين خالص عن اللي فات:

1. الفروق دي كبيرة قَدْ إيه فعلاً؟ (مش: هل هي معنوية)
2. لو غيّرنا الاختبار الإحصائي، النتيجة هتفضل زي ما هي؟

الجزء الأول: "معنوي" ≠ "مهم"

دي أكثر نقطة بتلخبط في الأوراق العلمية. الاختبار الإحصائي بيقولك إن الفرق مش صدفة. مايقولكش إن الفرق يستاهل تغيّر شغلك عشانه.

عشان نقيس حجم الفرق استخدمنا **Hodges-Lehmann** تقدير، وهو ببساطة: الفرق الوسيط بين الطريقتين على السلاسل. (السالب لصالح **TimesFM-3**).

الخصم	الفرق الوسيط في MASE	يعني إيه؟
Theta	-0.227	فرق واضح
AutoETS	-0.183	فرق واضح
SeasonalNaive	-0.133	فرق ملحوظ
Combination	-0.091	فرق صغير
AutoARIMA	-0.010	فرق لا يُذكر

اقرأ السطر الأخير كويس. قدام **AutoARIMA** الفرق النموذجي هو واحد من مئة من وحدة MASE — والـ MASE النموذجي في الدراسة حوالي 1.05. يعني الفرق حوالي 1% من مستوى الخطأ.

ده فرق بيتقاس (وبيطلع معنوي إحصائياً لأن عندنا 200 تكرار)، بس مش فرق محلل هيلاحظه في شغله ولا هيغيّر قراره عشانه. المعنوية جت من حجم العينة، مش من حجم الأثر.

الجزء الثاني: نفس البيانات، اختبارين، نتيجتين استخدمنا **Wilcoxon** كاختبارنا الأساسي (مسجل مسبقاً). وعشان نتأكد إن النتائج مش معتمدة على الاختيار ده، أعدنا كل حاجة بـ **t-test**.


اللاتنين اتفقوا في 163 من 180 مقارنة (90.6%). كويس.

بس الـ 17 اللي اختلفوا فيهم مش عشوائيين — فيهم نمط مهم جداً:

في **D8** (الطلب المتقطع) قدام **SeasonalNaive** : الـ **t-test** يقول **TimesFM-3** أحسن بشكل معنوي في كل طول ($p > 0.0001$)، بينما **Wilcoxon** يقول مفيش فرق معنوي أصلاً (p من 0.11 لـ 0.92)!

نفس الأرقام بالظبط. اختبارين محترمين. نتيجتين متضادين. مين الغلطان؟

الجزء الثالث: ولا واحد فيهم — دول بيجابوا على سؤالين مختلفين عشان تفهم، لازم تبص على الـ 200 سلسلة واحدة واحدة بدل ما تبص على رقم مجّمع:



شكل 10 — حجم الأثر، والسبب الحقيقي وراء اختلاف الاختبارين. (أ) الفروق الوسيطة قدام الخمس طرق.

AutoARIMA عند -0.010 — شعرة على مقياس MASE النموذجي (≈ 1.05). (ب) دي اللوحة المهمة: الـ 200 سلسلة في D8 عند $n=48$ ، مرتبة من الأسوأ للأحسن. الأخضر = TimesFM-3 أحسن، الأحمر = أسوأ. معظم الأعمدة حمرا وصغيرة، وشوية أعمدة خضرا ضخمة على الشمال. (ج) النتيجة: t-test بيدي p صغيرة جداً في كل طول، و Wilcoxon بيدي p فوق 0.05 في كلهم.

والأرقام اللي بتفتّر كل حاجة:

إيه اللي بيشفه	القيمة	
يقيسه Wilcoxon أسوأ بشعرة ← ده اللي TimesFM-3	+0.005	وسيط الفروق
يقيسه t-test أحسن بكثير ← ده اللي TimesFM-3	-0.358	متوسط الفروق
يعني تلتين السلاسل!	66%	نسبة السلاسل اللي TimesFM-3 أسوأ فيها
عشر سلاسل بس بتحرّك المتوسط	42%	مساهمة أسوأ 5% من السلاسل في المتوسط

فالحكاية كده: على تلتين السلاسل TimesFM-3 أسوأ من SeasonalNaive — بس بفروق تافهة (حوالي 0.005). وعلى أقلية صغيرة من السلاسل، SeasonalNaive بيقع بشكل كارثي و TimesFM-3 أحسن منه بوحدات MASE كاملة.

- المتوسط بيتأثر بالأقلية الكارثية ← فيقول "TimesFM-3 كسب بفارق كبير".
- الوسيط بيتبع الأغلبية ← فيقول "مفيش فرق يُذكر".

اللاتنين صح. الاختلاف مش عيب في اختبار — ده حقيقة عن الشكل الحقيقي للبيانات: توزيع غير متماثل بذيّل طويل. والاختبارين بيلخّصوه بطريقتين مختلفتين، وكل واحدة مفيدة لقرار مختلف:

- لو بتخاف من الكوارث النادرة (نفاد مخزون كبير) ← المتوسط هو اللي يهمك، و TimesFM-3 أحسن.
- لو بتهتم بـ الأداء في اليوم العادي ← الوسيط هو اللي يهمك، واللاتنين متعادلين.

وعشان كده بنعامل نتيجة D8 كنتيجة مشروطة مش حاسمة — وده السبب الثالث المستقل اللي يخلينا نقول كده (الأول: RMSSE يقلب النتيجة؛ الثاني: SMAPE يقلبها كمان).

9. ★ Representativeness and Robustness — هل التصميم بيُمثّل الواقع؟ وهل النتائج بتصمد؟

ربط باللي فات: في القسم 8 طلّعنا نتائج واضحة: TimesFM-3 بيشتري المتانة مش الدقة القصوى، و AutoARIMA بيكسب في الموسمية لما الدورات تكفي، والمقاييس بتتخاّنق في الطلب المتقطع. بس كل ده اتعمل على 9 عمليات، كل عملية ليها قيم بارامترات ثابتة — يعني D1 مثلاً دائماً $\phi = 0.7$.

فأي محكّم محترم هيسأل أسئلة زي دي:

1. السلاسل المولّدة دي شبه البيانات الحقيقية ولا عايشة في عالم لوحدها؟

2. لو غَيَّرنا القيم، أو البيانات ما يقتض "نضيقة" — النتائج هتفضل زي ما هي؟

3. الأرقام دي دقيقة قد إيه؟ ولو جَرَّبنا طرق أقوى أو موديلات أساس تانية؟

القسم ده بيجابو بالأرقام. وخلي بالك: كل التحليلات هنا بعدية (post hoc) — اتصممت بعد ما النتائج الأساسية ظهرت، ومسجلة كده في `DEVIATIONS.md` (من D-10 لـ D-12)؛ المقارنة المسجلة مسبقاً هي اللي في القسم 8.

تشبيه: تخيل شركة عربيات جربت العربية على طريق واحد بس — أسفلت ناعم، جو معتدل، سرعة 80. العربية طلعت ممتازة. الأسئلة الطبيعية: الطريق ده شبه الطرق اللي الناس بتسوق عليها فعلاً؟ ولو فيه مطبات أو مطر أو السواق ما يعرفش الطريق؟ وهل العربيات التانية من نفس الفئة هتعمل زيها؟ القسم ده هو التجربة على طرق تانية ومع عربيات تانية.

9.1 Why Fixed Values Are a Risk — ليه القيم الثابتة مخاطرة؟

لما `D1` دايماً $\phi = 0.7$ ، النتيجة بتقولك إيه اللي بيحصل عند 0.7 بالظبط. طب لو $\phi = 0.95$ (عملية قريبة جداً من حدود الاستقرار) أو $\phi = 0.2$ (شبه ضوضاء)؟ ممكن الترتيب يتقلب.

والقيم الثابتة ليها عيب تاني: كل عملية بتطلع سحابة صغيرة ومتلّمة من السلاسل المتشابهة. فالمسافات بين السحابات دي — واللي فيها سلاسل حقيقية كتير — مفيهاش أي سلسلة متجربة.

من الآخر: القيم الثابتة بتديك إجابة دقيقة على سؤال ضيق. عشان نوسع السؤال لازم نغير القيم.

9.2 Representativeness: the Instance Space — فضاء الخصائص: هل سلاسلنا شبه الحقيقية؟

الفكرة (من Smith-Miles 2017 & Kang, Hyndman): بدل ما نقارن السلاسل نقطة بنقطة، نوصف كل سلسلة بـ 4 أرقام بتلخص "شخصيتها"، ونحط السلاسل المولدة والحقيقية في نفس الفضاء ونشوف هل بيغطوا بعض.

الخصائص الأربعة، واحدة واحدة:

الخاصية	بتقيس إيه	لو قيمتها عالية	لو قيمتها واطية
Spectral entropy (الطيفية)	قد إيه السلسلة عشوائية ومش متوقّعة	قريبة من 1 = ضوضاء بيضا، صعب تتنبأ بيها	قريبة من 0 = نمط واضح وسهل التنبؤ
Trend strength (قوة الاتجاه)	قد إيه فيه اتجاه عام طالع أو نازل	السلسلة ماشية في اتجاه واضح	مفיש اتجاه، بتتذبذب حوالين مستوى
Seasonal strength (قوة الموسمية)	قد إيه فيه نمط بيتكرر كل 12 نقطة	موسمية قوية	مفיש موسمية
ACF1 of differences	الارتباط بين تغيّر النهارده وتغيّر امبارح	التغيّرات بتكمل بعض	التغيّرات بتعكس بعض (سالب)

قوة الاتجاه وقوة الموسمية بتتحتسبوا من تفكيك STL: السلسلة بتتقسم لـ اتجاه T + موسمية S + باقي R ، وبعدين:

$$\text{Trend strength} = \max \left(0, 1 - \frac{\text{Var}(R)}{\text{Var}(T + R)} \right)$$

• $\text{Var}(R)$: تباين الباقي، يعني الجزء اللي مش متفسّر.

• $\text{Var}(T + R)$: تباين الاتجاه والباقي مع بعض.

• **لو الباقي صغير جداً** قدام الاتجاه ← الكسر قريب من 0 ← القوة قريبة من 1 (اتجاه قوي).

• **لو الباقي هو كل حاجة** ← الكسر قريب من 1 ← القوة قريبة من 0 (مفیش اتجاه).

وقوة الموسمية نفس الفكرة بالطبط بس بـ **S** مكان **T** .


إزاي قارئاً؟

1. خدنا الـ **1,000 سلسلة M4 شهرية** (نفس بتاعة القسم 10)، وقصينا كل واحدة لآخر 96 نقطة من فترة التدريب بس — من غير الـ 18 شهر بتوع الاختبار الرسمي.

2. حسبنا الخصائص الأربعة لكل سلسلة حقيقية ومولدة، ووحدنا المقاييس باستخدام **متوسط وانحراف سلاسل M4 بس** — عشان المسطرة ماتتغيرش حسب التصميم اللي بنقيسه.

3. **تعريف "مغطاة"**: سلسلة M4 تعتبر مغطاة لو فيه سلسلة مولدة قريبة منها على الأقل قد ما السلاسل الحقيقية بتبقى قريبة من بعض. بالتحديد: المسافة لأقرب سلسلة مولدة $\geq$ المئين الـ 95 لمسافة أي سلسلة M4 لأقرب سلسلة M4 **تانية** (وطلع الحد ده 0.533).

ليه التعريف ده بالذات؟ عشان المقياس يبقى **عادل**: مش بنطلب من المحاكاة تقرب أكثر مما الواقع نفسه بيقترب لنفسه.



شكل 11 — السلاسل المولدة وسلاسل M4 في فضاء الخصائص (أول مكوّنين رئيسيين). النقط الرمادي = سلاسل M4 الحقيقية، والملوّنة = سلاسلنا المولدة عند $n = 96$. (أ) **التصميم الثابت**: كل عملية سحابة صغيرة متلّمة، وفيه فراغات كبيرة بين السحابات مليانة نقط رمادي. (ب) **التصميم العشوائي**: السحابات اتفردت وملّت جزء كبير من الفراغات دي.

النتيجة بالأرقام:

التصميم العشوائي	التصميم الثابت	
75.8% (73.2–78.4%)	48.5% (فترة ثقة 45.2–51.4%)	نسبة سلاسل M4 المغطاة
0.38	0.55	وسيط المسافة لأقرب سلسلة مولدة

وهل الأرقام دي بتعتمد على اختياراتنا؟ جربنا نغير كل حاجة:

- **الحد:** من المئين 80 لحد 99.
- **طول السلسلة:** 48 و 96 و 200.
- **عدد الخصائص:** 4 أو 6 (بإضافة الارتباط الذاتي للسلسلة نفسها و"التكتل" lumpiness).
- **حجم العينة:** صغّرنا التصميم الثابت لنفس حجم العشوائي.

وفي كل الحالات دي: التصميم العشوائي يغطّي من **76% لـ 89%** من M4، و**دائماً** أكثر من الثابت. وبالعكس كمان: من **60% لـ 92%** من السلاسل المولّدة واقعة جوه منطقة البيانات الحقيقية — وأقل نسبة عند **$n = 200$** ، لأن السلاسل الطويلة الحقيقية فيها اتجاه أقوى من سلاسلنا.

وتلات ملاحظات مهمة:

- **سلاسل M4 أكثر اتجاهاً** من سلاسلنا: وسيط قوة الاتجاه **0.87** عندهم مقابل **0.63** عندنا.
- **1.5% بس** من سلاسل M4 أقرب حاجة ليها هي **D8** (الطلب المتقطع) — لأن M4 مفيهاش سلاسل متقطعة أصلاً. فنتائج الطلب المتقطع **بتعتمد على المحاكاة لوحدها** (وعلى الأدبيات بتاعة الموضوع ده).
- **حوالي الربع** من سلاسل M4 لسه برّا التغطية، ومسجّل ده كحد من حدود الدراسة في القسم 14.

من الآخر: التصميم الثابت كان بيغطّي **أقل من النص** من الواقع الشهري؛ لما خَلينا القيم عشوائية بقى بيغطّي **حوالي تلات أرباعه** — والنتيجة دي بتصمد مهما غيّرنا طريقة الحساب.

9.3 Randomised Parameters — كل سلسلة بقيمها الخاصة

الفكرة: بدل **$\phi = 0.7$** لكل سلاسل **D1**، كل سلسلة **بتسحب قيمها بنفسها** عشوائياً من مدى واسع. وكل مدى **جواه** القيمة الثابتة القديمة — يعني التصميم القديم حالة خاصة من الجديد.

العملية	المدى الجديد (توزيع منتظم)	ليه المدى ده
D1 AR(1)	من 0.10 لـ 0.95 ϕ	بيوصل لقرب حدود الاستقرار
D2 ARMA(1,1)	لـ 0.8 -0.6 من θ ، من 0.10 لـ 0.90 ϕ	يشمل θ سالبة
D3 ARIMA(1,1,1)	لـ 0.6 drift، من 0 لـ 0.6 -0.5 من θ ، لـ 0.8 -0.5 من ϕ	
D4 SARIMA	من 0.1 لـ 0.8، سعة الموسمية من 5 لـ 20 و Φ و ϕ	موسمية ضعيفة لحد قوية
D5 ETS(A,A,A)	من 0.05 لـ 0.3 γ ، من 0.001 لـ 0.03 β ، من 0.05 لـ 0.5 α	
D6 كسر هيكلي	حجم الكسر من 3 لـ 15 انحراف معياري، بإشارة عشوائية ، ومكانه من 85n.0 لـ 50n.0	كسور صغيرة صعب تتشاف لحد كبيرة واضحة
D7 نمو لوجستي	من 0.04 لـ 0.15، نقطة الانقلاب من 0.4 لـ 0.8 من طول السلسلة r	
D8 طلب متقطع	احتمال الطلب p من 0.1 لـ 0.6، و λ من 1 لـ 8	من متقطع جداً لحد شبه مستمر
D9 AR + GARCH	من 0.75 لـ 0.90 (بشرط b ، من 0.05 لـ 0.15 a ، من 0.1 لـ 0.9 ϕ) $a + b < 0.98$	عشان التباين يفضل مستقر

الحجم: 200 سلسلة لكل (عملية × طول) = $7,200 = 9 \times 4 \times 200$ سحبة بارامترات — نفس حجم التصميم الأساسي بالظبط. وال seeds **منفصلة تماماً** عن بتاعة الدراسة الأساسية.

من الآخر: بدل ما نسأل "إيه اللي بيحصل عند 0.7؟" بقينا بنسأل "إيه اللي بيحصل في أي مكان من 0.1 لـ 0.95؟".

9.4 Four Departures from the Assumptions — أربع نسخ: لما البيانات مابتبقاش مثالية

نفس الـ 7,200 سحبة اتشغلت في **أربع نسخ**. كل نسخة بتكسر فرضية واحدة من فرضيات التصميم الأساسي:

(1 **Random parameters — القيم العشوائية بس:** الضوضاء **طبيعية (Gaussian)** زي الأصل. دي نقطة المرجع.

(2 **Heavy tails — ذيول ثقيلة:** الضوضاء بقت من توزيع **Student-t بـ 3 درجات حرية**، ومعدلة عشان يبقى ليها نفس التباين بالظبط.

- **يعني إيه ذيل ثقيل؟** التوزيع الطبيعي نادراً جداً ما بيطلع قيمة بعيدة عن المتوسط. الـ t_3 بيطلع قيم متطرفة **كثير** — صدمات كبيرة مفاجئة، زي اللي بتحصل في الأسواق فعلاً.

- **ليه "نفس التباين"؟** عشان الفرق يبقى في **شكل** التوزيع بس، مش في حجمه.

- **وإزاي اتبنت؟** من نفس الأرقام الطبيعية بتاعة النسخة الأولى بالظبط، مضروبة في عامل عشوائي (أرقام عشوائية مشتركة — *common random numbers*). يعني الفرق بين النسختين هو **الذيل الثقيل بس**.

- وفي **D8** : أحجام الطلب بقت **Negative Binomial** بنفس المتوسط و**3 أضعاف** تباين الـ Poisson.

(3 **Outliers — قيم شاذة:** كل نقطة في الـ **context** بس، باحتمال 3%، بتتقرب بـ 4 لـ 6 انحرافات معيارية "متينة" في اتجاه عشوائي. (وفي **D8** ، الطلب بيتضرب في 5).

- **ليه في الـ context بس؟** عشان عايزين نقيس: هل القيم الشاذة **بتلخبط تقدير الموديل؟** لو حظيناها في المستقبل كمان، هنبقى بنقيس مين بيعرف يتنبأ بحاجة **مستحيل تتوقعها** أصلاً.

- **ليه انحراف معياري "متين"؟** لأنه بيتحسب من الـ **MAD** — فالقيم الشاذة نفسها مابتأثرش على المقياس اللي بنحدد بيه حجمها.

(4 **Estimated period — الفترة الموسمية لازم تتقدر:** نفس سلاسل النسخة الأولى بالظبط، **بس** الطرق الكلاسيكية مابقتش بتأخذ الفترة الصح ($m = 12$) هدية.

- **افتكر الملاحظة من القسم 5:** الطرق الكلاسيكية كانت واحدة **معلومة مسبقة (oracle)** — إن **D4** و **D5** موسمين بفترة 12 — و **TimesFM-3** مكانش واخد أي حاجة.

- **دلوقتي:** الفترة بتتحدد بـ **اختبار الموسمية بتاع M4** (ارتباط ذاتي عند الإبطاء 12 مقارنةً بحد ثقة 90%)، و**مايبتطبّقش** غير لو فيه 3 دورات كاملة على الأقل (يعني $n \geq 36$).

- و **TimesFM-3** ؟ تنبؤاته **ماتغيرتش** — هو أصلاً عمره ما خد فترة موسمية.

الحجم الكلي: 182,400 تقييم لكل سلسلة.

من الآخر: بدل ما نختبر الطرق على **أسفلت ناعم** بس، جرّناها على مطبات (ذيول ثقيلة)، وحُفّر (قيم شاذة)، ومن غير خريطة (فترة مجهولة).

9.5 The Verdict — النتيجة: إيه اللي صمد وإيه اللي لأ؟

الاستنتاج	عشوائي	ذبول ثقيلة	قيم شاذة	فترة مقدرة
خلایا كسبها TimesFM-3 (من 36)	14	15	16	16
وسيط نسبته لأحسن طريقة في الخلية	1.029	1.038	1.004	1.017
أسوأ نسبة لـ TimesFM-3	1.56	1.54	1.49	1.55
أصغر "أسوأ نسبة" لأي طريقة كلاسيكية	2.12	2.32	2.09	1.58
مقارنات معنوية (كسب-خسارة) من 180	93-29	100-28	101-27	100-27
أحسن (من 3) AutoARIMA : $n \geq 48$ عند D4	3	3	2	3
أحسن على RMSSE (من 4) Croston : D8	4	4	4	4
بالفترة (الصحة) SeasonalNaive ÷ AutoETS : $n = 24$ عند D5	2.03	2.05	1.91	2.25

نقرا الجدول استنتاج استنتاج:

✓ (1) المتانة مثل الدقة القصوى — صمد في 3 نسخ. أسوأ حالة لـ TimesFM-3 طلعت من 1.31 (التصميم الثابت) لـ 1.56-1.49 (وفترات الثقة بتوصل لحد حوالي 1.75)، ودايماً في D7 عند $n = 96$ ، اللي فيها الـ Combination هو الأحسن. وأقل "أسوأ نسبة" كلاسيكية 2.09 لـ 2.32 — يعني الفرق لسه واضح.

⚠ (2) لكن مع الفترة المقدرة — الفرق اتقف! أسوأ حالة كلاسيكية نزلت لـ 1.58 (1.48-1.67)، وده نفس مستوى TimesFM-3 (1.55، من 1.41 لـ 1.71). ليه؟ لأن أكبر كوارث الكلاسيكي في التصميم الأساسي كانت جاية من إننا فرضنا موديل موسمي على دورتين بس. ولما المحلل بيستخدم اختبار موسمية عادي، أسوأ حالات العيلتين بتبقى متقاربة.

✓ (3) المقارنات الزوجية — صمد. TimesFM-3 كسب 93 لـ 101 وخسر 27 لـ 29 من 180 في كل نسخة. و AutoARIMA لسه أصعب خصم (7-7، 7-6، 4-10، 6-8 في النسخ الأربعة بالترتيب).

✓ (4) الموسمية مع دورات كفاية — صمد، واتضعف مع القيم الشاذة. AutoARIMA أحسن في D4 في كل الأطوال من 48 في 3 نسخ، بفارق 21-26%. لكن مع القيم الشاذة: في طولين بس من 3، وبفارق 5%. ليه؟ لأن القيم الشاذة بتبوظ تقدير الموديل الموسمي أكثر ما بتأثر على TimesFM-3.

✓ (5) الطلب المتقطع: عيلة Croston أحسن على RMSSE في كل الأطوال في كل النسخ. أما مقارنة MASE هنا فـ مالهش معنى — وده هنشرحه بالتفصيل في 9.8 (الموضوع ليه علاقة بتنبؤ "صفر").

9.6 ★ The Two-Cycle Collapse, Corrected — انهيار الدوريتين: الصورة الصح

افتكر من 8.3: في D5 عند $n = 24$ (دورتين بس)، AutoETS — الموديل الصح للبيانات دي — طلع MASE بتاعه 2.7 مرة قد SeasonalNaive. وقلنا: المشكلة مش في الشكل، المشكلة في التقدير.

النتيجة الجديدة: مع القيم العشوائية النسبة 1.91 لـ 2.05 — الانهيار لسه موجود بس أصغر شوية.

وماذا لو الفترة اتقدّرت؟ عند $n = 24$ مفيش 3 دورات، فاختبار الموسمية **مايبتتبّقش** وكل سلسلة بتتعامل كأنها **مش موسمية**. هنا لازم نقارن بـ **SeasonalNaive** **بالفترة الصح** — لأن ال naive العادي ($m = 1$) نفسه بيفشل بنفس الدرجة، فالمقارنة بيه تخبي المشكلة.

الأرقام عند $n = 24$:

D4	D5	
4.25	2.55	من غير موسمية (الاختبار مايبتتبّقش) AutoETS
3.14	2.29	بالفترة الصح (موديل موسمي مفروض) AutoETS
1.09	1.13	بالفترة الصح SeasonalNaive
1.45	1.11	TimesFM-3

يعني إيه؟ بدورتين بس، الطرق الأتوماتيكية الكلاسيكية **فاشلة في الحالتين:**


- لو **فرضت** موديل موسمي ← مفيش بيانات كفاية تقدره ← 2.29.
- لو **شلت** الموسمية خالص ← بتتجاهل أهم حاجة في البيانات ← 2.55.
- **الناجين الوحيدين:** **SeasonalNaive** (اللي بيكرر السنة اللي فاتت) و **TimesFM-3**.

تشبيه: واحد عايز يتوقع حرارة الشهر الجاي، ومعاها بيانات **سنتين** بس. لو حاول يحسب 12 متوسط شهري من نقطتين لكل شهر ← أرقام مجنونة. ولو قال "مفيش مواسم" وخذ المتوسط العام ← هيتوقع حرارة ربيع في عز الصيف. الحل البسيط اللي بيشتغل: **"الشهر الجاي هيبقى زي نفس الشهر السنة اللي فاتت"** — وده بالضبط الـ **SeasonalNaive**.

من الآخر: بدورتين بس، مش إن "الموديل الصح بيعق" — **كل** الطرق الكلاسيكية الأتوماتيكية بتقع، سواء فرضت الموسمية أو شالته. اللي بيفضل واقف: أبسط قاعدة، والموديل الأساس.

9.7 How the Answer Moves with the Parameters — النتيجة بتتغير إزاي مع القيم؟

دلوقتي إن كل سلسلة ليها قيمها الخاصة، نقدر نسأل: **الفرق بين TimesFM-3 و AutoARIMA** بيتغير إزاي لما البارامتر **يتغير؟**



شكل 12 — وسيط $\log_2$ لنسبة MASE ($\text{TimesFM-3} \div \text{AutoARIMA}$) حسب خمس البارامتر المسحوب. تحت الخط المنقط = **TimesFM-3** أحسن. كل خط = طول سلسلة مختلف.

إزاي تقرا المحور الرأسي؟ $\log_2$ للنسبة: 0 = متعادلين، TimesFM-3 = -1 غلظه نص غلط +1 ، AutoARIMA = غلظه الضعف.

- D1 (معامل AR) و D9 (استمرارية GARCH): الخط مسطح — القيم الثابتة ماكانتش بتحدد النتيجة.
- D6 (حجم الكسر): كل ما الكسر يكبر، TimesFM-3 بيتحسن شوية قدام AutoARIMA .
- D7 (مكان نقطة الانقلاب): الإشارة بتتقلب حسب مكان الانقلاب.
- D8 (احتمال الطلب p): الخط بيتحرك جامد مع p — بس زي ما هنشوف في 9.8، مقارنة MASE في D8 مالهاش معنى، فاللوحة دي للعرض بس.

وبالأرقام — انحدار سطح الاستجابة (response surface): عملنا لكل عملية انحدار ل $\log_2$ النسبة على البارامترات المسحوبة وطول السلسلة والنسخة:

- أكبر أثر منتظم هو الطول: كل ما n يتضاعف، النسبة بتميل ضد TimesFM-3 بـ 20% في D4 و 11% في D5 — يعني الكلاسيكي بيستفيد من البيانات الإضافية أكثر.
 - القيم الشاذة في العمليات الموسمية بتميل لصالح 14% TimesFM-3 في D4 و 10% في D5 .
 - باقي الآثار صغيرة، وال R^2 كله أقل من 0.26 — يعني معظم الفرق بين الطريقتين على أي سلسلة واحدة ضوضاء خاصة بالسلسلة، مش دالة في الإعدادات.
- من الآخر: النتائج مابتعتمدش على القيم اللي اخترناها في معظم العمليات، والأثر الوحيد الكبير والمنتظم هو طول السلسلة.

9.8 ★★ What the Referee Review Added — اللي أضافته مراجعة المحكمين

قبل ما نبعث الورقة ل Journal of Forecasting، عملنا مراجعة داخلية بتلات محكمين (محاكاة): واحد متخصص في مسابقات التنبؤ (M4)، وواحد في تصميم دراسات المحاكاة، وواحد في ال foundation models. الثلاثة قالوا: تعديل كبير (major revision). وكل تعليق اتعمل عليه. أهم اللي طلّع:

(1) الدقة الإحصائية للأرقام نفسها (Monte Carlo): كل متوسط MASE في خلية له خطأ معياري بين 1.5% و 6.2% من قيمته. وبال bootstrap أسوأ نسبة ل TimesFM-3 = 1.31 (1.28-1.36) ، ول AutoARIMA = 2.22 (2.05-2.38) — يعني الفرق حقيقي مش صدفة. أما عدد الخلايا اللي كسبها (16) TimesFM-3 ففترته من 13 ل 20 — فمانقدرش نبني حاجة على "16 مقابل 20".

(2) طرق كلاسيكية أقوى — والنتيجة ماتغيرتش: ضفنا DOTM (نسخة محسنة من Theta)، ومعيار Comb بتاع مسابقة M4، ودمج تاني. ولا واحد فيهم بقى أمتن: DOTM أسوأ نسبته 4.66، وال Comb 4.45 — وال اثنين بيوقعوا في نفس الخلية اللي Theta بيوقع فيها (D4 عند n = 200)، لأنهم كلهم بيقتضوا نمط موسمي ثابت، والعملية دي نمطها الموسمي بيتحرك.

(3) ★ موديلات أساس تانية — والمئات طلعت خاصة بـ TimesFM-3: ضفنا TimesFM-2.5 و Chronos-Bolt :

الموديل	أسوأ نسبة لأحسن طريقة
TimesFM-3	1.31
TimesFM-2.5	2.18
AutoARIMA	2.22
Chronos-Bolt	3.06

يعني: المتانة **مش** صفة في "الموديلات الأساس" كفاءة — دي صفة في TimesFM-3 بالذات. وده بالظبط اللي الإطار الاستكشافي كان متوقعه: بنوصف سلوك **موديل معين**، مش قانون عام.

(4) **إعدادات TimesFM-3 ومخرجاته:** - الورقة كانت بتستخدم الإعدادات الافتراضية للمكتبة. بإعدادات المطورين أنفسهم (positivity + averaging symmetric) أسوأ نسبة بتحسّن من 1.31 لـ 1.27 — ومفيش استنتاج بيتغيّر. - المخرجات سليمة: 9 كوانتايلات بالظبط، والتنبؤ النقطي = الوسيط بالظبط، والتقاطع بين الكوانتايلات بيحصل بس في D8 . - **ولما أدّيناه الشهر كمعلومة إضافية (covariates)** — نفس المعلومة اللي الكلاسيكي بياخذها — **ماتحسنش**، بالعكس اتدهور شوية في 7 من 8 خلايا. يعني تفوّق AutoARIMA الموسمي **مش** بسبب إنه واخد معلومة زيادة.

(5) ★★ **الطلب المتقطع — تصحيح كبير: المحكّم الأول سأل سؤال بسيط: "جربّتوا تنبّأوا بصفر؟"**

الطريقة (D8)	MASE	الانحياز	periods in stock
تنبؤ "صفر" دائماً	0.668-0.718 (الأحسن!)	-0.67 لـ -0.72	-81 لـ -91
TimesFM-3 (الوسيط)	0.683-0.780	-0.58 لـ -0.67	-74 لـ -81
TimesFM-3 (متوسط الكوانتايلات)	0.915-1.002	قريب من صفر	معقول

يعني إيه؟ الـ MASE بيكافئ الوسيط، ووسيط الطلب المتقطع = **صفر** تقريباً. فـ "تفوّق" TimesFM-3 على Croston في MASE (اللي في 8.5 و 8.6) كان في الحقيقة **تفوّق تنبؤ قريب من الصفر** — وده في الواقع معناه **نفاد مخزون مستمر**. فالنتيجة دي مابقتش بتتقدّم كدقة مفيدة.

بس TimesFM-3 مش فاشل هنا — ميزته الحقيقية في **التوزيع التنبؤي كله**: - خسارة الـ pinball بتاعته أقل من أحسن طريقة كلاسيكية بـ حوالي 15% في كل الأطوال. - ولو استخدمنا متوسط الكوانتايلات كتنبؤ نقطي ← بيبقى قد أحسن طريقة Croston على RMSSE ومن غير انحياز تقريباً.

من الآخر للطلب المتقطع: TimesFM-3 مش بيديك **تنبؤ نقطي** أحسن — بيديك **توزيع** أحسن، تاخد منه النقطة المناسبة لقرارك.

(6) **فترات الـ conformal مش حل:** جربنا فترات "conformal" للكلاسيكي بدل الفترات الطبيعية. بنافذتين معايرة بس (اللي الأطوال دي تسمح بيها) غطّت 53-66% بس بدل 80%. فمش حل عند الأطوال دي.

(7) ★ **اختبار M4 الرسمي:** بدل النوافذ المتدرجة، اتبنّأنا بفترة الاختبار الرسمية (18 شهر) لنفس الـ 1,000 سلسلة، وحسبنا OWA زي المسابقة بالظبط (نسبةً لـ Naive2):

الطريقة	OWA
(إعدادات المطورين) TimesFM-3	0.857
TimesFM-3	0.862
TimesFM-2.5	0.864
الدمج (ETS, ARIMA, DOTM)	0.867
AutoARIMA	0.891
Chronos-Bolt	0.900
Theta	0.926

واختبار **MCB** (المقارنات المتعددة) قال إن **6 طرق متعادلين إحصائياً** في القمة: الدمجين، و **TimesFM-3** بالإعدادين، و **TimesFM-2.5**، و **AutoARIMA**. يعني على بيانات حقيقية طويلة، **TimesFM-3** واحد من مجموعة الأوائل — مش فايز لوحده.

8) ★ تجربة القصّ (truncation) — نفس درس المحاكاة على بيانات حقيقية: ادينا كل طريقة آخر 24 نقطة بس من كل سلسلة: M4:

طول التاريخ	TimesFM-3	AutoARIMA	أحسن كلاسيكي
آخر 24 بس	1.046	1.175	1.096
آخر 48	0.961	1.019	0.955
كامل	0.929	0.939	0.928

مع 24 نقطة بس **TimesFM-3** أحسن من **AutoARIMA** بـ 11%، ومع التاريخ الكامل الكل متقارب. ده بالظبط درس القابلية للتقدير من القسم 8.3 — لكن المرة دي على بيانات حقيقية.

من الآخر للمراجعة: المحكّمين غيّروا استنتاجين: (1) المتانة خاصة بـ **TimesFM-3** مش بالموديلات الأساس عموماً، و(2) تفوّقه في MASE على الطلب المتقطع كان وهم. وفي المقابل، أكّدوا إن المتانة حقيقية بفترات ثقة، وإن درس القابلية للتقدير بيظهر على بيانات حقيقية كمان.

9.9 What This Section Does NOT Prove — اللي القسم ده مايثبتوش

عشان نبقي أمناء:

1. ده كله تحليل بعدي. اتصمّم بعد ما النتائج الأساسية ظهرت، ومسجّل كده (D-10 ل D-12).
2. العمليات نفسها لسه ثابتة. غيّرنا القيم، بس لسه 9 عائلات أحادية المتغير بفترة 12. حوالي الربع من سلاسل M4 الشهرية برّا التغطية، وأي بيانات بتتردد تاني برّا الدراسة كلها.
3. الانحرافات اتجربت واحدة واحدة. ماجربناش مثلاً ذيول ثقيلة مع فترة مقدّرة في نفس الوقت.

4. 4 خصائص مش كل حاجة. سلسلتين ممكن يتشابهوا في الأربعة ويختلفوا في حاجات تانية.

5. وده الأهم: إحنا بنوصف السلوك، مش بنفسره. **TimesFM-3 صندوق أسود**: أوزانه علنية وتقدر تعيد كل تنبؤ، بس الـ 330 مليون بارامتر **مالهمش تفسير فردي**، وبيانات تدريبه **مش متاحة لفحصها**. عشان كده الورقة بتسمي نفسها **دراسة استكشافية (exploratory)**: بتقيس إيه اللي الموديل بيعمله، مش ليه.

من الآخر خالص: غيّرنا القيم، وصعّبنا البيانات، وشيلنا الميزة الظالمة من الكلاسيكي، وضمنا موديلات وطرق أقوى، واختبرنا على فترة M4 الرسمية. **المتانة صمدت** — بس طلعت **خاصة بـ TimesFM-3**، وبتختفي لما الكلاسيكي يستخدم اختبار موسمية. **وتفوق الطلب المتقطع اتصحح**: الميزة في التوزيع مش في النقطة. ده وصف دقيق لسلوك صندوق أسود في مناطق محددة — مش قانون عام عن الـ foundation models.

10. The Real-Data Tier: M4 Monthly — البيانات الحقيقية

المحاكاة بتشتري النقاء بثمان الواقعية. القسم ده بيرجع جزء من الثمن ده.

10.1 What Is M4 Anyway? — إيه هي بيانات M4 أصلاً؟

الـ M4 هي **مسابقة تنبؤ عالمية** نظّمها Spyros Makridakis سنة 2018. حظوا 100,000 **سلسلة زمنية حقيقية** من الاقتصاد والمالية والصناعة والديموغرافيا، وخلّوا الناس كلها تتنافس عليها. دي مش بيانات لعبة — دي المرجع المعياري اللي أي ورقة تنبؤ جادة بتتقاس عليه.

السلاسل مقسومة بالتردد: سنوية، ربع سنوية، **شهرية**، أسبوعية، يومية، بالساعة. إحنا أخذنا **الشهرية** — وهي أكبر مجموعة فيهم: **48,000 سلسلة**.

ليه الشهرية بالذات؟ لأنها أقرب حاجة للواقع اللي المحلل بيشتغل عليه (مبيعات شهرية، طلبات شهرية، مؤشرات اقتصادية شهرية)، وفيها **موسمية حقيقية** بفترة 12 — وده بيخليها الاختبار الطبيعي للتنبؤ اللي طلعت من **D4** و **D5** في المحاكاة.

10.2 How We Picked the Series — إزاي اخترنا السلاسل بالظبط

مخدناش الـ 48,000 كلهم — لأن ده هياخد أيام حساب من غير فائدة إضافية. المواصفات بالتفصيل:

الخطوة	القيمة	ليه
المجموعة الأصلية	48,000 سلسلة شهرية	كل الشهرية في M4
شرط الطول	السلسلة لازم تكون ≤ 138 شهر	عشان تكفي لـ context محترم + 18 شهر مختبين
المؤهلة بعد الشرط	32,581 سلسلة	اللي عدّت الشرط
العينة	1,000 سلسلة عشوائي	بـ seed ثابتة 20260908

ليه seed ثابتة؟ عشان أي حد يشغل الكود يجيب نفس الألف سلسلة بالظبط — مش عينة تانية. لو مكانش فيه seed، كل واحد هيجيب نتيجة مختلفة شوية والمقارنة تبقى مالهش معنى.

طول السلاسل اللي طلعت: الأقصر 138 شهر، الوسيط 299 شهر (يعني حوالي 25 سنة!)، والأطول 1,808 شهر. يعني دي سلاسل **طويلة ومحترمة** مش أمثلة صغيرة.

10.3 ★ "Window" and a "Origin" What Is an — يعني إيه "origin" و"window"؟

دي أهم نقطة محتاجة توضيح، وهي بسيطة جداً لما تتشرح صح.

ال Origin (نقطة الأصل) = اللحظة اللي بتقف فيها عن المشاهدة وتبدأ تنبأ.

تخيل إنك واقف في شهر معين. كل اللي قبله إنت شايفه (ده ال context)، وكل اللي بعده مخبي عنك (ده ال truth اللي هتتقاس عليه). النقطة اللي إنت واقف عندها دي اسمها ال origin.

ال Window (النافذة) = زوج واحد: (البيانات اللي شفتها، الحقيقة المخبية).

مثال حقيقي بالأرقام من بياناتنا

خد سلسلة حقيقية من العينة، اسمها M10046، طولها 346 شهر. إحنا بنأخذ منها 3 نوافذ:

النافذة	الموديل بيشف	يتنبأ بـ	العدد
origin 1	شهور 1 → 328	شهور 329 → 346	18 شهر
origin 2	شهور 1 → 316	شهور 317 → 334	18 شهر
origin 3	شهور 1 → 304	شهور 305 → 322	18 شهر

شوف النمط: كل مرة بنرجع 12 شهر لورا (سنة كاملة)، وبنطلب منه يتنبأ بـ 18 شهر من النقطة دي.

ليه بنرجع 12 شهر مش شهر واحد؟ عشان لو رجعنا شهر واحد، النوافذ هتبقى متداخلة جداً وكأننا بنقيس نفس الحاجة 3 مرات. الرجوع سنة كاملة بيدّي مواقف مختلفة فعلاً في السلسلة.

ليه 3 نوافذ مش واحدة؟ عشان لو قيّمنا على نقطة واحدة بس، ممكن نكون وقعنا على شهر استثنائي (أزمة، عيد، حاجة غريبة) والنتيجة كلها تبقى حظ. ثلاث نقاط بتقلّل الحظ ده.

وليه 18 شهر بالذات؟ لأن ده الأفق الرسمي اللي مسابقة M4 نفسها حدّته للسلاسل الشهرية. يعني نتايجنا تبقى قابلة للمقارنة مع أي نتيجة منشورة على M4.

وليه 2,932 نافذة مش 3,000؟

سلسلة $3 \times 3,000 = 1,000$ — بس الرقم الحقيقي 2,932. الفرق 68 نافذة. ليه؟

السبب في جملة: مش كل سلسلة طولها يسمح بـ 3 نوافذ. السلاسل القصيرة بتدّي أقل، وإحنا مرميناهاش — أخذنا منها اللي طولها يسمح بيه.

الشرط بالظبط، ومن فين جه

عشان النافذة رقم k تعدي (يعني $k = 0$ للأولى، 1 للتانية، 2 للتالثة)، لازم اللي يفضل للموديل يشوفه ما يقلّش عن 120 شهر. والحساب:

• إحنا بنرجع لورا $12k$ شهر عشان نوصل لل origin بتاع النافذة دي.

• وبنشيل 18 شهر (الأفق) عشان نخبيهم.

• فاللي بيفضل للموديل $n - 12k - 18$.

فالشرط:

$$n - 12k - 18 \geq 120 \quad \Longleftrightarrow \quad n \geq 138 + 12k$$


نطبّقه على النوافذ الثلاثة:

النافذة	k	الشرط	يعني السلسلة لازم تكون
الأولى	0	$n \geq 138 + 0$	≤ 138 شهر
الثانية	1	$n \geq 138 + 12$	≤ 150 شهر
الثالثة	2	$n \geq 138 + 24$	≤ 162 شهر


ودي بالظبط الأرقام اللي في الشكل تحت. ولاحظ إن شرط النافذة الأولى (138) هو **نفسه** شرط اختيار العيّنة من الأول — عشان كده مفيش ولا سلسلة طلعت بصفر نوافذ.

الشكل: إزاي السلسلة بتتقسّم لنوافذ

سلسلة طويلة (346 شهر) — التلات نوافذ كلها بتعدي




سلسلة قصيرة (145 شهر) — نافذة واحدة بس بتعدي



$$951 \times 3 + 30 \times 2 + 19 \times 1 = 2,932$$

كل طول بيدي كام نافذة؟



اللي بيتنبأ بيه (18 شهر) اللي الموديل بيشوفه (context)

شكل 5 — إزاي السلسلة الواحدة بتتحول لنوافذ، وليه القصيرة بتدي أقل. اللون الأزرق = اللي الموديل بيشوفه، والبرتقالي = الـ 18 شهر اللي بيتنبأ بيهم. الخط الأحمر المتقطع = الحد الأدنى للتاريخ (120 شهر).

• **فوق:** سلسلة طولها **346 شهر**. كل مرة بنرجع 12 شهر لورا، ولسه فاضل للموديل 328 ثم 316 ثم 304 شهر — كلهم فوق الـ 120 بكتير. فالتلات نوافذ بتعدي.

• **في النص:** سلسلة طولها **145 شهر** بس. النافذة الأولى تمام (بيفضل 127 شهر). لكن الثانية هيفضل فيها **115 شهر** — أقل من 120، ف **مرفوضة**. والثالثة 103، مرفوضة كمان. فالسلسلة دي بتدي **نافذة واحدة** وخلص.

• تحت: التوزيع النهائي على الألف سلسلة.

الحساب النهائي

عدد النوافذ	شرط الطول	عدد السلاسل	إجمالي النوافذ
3 نوافذ	$n \geq 162$	951	$951 \times 3 = 2853$
نافذتين	$150 \leq n < 162$	30	$30 \times 2 = 60$
نافذة واحدة	$138 \leq n < 150$	19	$19 \times 1 = 19$
الإجمالي		1,000	2,932

$$2853 + 60 + 19 = 2932$$

★ وليه ده مهم أصلاً؟

ممکن تقول: "طب ما كنت تشيل الـ 49 سلسلة القصيرة وتخليها $2,853 = 3 \times 951$ وخلص، الرقم يبقى مضبوط!" — وده بالضبط اللي معملناهوش، وليه سبين:

1. رمي البيانات القصيرة **يحيّز النتيجة**. السلاسل القصيرة هي أصعب حالة على الطرق الكلاسيكية (فاكر درس الـ **estimability** في القسم 8.3). لو شلناها، نبقى شلنا بالضبط الحالات اللي **TimesFM-3** بيتفوق فيها — يعني **حيّزنا النتيجة ضد نفسنا** من غير ما ناخذ بالنّا.

2. الرقم "الوحش" **أصدق من الرقم المضبوط**. لما تلاقي في ورقة رقم زي 2,932 بدل 3,000 المستديرة، ده مؤشر إن الباحث **مزوّقش** — وصف اللي حصل فعلاً. الأرقام المستديرة أوي في الأوراق أحياناً بتبقى علامة إن حد رمى بيانات عشان الجدول يبقى شكله حلو.

من الآخر: الرقم 2,932 مش غلط ولا نقص — ده **نتيجة قاعدة واضحة** ($n \geq 138 + 12k$) اتطبقت على أطوال حقيقية مختلفة، وكل سلسلة أخذت اللي طولها يسمح بيه بالضبط.

10.4 ★ ★ Why Use Data the Model May Have Seen? — ليه نستخدم بيانات الموديل يمكن يكون شافها؟

ده أهم سؤال في القسم كله، وسؤال وجيه جداً. الإجابة من ثلاث حتت:

الحتة الأولى: إحنا مش بنبني الادعاء الأساسي عليها
الادعاء الرئيسي للورقة مبني على **المحاكاة** — لأن هناك التلوث **مستحيل بالبناء**. القسم ده بيجابو على سؤال **تاني خالص وأضيق:**

السلاسل الحقيقية بتشبه أنهى نظام من الأنظمة التسعة اللي حاكيها؟

وده سؤال مشروع تماماً حتى لو البيانات ملوثة، لأنه سؤال عن **شكل البيانات** مش عن **مين أدق**.

الحتة الثانية: المحاكاة لوحدها ممكن تكون **منفصلة عن الواقع**
لو الورقة اكتفت بالمحاكاة، أول اعتراض من أي محكم هيبقى: "كلامكم حلو على بيانات صناعية — بس الدنيا الحقيقية مش كده". فلازم نوريه إن نتايجنا **بتتكرر** على بيانات حقيقية.

وده اللي حصل بالطبط: نفس النمط ظهر في الاتنين. والاتفاق ده قيمته أكبر من أي طبقة لوحدها، لأن ضعف كل طبقة معاكس للتانية:

التلوث	المحاكاة	M4 الحقيقية
مستحيل بالبناء	محتمل جداً	
الواقعية	صناعية ومبسطة	حقيقية 100%

يعني لو حاجة طلعت صح في الاتنين، تبقى مش صدفة تصميم ولا صدفة تلوث.

الحته الثالثة ★ — التعادل نفسه دليل

دي النقطة الذكية اللي تستاهل تفتكرها.

لو كان TimesFM-3 بيغش فعلاً (يعني حافظ سلاسل M4 من التدريب)، كنا هنتوقع إيه؟ كنا هنتوقع إنه يسحق الطرق الكلاسيكية سحق — لأنه حرفياً شايف الإجابة.

بس ده مش اللي حصل. هو اتعادل مع $p = 0.27$ ، (52.6% AutoARIMA) واتعادل مع الـ (48.5% Combination $p = 0.27$). يعني حتى على البيانات اللي هو "متهم" إنه شافها، مكسبش عليهم.

فالتعادل ده في حد ذاته دليل ضد فرضية إن الموديل بيستفيد استفادة ضخمة من الحفظ. مش دليل قاطع — يمكن حافظ حته صغيرة — بس هو أقوى حاجة تقدر تستنتجها من بيانات عامة.

من الآخر: إحنا بنستخدم M4 عارفين إنها ملوثة، وقايلين كده بصراحة في الورقة، ومش بانيين عليها الادعاء الرئيسي. بنستخدمها عشان نعرف شكل الواقع ونشوف هل المحاكاة بتوصف الدنيا الحقيقية ولا لأ. والنتيجة إن الاتنين بيقولوا نفس الكلام.

النتيجة

الطريقة	متوسط MASE	التغطية 80%	pinball
Combination	0.9027	0.8006	0.3653
TimesFM3	0.9114	0.7655	0.3627
AutoARIMA	0.9182	0.7851	0.3744
AutoETS	0.9465	0.7909	0.3840
Theta	0.9672	0.7344	0.3977
SeasonalNaive	1.2768	0.7867	0.5135

والاختبارات (Wilcoxon مزدوج عبر الـ 1,000 سلسلة، مصحح بـ BH):

المقارنة	% سلاسل TimesFM-3 أحسن فيها	p مصحح	الحكم
ضد SeasonalNaive	80.1%	< 0.0001	TimesFM-3 كسب
ضد Theta	56.8%	< 0.0001	TimesFM-3 كسب
ضد AutoETS	54.1%	0.0043	TimesFM-3 كسب
ضد AutoARIMA	52.6%	0.27	تعاذل
ضد Combination	48.5%	0.27	تعاذل

ملاحظات مهمتين

الأولى — الطبقتين يتفقا. النمط ده نفس نمط المحاكاة بالظبط: بيكسب على كل حاجة ما عدا **AutoARIMA** اللي بيتعاذل معاه. وسلاسل **M4** الشهرية **طويلة وموسمية** — يعني بالظبط النظام "القابل للتقدير" اللي المحاكاة اتنبأت إن الكلاسيكي هيبقى منافس فيه. والاتفاق ده قيمته أكبر من أي طبقة لوحدها، لأن الاتنين **ضعفهم معاكس لبعض**: المحاكاة نضيفة بس صناعية، والحقيقية واقعية بس ملوثة.

الثانية — نتيجة الفترات مانتقلتش. على البيانات المولدة كان **TimesFM-3** الأحسن معايرةً؛ هنا هو **ثاني أسوأ واحد**: تغطية **0.765** مقابل مطلوب **0.80**، بينما الـ **Combination** وصل **0.801**. يعني على سلاسل حقيقية فيها بنية مش موجودة في عملياتنا التسعة، الـ quantiles المتعلّمة بتاعته **بتقصّر**. وده بيخفّف من نتيجة المعايرة اللي فوق، ومتسق مع اللي **وزمائه (Adler 2026)** بلّغوا عنه.

لكن لاحظ: على الـ **pinball loss** — وهو proper scoring rule ومسجل مسبقاً — **TimesFM-3** طلع **الأحسن** (0.3627). فالصورة مش "فترات وحشة" على طول، دي "التغطية وحشة والتوزيع ككل كويس".

من الآخر: على بيانات حقيقية طويلة وموسمية، الموديل والكلاسيكي **متعادلين** في الدقة، والكلاسيكي أحسن في معايرة الفترات.

11. Costs That Don't Show in an Accuracy Table — تكاليف مش بتظهر في جدول الدقة

11.1 ★ Speed — والنتيجة بالعكس تماماً من المتوقع

الطبيعي إنك تفتكر إن موديل بـ 330 مليون parameter هو الغالي، والموديل الإحصائي بـ 3 parameters هو الرخيص. **العكس تماماً** على الجهاز ده:

الطريقة	زمن لكل سلسلة	النسبة لـ TimesFM-3
SeasonalNaive	3.1 ms	0.13×
Theta	9.0 ms	0.39×
TimesFM3 (GPU, batched)	23.2 ms	1×
AutoETS	102.0 ms	4.4×
AutoARIMA	2382.7 ms	102.8×

AutoARIMA أبطأ 103 مرة من **TimesFM-3** لكل سلسلة!

ليه؟ السبب بنيوي مش عرضي: الـ **AutoARIMA** بيعمل بحث تدريجي على الـ orders، وبيركّب كل مرشح بـ maximum likelihood، لكل سلسلة لوحدها. بينما **TimesFM-3** بيعمل مرور أمامي واحد مجمّع (batched) وبيوزّع تكلفته على الدفعة كلها.

⚠ بس التحفظ الثاني أهم من الرقم الرئيسي

الرقم ده لكل سلسلة على نواة واحدة — والصورة بتتغير لما تشغل الكل بالتوازي. الأرقام الحقيقية من الـ log بتاع التشغيل:

- الطرق الكلاسيكية الأربعة على الـ 7,200 سلسلة كلها بـ 22 نواة: 7.3 دقيقة
- **TimesFM-3** على نفس الشغل بـ GPU واحد: 3.2 دقيقة
- النسبة: 2.3× — مش 103×!

يعني: الـ 103× صح لكل سلسلة على نواة واحدة، لكن الكلاسيكي بيتوازي ببساطة، والتوازي بيسترد معظم الفرق. الرقمين يجاوبوا على سؤالين مختلفين، وإنّي أقول الأول بس يبقى مبالغة. (وكمان **TimesFM-3** محتاج GPU أصلاً).
من الآخر: الموديل الجبار مش الخيار الغالي — لا لكل سلسلة ولا في الإجمالي. بس الفرق الإجمالي 2.3× مش 103×.

11.2 ★★ Licensing — وده أهم بند عملي في الورقة كلها

أوزان **TimesFM-3** صادرة تحت رخصة **timesfm-non-commercial-license-v1.0** — يعني استخدام غير تجاري وغير إنتاجي فقط.

الكود نفسه Apache-2.0، وأوزان **TimesFM-2.5** كانت Apache-2.0 كمان. لكن أوزان النسخة 3 لأ.

النتيجة العملية مطلقة وسابقة لأي كلام عن الدقة: لو إنت بتشتغل في تطبيق تنبؤ تجاري، فـ **TimesFM-3** بشكله المنشور مش متاح لك أصلاً — عند أي مستوى دقة. تقليل 26% في الخطأ على الطلب المتقطع ملهوش أي معنى لتاجر تجزئة مش مسموح له قانونياً ينشر الموديل ده.

الخيارات المتاحة: تستخدم **TimesFM-2.5** تحت Apache-2.0، أو تتفاوض على شروط منفصلة مع Google، أو تستخدم طريقة كلاسيكية. كل طريقة كلاسيكية في المقارنة دي خالية من القيود دي.

بنقول ده مش كنقد لـ Google — بنقوله لأنه **بيتشال دايماً** من مقارنات الموديلات، وهو **بيقلب الترتيب رأساً على عقب** لفئة كاملة من المستخدمين.

من الآخر: قبل ما تسأل "أدق؟" اسأل "مسموح لي أصلاً؟"

Interpretability 11.3 — القابلية للتفسير والتشخيص

ARIMA بيقولك الـ orders والمعاملات والأخطاء المعيارية بتاعتها. **ETS** بيقولك معاملات التنعيم والحالات. ودول بيسمحوا بشغل التشخيص العادي: تفحص الـ residuals، تختبر الارتباط الذاتي المتبقي، تفسّر لصاحب القرار **ليه** التنبؤ بيلف هنا، وتكتشف إن الموديل **بطل يظبط**.

TimesFM-3 **مبيديش حاجة من دول**. لما يتنبأ غلط، مفيش parameter تبصله ولا تشخيص تشغله — اللي تقدر تعمله إنك **تلاحظ** الأخطاء وتغيّر الطريقة. وفي بيئة منظّمة (regulated) لازم تبرّر التنبؤ مش بس تنتجه — الفرق ده لوحده ممكن يترجّح على المقارنة كلها.

Prediction Intervals in Theory 11.4 — الفترات نظرياً

الفترات الكلاسيكية مشتقة من **بنية الخطأ المفترضة**، فتقدر تناقشها تحليلياً. أما **TimesFM-3** quantiles فهي **مخرجات متعلّمة** من رأس شبكة، من غير نظرية. أثبتنا فوق إنها في الواقع أحسن معايير في المتوسط — **بس تجريبياً، على العمليات دي**، مش بالبناء. وسلوكها على عملية شبيهة بحاجة مش موجودة في corpus التدريب **مجهول بالتعريف**.

12. ★ When to Use Which — امتى تستخدم إيه (جدول القرار)

ده خلاصة الورقة العملية:

الموقف	استخدم	الدليل
نشر تجاري أو إنتاجي	كلاسيكي (أو TimesFM-2.5)	أوزان v3 رخصتها غير تجارية — الدقة مش القيد أصلاً
طلب متقطع، وتكلفتك خطية	TimesFM-3	كسب على السنة Croston في 24/24 مقارنة
طلب متقطع، وتكلفتك تربيعية	Croston-SBA / ADIDA	بيكسبوا على RMSSE في كل طول
موسمية قوية + ≤ 4 دورات	AutoARIMA	أحسن بـ 21-24%، كلها $p > 0.0001$
موسمية بس $\geq$ دورتين	TimesFM-3 أو SeasonalNaive	الكلاسيكي الأوتوماتيكي يبيع: AutoETS = 3.03
آلاف السلاسل، مفيش وقت تضبط كل واحدة	TimesFM-3	بيكسب على كل الطرق ما عدا AutoARIMA
سلسلة واحدة وإنترنت عارف تحدد وتقدر الموديل	كلاسيكي	AutoARIMA متعادل (11-9)، ومجاني ومفسر
كسر هيكلي قريب والفترات مهمة	TimesFM-3	تغطية مشابهة بفترات نص العرض (محاكاة بس)
الإنتاجية مهمة وعندك GPU	TimesFM-3	أسرع $103 \times$ لكل سلسلة، $2.3 \times$ إجمالاً
فترات ثابتة على بيانات حقيقية	Combination II	على 0.801: M4: مقابل 0.765 لـ TimesFM-3
لازم تفسر أو تراجع (audit)	كلاسيكي	TimesFM-3 مبيدّيش parameters ولا تشخيص

13. The Hypotheses — الفرضيات: مفيش واحدة نجت سليمة

سجلنا 5 فرضيات قبل أي تنبؤ. والنتيجة:

#	الفرضية	الحكم
H1	الكلاسيكي يكسب على أرضه، والفرق أكبر عند n صغير	✗ مفندة — الفرق يبروح في الاتجاه المعاكس عند n صغير
H2	TimesFM-3 يكسب حيث لا شكل كلاسيكي صحيح	⚠ مدعومة جزئياً — على MASE و pinball نعم، على RMSSE و SMAPE لا
H3	في D9 يتعادلا في المتوسط والكلاسيكي يقصر في التغطية	⚠ جزئياً — التعادل صح، لكن AutoARIMA بس هو اللي بيقتصر
H4	Combination ال يكسب على كل فرد ويكون أصعب خصم	✗ مفندة في الشقين — AutoARIMA أحسن منه، وهو الخصم الأصعب (11-9 مقابل 27-3)
H5	الطرفين يقصروا في تغطية 80%	✗ مفندة — على المتوسط TimesFM-3 على المطلوب والكلاسيكي بيزود من $n=96$

النقطة المهمة: إن كل فرضية فشلت في حته ما هو أقوى حجة للتسجيل المسبق. لو الفرضيات اتكتبت **بعد** النتائج، القسم ده كان هيبّلغ 5 تأكيدات.

من الآخر: التسجيل المسبق مش بيروقراطية — هو اللي خلانا نقول "غلطنا" 3 مرات بدل ما نقول "توقعنا صح" 5 مرات.

14. Limitations — حدود الدراسة (بصراحة)

- 1. قوة المحاكاة هي حدودها كمان.** سلاسل مولدة من 9 عمليات بارامترية **مش** سلاسل حقيقية: هي نضيفة، ومستقرة حيث حددنا، وخالية من خطأ القياس والتأثيرات التقويمية والعروض الترويجية وتغيرات النظام. اللي اشتترته المحاكاة (غياب التلوث + معرفة التخصيص الصحيح) دفعت تمنه **واقعية**.
- 2. قيّمنا الموديل zero-shot و univariate بس.** الجديد الأساسي فيه هو ال **multivariate** بال covariates، والقدرة دي **مش متختبرة هنا** لأن عملياتنا كلها أحادية المتغير بالبناء. دراسة تستغل المعلومات عبر السلاسل ممكن توصل لنتائج مختلفة — وده الامتداد الطبيعي.
- 3. مفيش تطبيق يدوي لأي طريقة.** ده مقصود وهو الوضع اللي معظم المحللين بيقابله، لكن خبير يشوف كل عملية بعينه ويركب الموديل المناسب بإيده **هيكسب على كل** طريقة أوتوماتيكية هنا.
- 4. الأفق قصير ($H=12$) والفترة الموسمية ثابتة عند 12.** آفاق أطول وترددات تانية ممكن تختلف.
- 5. تحليل الطلب المتقطع بعدي (post-hoc)** — أضفنا Croston بعد ما شفنا النتائج، ردأ على ثغرة اتحدت في المراجعة، ونبيلّغه منفصل عن المقارنة المسجلة مسبقاً.
- 6. الدراسة مركزة على موديل واحد.** ضفنا TimesFM-2.5 و Chronos-Bolt في القسم 9.8، وطلعوا بيتصرفوا مختلف عن TimesFM-3 — وده دليل إن نتائج موديل واحد مابتعمّمش على الفئة. Moirai والإصدارات الأحدث مش متقيّمة.
- 7. العائلات نفسها ثابتة.** القسم 9 خلّى القيم عشوائية وكسر 3 فرضيات (واحدة واحدة، مش مع بعض)، بس لسه 9 عائلات أحادية المتغير بفترة 12. التصميم العشوائي بيغطّي حوالي 76% من سلاسل M4 الشهرية في فضاء خصائص من 4 أبعاد — يعني حوالي الربع من السلاسل الشهرية الحقيقية، وكل الترددات التانية، برّا المناطق اللي درسناها.

8. دراسة استكشافية عن صندوق أسود. التصميم يقيس إيه اللي TimesFM-3 بيعمله تحت ظروف معروفة، مش
ليه: البارامترات مالهاش تفسير فردي، وبيانات التدريب مش متاحة. أي تفسير لسلوكه في الورقة هو تفسير متسق مع
الأرقام، مش نتيجة.

15. Honesty & Reproducibility — إعادة الإنتاج والأمانة

15.1 Pre-registration and Deviations — التسجيل المسبق والانحرافات

- **PREREGISTRATION.md** متجمّد قبل أي تنبؤ، ومتعدّلش أبداً بعد كده.
- **DEVIATIONS.md** فيه 12 انحراف، كل واحد بتاريخه وسببه، مقسومين مجموعتين:
- **D-01 J D-03** اتعملوا قبل وجود أي نتيجة (تصليح توزيعات البيانات).
- **D-04 J D-12** اتعملوا بعد وجود نتائج، وكل واحد بيقول كده في مدخله (آخرهم D-10 J D-12 دراسة المتانة، وخط الأساس Oracle ARIMA، وتحليلات مراجعة المحكّمين في القسم 9).
- ⚠️ **والتقسيم دي مهمة، مش شكلية:** انحراف اتعمل قبل ما تشوف أي نتيجة مختلف تماماً عن انحراف اتعمل بعدها. الأول مستحيل يكون متحيّز لنتيجة معيّنة، لأنها لسه مش موجودة أصلاً؛ الثاني ممكن يكون. عشان كده كل مدخل في المجموعة الثانية بيقول صراحةً إنه بعدي، وإيه اللي دفعه، وهل بيأثر على نتيجة مسجلة مسبقاً ولا لا.

15.2 Real Bugs Caught — أخطاء حقيقية اتمسكت، وإزاي

- ★ **الغلط الأخطر: اختلال محاذاة صامت.** لما ربّنا سلاسل M4 بـ `unique_id = str(i)`، مكتبة `statsforecast` رجّعت الصفوف بترتيب أبجدي: "0"، "1"، "10"، "100"، "1000"... بينما الكود بيعيد التشكيل على أساس ترتيب رقمي. النتيجة: كل تنبؤ اتقرن بالسلسلة الغلط. ومفيش أي رسالة خطأ — الكود اشتغل عادي!
- اكتشفناه إزاي؟ لأن `SeasonalNaive` طلع `MASE = 28.9`، وده مستحيل: هو أساساً مقام الـ MASE، فلازم يبقى حوالي 1.
- الدرس (وده أهم درس هندسي في المشروع):** لازم يبقى معاك دايماً رقم واحد على الأقل تعرف قيمته الصحيحة مسبقاً. عشان الغلط الصامت يبقى مستحيل مش بس مستغرب. والحل: `f"{i:07d}"` — أصفار في الأول عشان الترتيب الأبجدي = الرقمي.

غلط ثاني: الـ `Diebold-Mariano` غير الصالح (شرحناه في 7.2) — اتمسح.

غلط ثالث: ادعاء إن "كل DOI اتحقق منه عبر Crossref" كان غير دقيق — السكربت كان بيراجع قائمة مكتوبة بالإيد موازية للـ `refs.bib`، والاتنين افترقوا، و6 DOIs في المراجع مراجعوش خالص (كلهم arXiv، و Crossref ميخدمهاش أصلاً).
اتصلّح: السكربت دلوقتي بيقرأ الـ `bib` نفسه ويحلّ الـ DOI عبر `doi.org` اللي بيرد عن Crossref و DataCite دلوقتي 30 من 30 بيتحلّوا.

15.3 Archiving and Publication — الأرشفة والنشر

- **المستودع العام:** `https://172.github.com/ebrahimkhaled/timesfm-classical-paper` ملف، 115 ميغا: الكود كامل + المقاييس لكل سلسلة في الـ 129,600 تقييم + التنبؤات الخام + الأشكال + مصدر المخطوطة).
- **Zenodo:** بالطريقة المعتادة — تفعيل المستودع من موقع Zenodo، وبعدين عمل release على GitHub، والـ webhook بيسك الـ DOI لوحده. وملف `zenodo.json`. موجود في جذر المستودع ف Zenodo بياخد العنوان والـ

ORCID والرخصة منه أوتوماتيك.

- **ليه ننشر التنبؤات الخام؟** مش للكمال — عشان نتيجة الطلب المتقطع **بتنقلب** بين المقاييس، فأني قارئ عايز يعيد التقييم بدالة خسارة مختلفة يقدر **من غير ما يعيد الدراسة كلها**.
- **arXiv:** الحزمة اتبنت واثققت في **غرفة نظيفة** (extract في مجلد فاضي + compile) — صفر أخطاء، صفر مراجع غير معرّفة. الفئة الأساسية **stat.ME** مع cross-list على **stat.AP** و **cs.LG**.
- **أوزان الموديل مش متعادة نشرها** — رخصتها غير تجارية، والكود بينزلها من Hugging Face.

16. الخلاصة الكبيرة — لو هتفتكر 5 حاجات بس

1. **مفیش طرف كسب.** الموديل كسب 16 خلية والكلاسيكي 20 — بس الـ 20 دول موزعين على 5 طرق مختلفة، والموديل واحد من غير تطبيق.
 2. **AutoARIMA** هو الوحيد اللي بيصمد (9-11). كل اللي غيره — حتى دمج الثلاثة — بيتغلب في الغالبية.
 3. **التخصيص الصحيح ≠ القابلية للتقدير.** بدورتين موسميتين، **AutoETS** خسر بـ 2.7 مرة قدام قاعدة من سطر واحد — على بيانات هو اللي ولّدها. ولو شلنا الموسمية خالص يبقي أسوأ كمان (2.55). والدرس ده ظهر على بيانات M4 الحقيقية: بآخـر 24 نقطة بس، **TimesFM-3** أحسن من **AutoARIMA** بـ 11%.
 4. **الموديل بيشتري المتانة مش الدقة القصوى.** عمره ما بقى أسوأ من 1.31× من الأحسن (فترة ثقة 1.28-1.36)، بينما كل كلاسكي يبقي $\leq 2.2\times$ أسوأ في مكان ما. بس المتانة دي خاصة بـ **TimesFM-2.5** (**TimesFM-3** و **Chronos-Bolt** مش أمتن من **AutoARIMA**)، وبتتقفل لما الكلاسيكي يقدر الفترة الموسمية باختبار عادي. وفي الطلب المتقطع ميزته في **التوزيع** مش في التنبؤ النقطي.
 5. **حاجتين بيقطعوا عرض المقارنة كلها:** الموديل أسرع 103× لكل سلسلة من **AutoARIMA** (مش أغلى!)، ورخصته غير تجارية — يعني لفئة كاملة من المستخدمين السؤال محسوم قبل أي كلام عن دقة.
- من الآخر خالص:** مش "الجديد أحسن من القديم" ولا العكس — الجديد أثبت، والقديم أدق لما يقدر يتقدر، والرخصة ممكن تحسم الموضوع قبل الاتنين.

الملف ده شرح مصاحب للورقة. الأرقام كلها متطابقة مع ملفات النتائج في **results/**، وكل رقم في الورقة نفسها متربوط بملف CSV بيثبتته (18 من 18 فحص بيعدّي).